PROYECTO 2 · ANÁLISIS EXPLORATORIO

Presentación del repositorio

MAP — Charting Student Math Misunderstandings

Procesamiento del Lenguaje Natural aplicado a explicaciones matemáticas

Abrir repositorio en GitHub

Jorge Gabriel Palacios Sales · Pablo Daniel Barillas Moreno · Roberto Emiliano Otoniel Camposeco Torres · Abby Sofia Donis Agreda
CC3084 — Data Science, Sección 10
Universidad del Valle de Guatemala · 2026

RESUMEN

Lectura rápida del proyecto

Este documento presenta cómo está organizado el repositorio, qué artefactos contiene y cómo reproducir el análisis. El notebook fue ejecutado desde cero con los CSV locales; sus 26 celdas de código finalizaron sin errores y las siete figuras de los entregables se regeneraron desde esas salidas.

36,696	15	35	18
explicaciones analizadas	preguntas	concepciones erróneas	diapositivas PPTX/HTML

Propósito

- Documentar un EDA de explicaciones matemáticas abiertas con variables categóricas, textuales y contextuales.
- Conectar los hallazgos del notebook con la situación problemática, los objetivos y las decisiones de modelado NLP.
- Mantener trazabilidad entre datos, código, figuras, informe, presentación y control de versiones.

Idea central

La respuesta seleccionada no basta: el sistema debe interpretar conjuntamente pregunta, opción y explicación para distinguir corrección, razonamiento y concepción errónea.

Acceso

Repositorio: https://github.com/DanielBarillasM/Proyecto-2_Grupo-1_DS_Sec-10

Rama inspeccionada: main · Licencia: MIT · Área principal: notebooks/

ARQUITECTURA DE ARTEFACTOS

Mapa del repositorio

```
Proyecto-2_Grupo-1_DS_Sec-10/
├── data/
│   ├── train.csv
│   ├── test.csv
│   └── sample_submission.csv
├── instructions/
│   └── Proyecto 2. Análisis Exploratorio. 2026.pdf
├── notebooks/
│   ├── 01_analisis_exploratorio.ipynb
│   └── exportar_figuras.py
├── report/
│   ├── assets/
│   ├── informe_analisis_exploratorio_MAP.tex / .pdf
│   └── revision_bibliografica_algoritmos_MAP.tex / .pdf
├── presentation/
│   ├── presentacion_MAP.html
│   ├── presentacion_MAP.pptx / .pdf
│   └── generar_presentacion.py
├── file/
│   └── Presentacion_Repositorio_MAP.docx / .pdf
├── requirements.txt
├── LICENSE
└── README.md
```

Zona	Función	Estado observado
data/	Archivos del reto para análisis local	Presente; excluido de Git por tamaño/privacidad
notebooks/	EDA y resultados persistidos	Notebook principal presente
instructions/	Guía académica y rúbrica	PDF de instrucciones presente
report/	Informe, figuras y entregables	Informes, activos y presentaciones verificados localmente
README.md	Puerta de entrada al proyecto	Completo: contexto, resultados, reproducción y entregables

FLUJO DE TRABAJO

Del dato al entregable

01	**Fuente**	CSV locales del reto MAP
02	**Análisis**	Notebook Jupyter con EDA
03	**Evidencia**	Salidas y siete figuras persistidas
04	**Síntesis**	Informe LaTeX con investigación y APA 7
05	**Comunicación**	PDF, HTML interactivo, PowerPoint editable y DOCX

Regla de trazabilidad
Las cifras se contrastaron con train.csv. El notebook se ejecutó en orden y las siete figuras se exportaron de sus salidas antes de regenerar los informes y la presentación.

Piezas principales

Archivo	Audiencia	Uso
01_analisis_exploratorio.ipynb	Equipo técnico	Código, tablas y gráficas del EDA
informes EDA y revisión bibliográfica (.pdf/.tex)	Docente/evaluación	Rúbrica EDA, investigación APA y selección preliminar
presentacion_MAP.html / .pptx	Exposición	Recorrido visual interactivo y PowerPoint editable
Presentacion_Repositorio_MAP.docx	Lectores del repositorio	Arquitectura, estado y reproducibilidad

CONTENIDO ANALÍTICO

Datos y hallazgos visibles

40.34%
True_Correct

73.1%
ausencia estructural en Misconception

13
palabras de mediana

El repositorio documenta un problema jerárquico: primero se clasifica la relación entre opción y razonamiento; después se asigna una concepción errónea solo cuando corresponde.

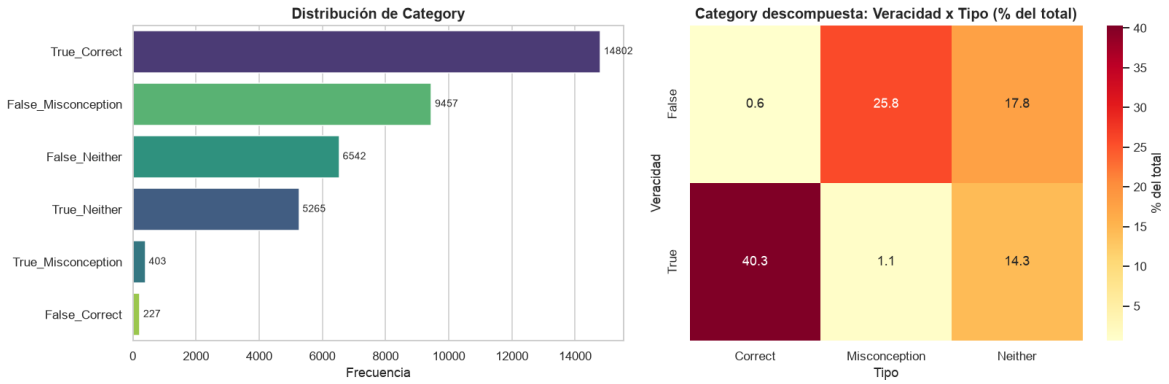


Figura 1. Distribución de la variable Category recuperada del notebook.

Interpretación

El desbalance y la ausencia estructural desaconsejan imputar etiquetas con la moda o evaluar un futuro modelo únicamente con accuracy.

CRUCES EXPLORATORIOS

La pregunta organiza el lenguaje

Las frecuencias de categorías y concepciones cambian según QuestionId. Esta dependencia es sustantiva: una separación aleatoria de filas puede permitir que vocabulario específico de una pregunta aparezca tanto en entrenamiento como en validación.

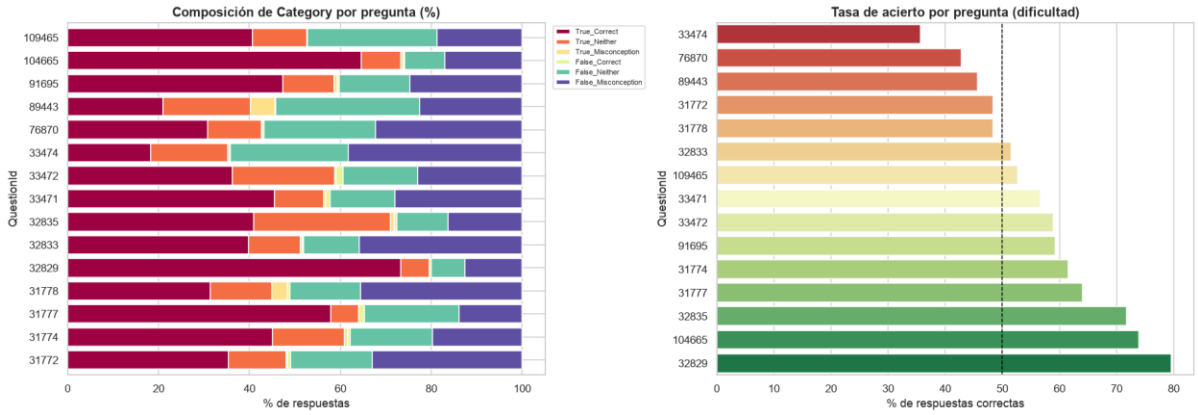


Figura 2. Cruces por pregunta almacenados en el notebook.

Implicación de diseño

- Comparar una partición estratificada con GroupKFold o leave-one-question-out.
- Reportar MAP@3 y macro-F1 junto con resultados por pregunta y por etiqueta.
- Usar QuestionId y MC_Answer como contexto, sin confundir memorización con generalización.

CÓMO VOLVER A PRODUCIR EL ANÁLISIS

Reproducibilidad

Paso	Acción	Comprobación
1	Clonar el repositorio y ubicarse en la raíz	La rama main está disponible
2	Obtener los CSV desde Kaggle	train.csv, test.csv y sample_submission.csv
3	Colocar los archivos en data/	La ruta coincide con el notebook
4	Crear un entorno e instalar requirements.txt	Versiones fijadas para análisis y generación documental
5	Ejecutar el notebook en orden	Celdas terminan sin error y resultados coinciden
6	Compilar el informe desde report/	PDF y figuras resuelven con rutas relativas

Estado de reproducibilidad

Ruta de datos
El notebook localiza data/ y data/raw desde la raíz o desde notebooks/.

Dependencias
requirements.txt fija el entorno de análisis y los generadores documentales.

Estado corregido
Ruta flexible, dependencias fijadas, notebook ejecutado sin errores, figuras sincronizadas y entregables compilados. Solo resta hacer commit y push cuando el equipo apruebe la versión final.

Fuentes documentales

King, J., Smith, K., Burleigh, L., Crossley, S., Demkin, M., & Reade, W. (2025). MAP—Charting student math misunderstandings. Kaggle.

Rittle-Johnson, B., Adler, R., Durkin, K., Burleigh, L., King, J., & Crossley, S. (2025). Detecting math misconceptions: An AI benchmark dataset. AIME-Con WIP, 20–24.

Universidad del Valle de Guatemala. (2026). Proyecto 2: Análisis exploratorio [Guía del curso].

Repositorio local y salidas verificadas de notebooks/01_analisis_exploratorio.ipynb.