PROYECTO 2 · ANÁLISIS EXPLORATORIO

Presentación del repositorio

MAP — Charting Student Math Misunderstandings

Procesamiento del Lenguaje Natural aplicado a explicaciones matemáticas

Abrir repositorio en GitHub

Daniel Barillas · Mario Gómez · Marco Romero
CC3084 — Data Science, Sección 10
Universidad del Valle de Guatemala · 2026

RESUMEN EJECUTIVO

Lectura rápida del proyecto

Este documento presenta **cómo está organizado el repositorio, qué artefactos contiene y qué hace falta para que otra persona pueda reproducir el análisis**. No reejecuta el notebook ni recalcula resultados; describe la evidencia ya persistida en él.

36,696	15	65	18
explicaciones analizadas	preguntas	concepciones erróneas	diapositivas HTML

Propósito

- Documentar un EDA de explicaciones matemáticas abiertas con variables categóricas, textuales y contextuales.
- Conectar los hallazgos del notebook con la situación problemática, los objetivos y las decisiones de modelado NLP.
- Mantener trazabilidad entre datos, código, figuras, informe, presentación y control de versiones.

Idea central

La respuesta seleccionada no basta: el sistema debe interpretar conjuntamente pregunta, opción y explicación para distinguir corrección, razonamiento y concepción errónea.

Acceso

Repositorio: https://github.com/DanielBarillasM/Proyecto-2_Grupo-1_DS_Sec-10

Rama inspeccionada: main · Licencia: MIT · Área principal: notebooks/

ARQUITECTURA DE ARTEFACTOS

Mapa del repositorio

```
Proyecto-2_Grupo-1_DS_Sec-10/
├── data/
│   ├── train.csv
│   ├── test.csv
│   └── sample_submission.csv
├── instructions/
│   └── Proyecto 2. Análisis Exploratorio. 2026 (4).pdf
├── notebooks/
│   └── MAP_Student_Math_Misunderstandings.ipynb
├── report/
│   ├── assets/
│   ├── informe_analisis_exploratorio_MAP.tex / .pdf
│   ├── presentacion_MAP.html
│   └── Presentacion_Repositorio_MAP.docx
├── .gitignore
├── LICENSE
└── README.md
```

Zona	Función	Estado observado
data/	Archivos del reto para análisis local	Presente; excluido de Git por tamaño/privacidad
notebooks/	EDA y resultados persistidos	Notebook principal presente
instructions/	Guía académica y rúbrica	PDF de instrucciones presente
report/	Informe, figuras y entregables	Creado localmente; requiere commit/push
README.md	Puerta de entrada al proyecto	Incompleto: solo contiene un recordatorio

FLUJO DE TRABAJO

Del dato al entregable

01	**Fuente**	CSV locales del reto MAP
02	**Análisis**	Notebook Jupyter con EDA
03	**Evidencia**	Salidas y siete figuras persistidas
04	**Síntesis**	Informe LaTeX con investigación y APA 7
05	**Comunicación**	PDF, HTML interactivo y este DOCX

Regla de trazabilidad

Las cifras y figuras del informe provienen de salidas ya guardadas en el notebook. La preparación documental no ejecutó celdas ni modificó los datos.

Piezas principales

Archivo	Audiencia	Uso
MAP_Student_Math_Misunderstandings.ipynb	Equipo técnico	Código, tablas y gráficas del EDA
informe_analisis_exploratorio_MAP.pdf	Docente/evaluación	Desarrollo científico completo según rúbrica
presentacion_MAP.html	Exposición	Recorrido visual interactivo de 18 diapositivas
Presentacion_Repositorio_MAP.docx	Lectores del repositorio	Arquitectura, estado y reproducibilidad

CONTENIDO ANALÍTICO

Datos y hallazgos visibles

40.34%	73.1%	≈15
True_Correct	ausencia estructural en Misconception	palabras de mediana

El repositorio documenta un problema jerárquico: primero se clasifica la relación entre opción y razonamiento; después se asigna una concepción errónea solo cuando corresponde.

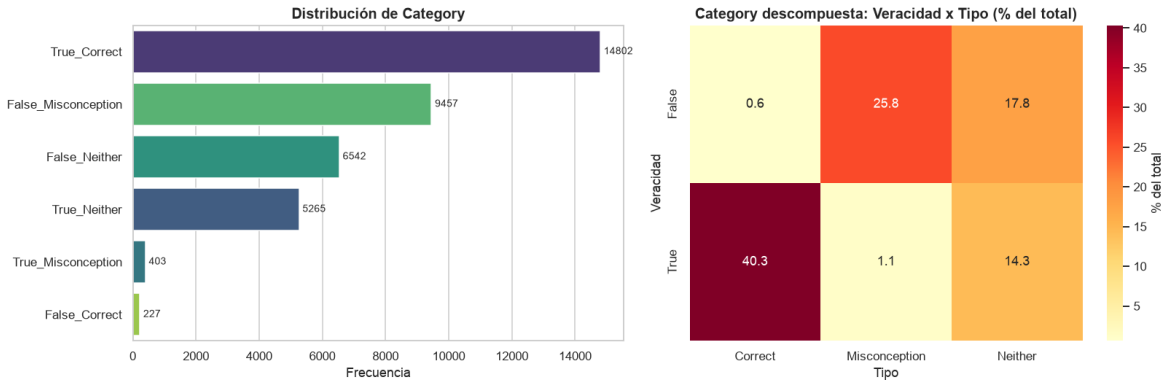


Figura 1. Distribución de la variable Category recuperada del notebook.

Interpretación

El desbalance y la ausencia estructural desaconsejan imputar etiquetas con la moda o evaluar un futuro modelo únicamente con accuracy.

CRUCES EXPLORATORIOS

La pregunta organiza el lenguaje

Las frecuencias de categorías y concepciones cambian según QuestionId. Esta dependencia es sustantiva: una separación aleatoria de filas puede permitir que vocabulario específico de una pregunta aparezca tanto en entrenamiento como en validación.

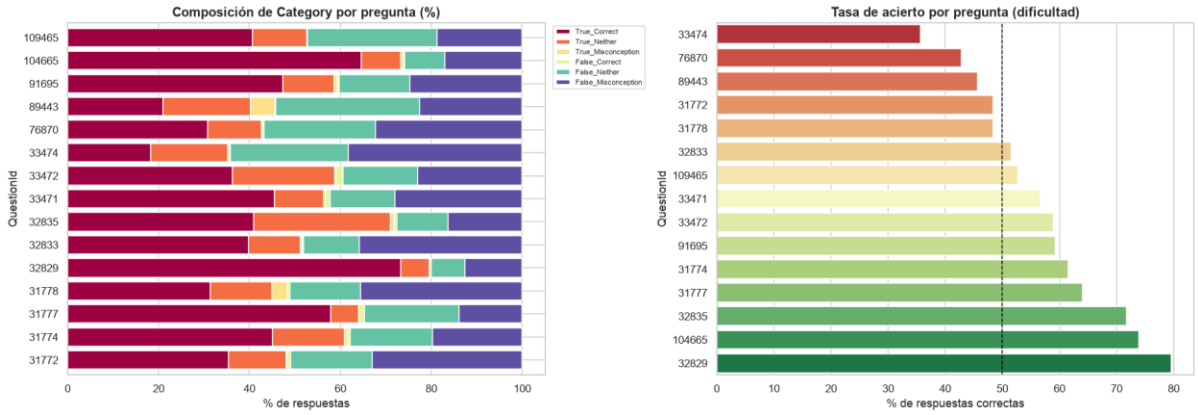


Figura 2. Cruces por pregunta almacenados en el notebook.

Implicación de diseño

- Comparar una partición estratificada con GroupKFold o leave-one-question-out.
- Reportar MAP@3 y macro-F1 junto con resultados por pregunta y por etiqueta.
- Usar QuestionId y MC_Answer como contexto, sin confundir memorización con generalización.

CÓMO VOLVER A PRODUCIR EL ANÁLISIS

Reproducibilidad

Paso	Acción	Comprobación
1	Clonar el repositorio y ubicarse en la raíz	La rama main está disponible
2	Obtener los CSV desde Kaggle	train.csv, test.csv y sample_submission.csv
3	Colocar los archivos en data/	La ruta coincide con el notebook
4	Crear un entorno y documentar dependencias	requirements.txt o environment.yml
5	Ejecutar el notebook en orden	Celdas terminan sin error y resultados coinciden
6	Compilar el informe desde report/	PDF y figuras resuelven con rutas relativas

Bloqueos observados

Ruta de datos

El notebook apunta a data/raw, pero los CSV observados están directamente en data/.

Dependencias

No existe todavía un manifiesto reproducible del entorno Python.

Corrección recomendada

Definir una única constante de ruta relativa a la raíz del repositorio, documentarla en README y añadir un archivo de dependencias antes de la entrega.

Fuentes documentales

King, J., Smith, K., Burleigh, L., Crossley, S., Demkin, M., & Reade, W. (2025). MAP—Charting student math misunderstandings. Kaggle.

Rittle-Johnson, B., Adler, R., Durkin, K., Burleigh, L., King, J., & Crossley, S. (2025). Detecting math misconceptions: An AI benchmark dataset. AIME-Con WIP, 20–24.

Universidad del Valle de Guatemala. (2026). Proyecto 2: Análisis exploratorio [Guía del curso].

Repositorio local y salidas persistidas de MAP_Student_Math_Misunderstandings.ipynb.