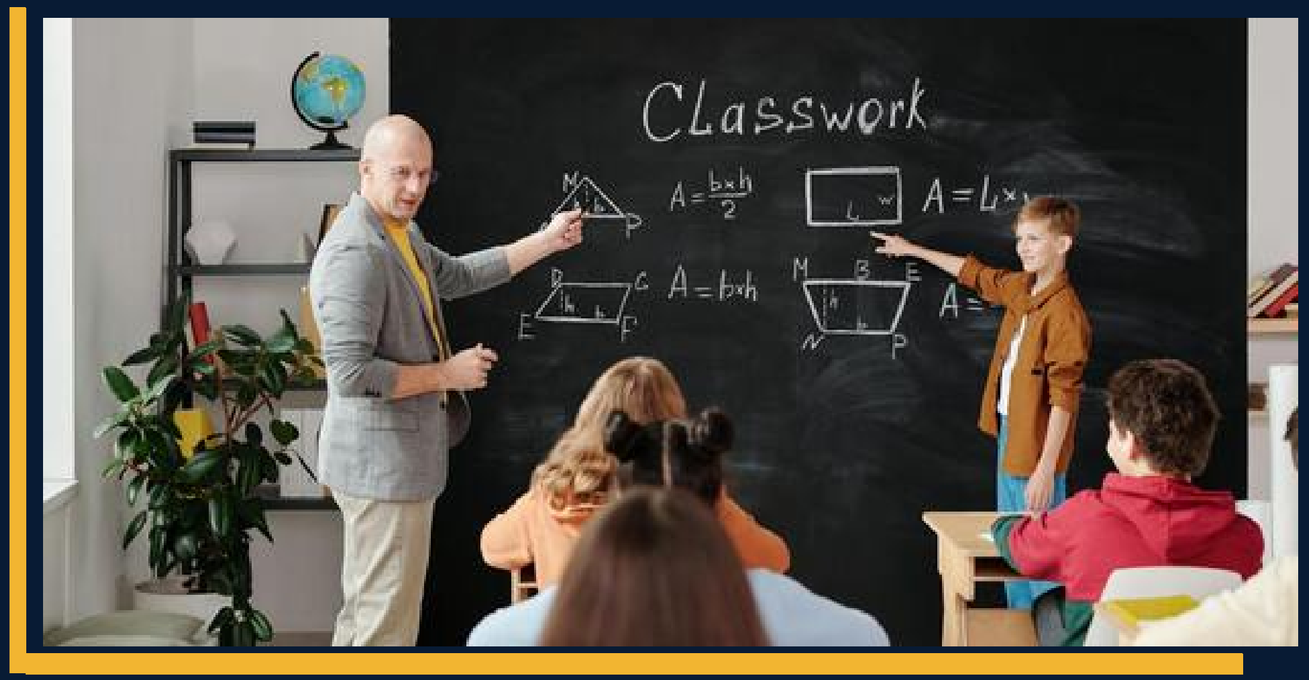
PROYECTO 2 · DATA SCIENCE

Charting Student Math Misunderstandings - Kaggle

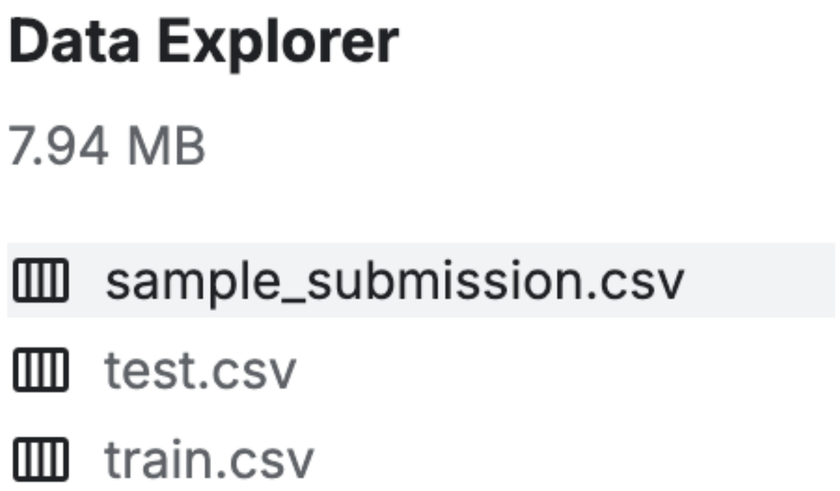
Procesamiento del lenguaje natural para comprender el razonamiento matemático

Realizado por:
· Jorge Gabriel Palacios Sales
· Pablo Daniel Barillas Moreno
· Roberto Emiliano Otoniel Camposeco Torres
· Abby Sofia Donis Agreda



Recordando el Data-set

El data set es de una competencia en Kaggle , donde se desarrolan NLP impulsado por ML (Aprendizaje Automático) para predecir con precisión los posibles conceptos matemáticos erróneos de los estudiantes basándose en sus explicaciones en respuestas abiertas.



Kaggle (2025); Rittle-Johnson et al. (2025)

Pregunta Central

¿qué patrones del texto, de su estructura y del contexto permiten distinguir si la respuesta es correcta, qué tan bueno es el razonamiento y qué concepción errónea hay detrás?



Kaggle (2025); Rittle-Johnson et al. (2025)

Del error a la explicacion escrita

Contexto Educativo

Los errores reflejan reglas aplicadas fuera de contexto o generalizacoines que fueron hechas en exceso.

La explicacion distingue un descuido de un error conceptual persistente .

Reto MAP

Predecir la categoría de la respuesta y el error conceptual que se le asocia en base de una pregunta de opcion multiple y de explicacion

Formato de salida

Una lista ordenada de hasta 3 pares ‘Category: Misconception’ que se evalua con MAP@3.

El problema combina clasificación multiclase, predicción jerárquica, ranking y procesamiento de lenguaje matemático.

Kaggle (2025); Rittle-Johnson et al. (2025)

Problema a resolver

Exigencias

1. Entender lenguaje informal y notacion matematica.
2. Condicionar a pregunta y opcion
3. Aprender clases desbalanceadas
4. Producir un ranking
5. Generalizar sin memorizar

Revisar algoritmos de aprendizaje automatico para la calificacion y deteccion de errores conceptuales y seleccionar una arquitectura preliminar.

Un clasificador prioriza casos, no reemplaza el juicio del docente



Objetivos

Objetivo general

Revisar algoritmos de aprendizaje automático aplicados a calificaciones, clasificación de respuestas cortas y detección de errores conceptuales, para seleccionar una arquitectura preliminar adecuada para el reto.

01

Identificar familias de modelos, representaciones y esquemas de evaluación

02

Contrastar ventajas y limitaciones con tamaño, estructura, desbalance y dependencia contextual del corpus.

03

Seleccionar líneas base, modelo principal, alternativas de adaptación de dominio y método de ensamble/ranking

04

Diseñar un plan experimental que evite fuga entre preguntas y mida el desempeño

05

Establecer controles de confiabilidad, explicabilidad y supervisión humana.

Alcance actual: EDA y selección preliminar completados · entrenamiento y comparación empírica pendientes

Nuestras Variables

- **QuestionId: Identificador único de la pregunta.**
- **StudentExplanation: La explicación de un estudiante para elegir una respuesta de opción múltiple específica.**
- **Misconception: [Solo en el set de entrenamiento] El concepto matemático erróneo identificado en la explicación del estudiante para sus respuestas. Solo aplica cuando la Categoría contiene un concepto erróneo, de lo contrario es 'NA'.**
- **sample_submission.csv: Un archivo de envío en el formato correcto.**
- **StudentExplanation: La explicación de un estudiante para elegir una respuesta de opción múltiple específica.**
- **Category: [Solo en el set de entrenamiento] Una clasificación de la relación entre la respuesta de opción múltiple de un estudiante y su explicación (por ejemplo, «True_Misconception», que indica la selección de una respuesta correcta acompañada de una explicación que revela un concepto erróneo).**
- **QuestionText: El texto de la pregunta.**
- **MC_Answer: La respuesta de opción múltiple que seleccionó el estudiante.**

CONJUNTO DE DATOS

Perfil del Corpus MAP

36,696	7	15	49	35	65
FILAS	COLUMNAS	PREGUNTAS	OPCIONES	ERRORES	PARES

Variables de entrada

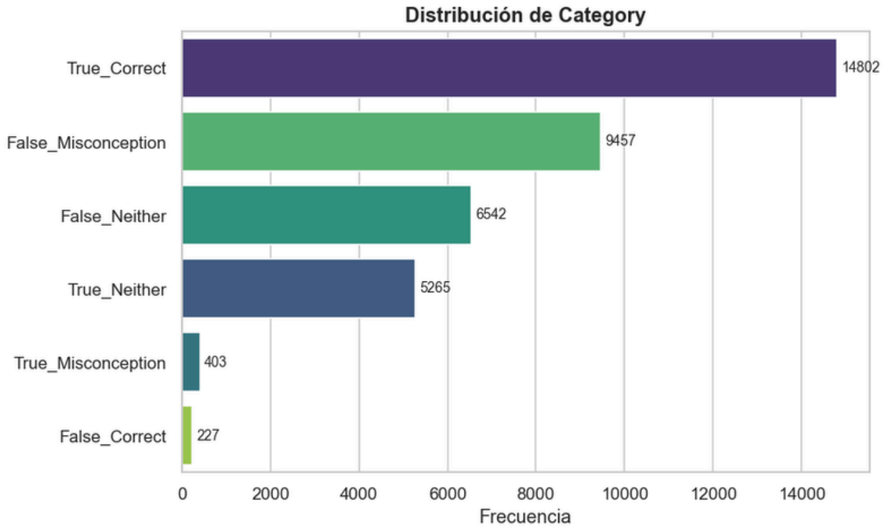
- row_id
- QuestionId
- QuestionText
- MC_Answer
- StudentExplanation

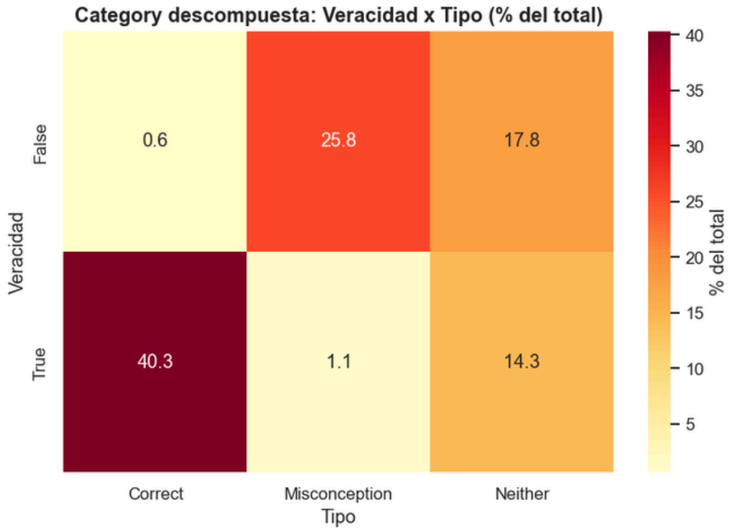
Variables objetivo

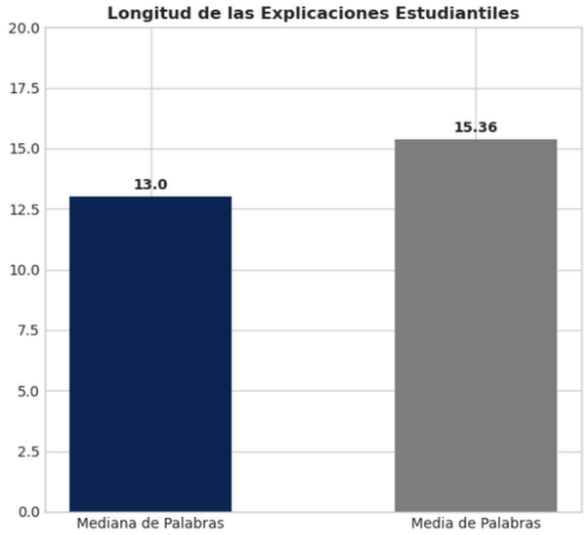
- Category combina tipo y corrección
- Misconception identifica la idea errónea cuando aplica
- La unidad de análisis es respuesta estudiantil

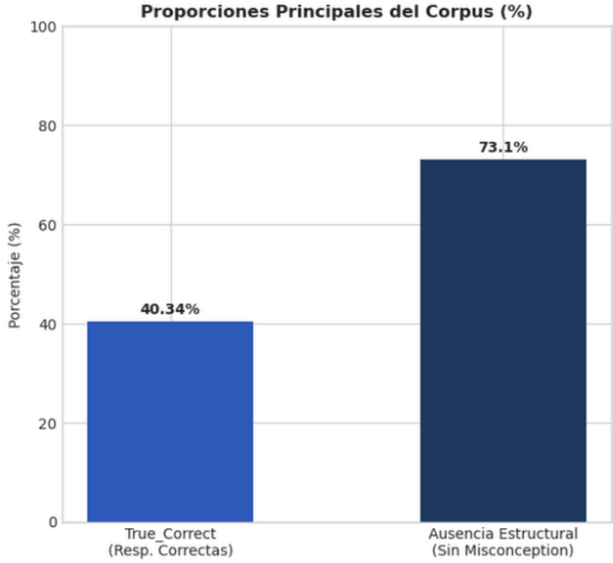
Fuente: train.csv del repositorio del proyecto

Hallazgos clave









Los nulos tienen significado semántico

26,836	73.1%	736	970
MISCONCEPTION NULOS	DEL TOTAL	DUPLICADOS SIN row_id	TEXTOS REPETIDOS

Decisiones de limpieza

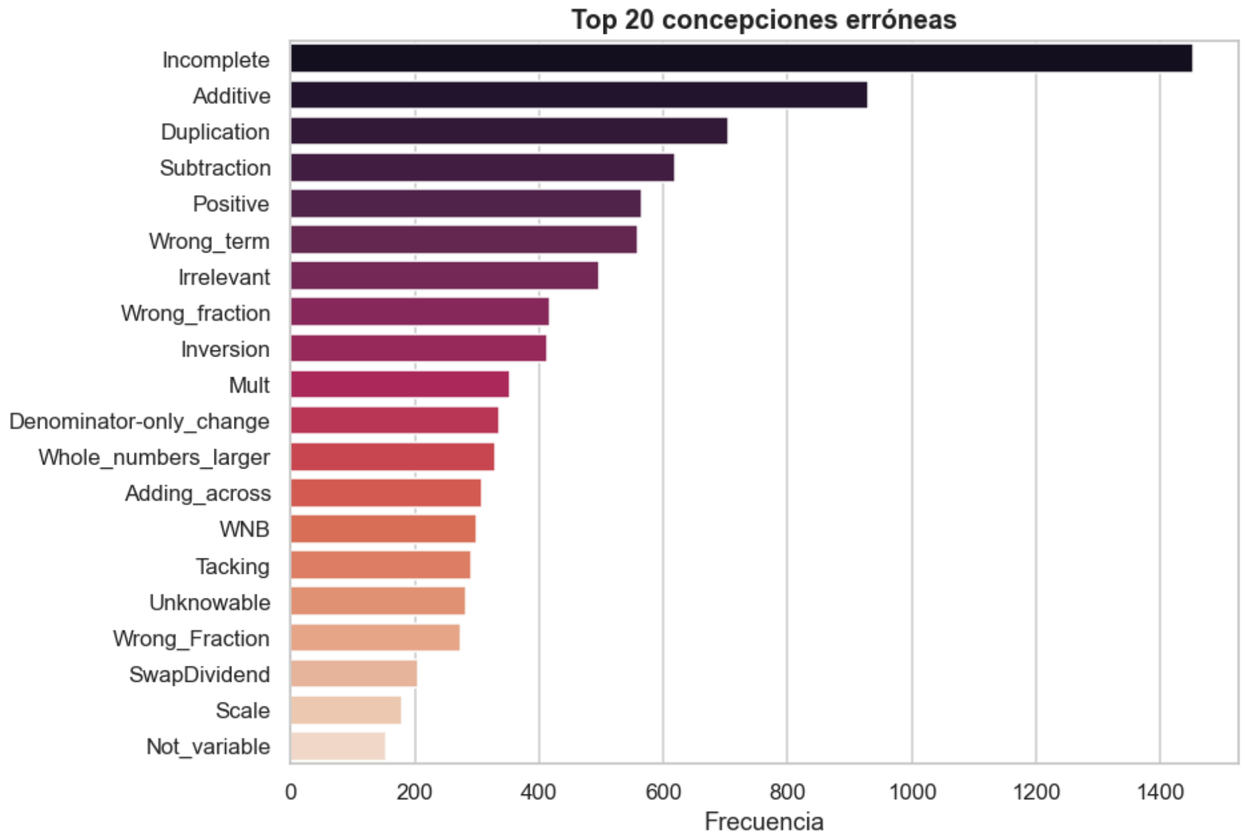
- Conservar “nulo” como una ausencia válida
- Normalizar espacios y unicode
- Agrupar duplicados en la validación
- Auditar textos extremos

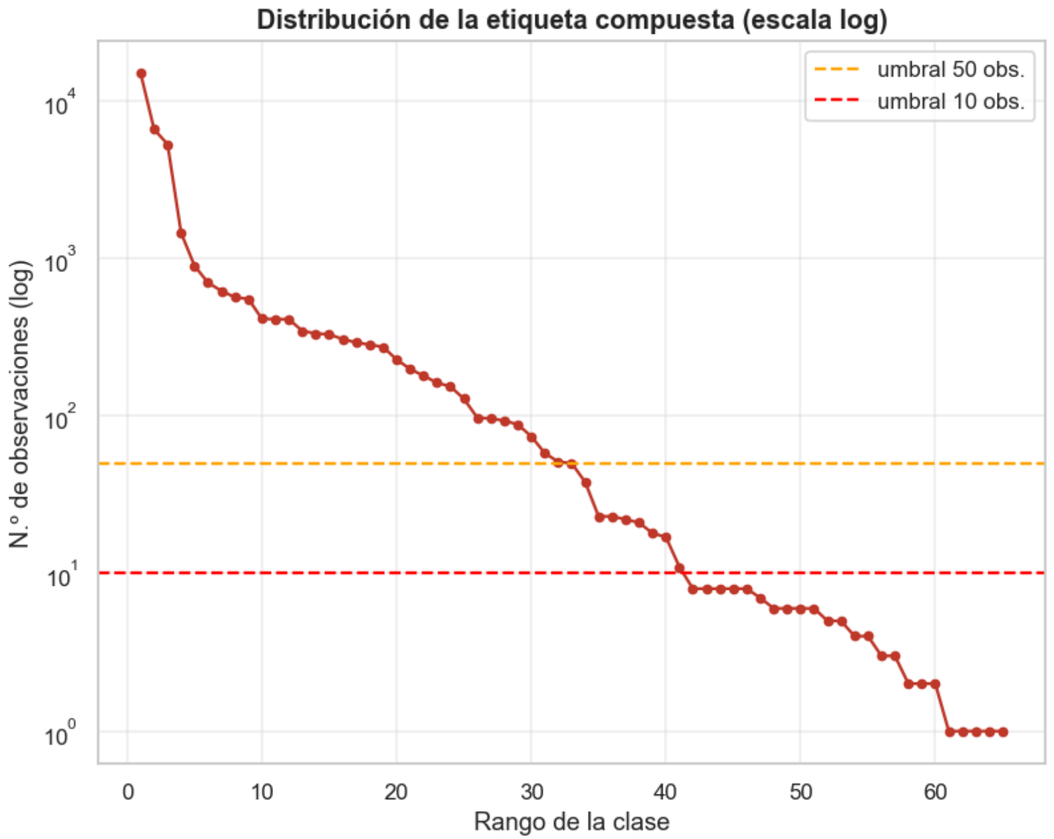
Qué no se elimina

Números, operadores, signos, negaciones ni estructura de la expresión: pueden cambiar completamente el razonamiento matemático.

Comprobación: el patrón de nulos coincide con categorías sin misconception; no se imputa una etiqueta inexistente.

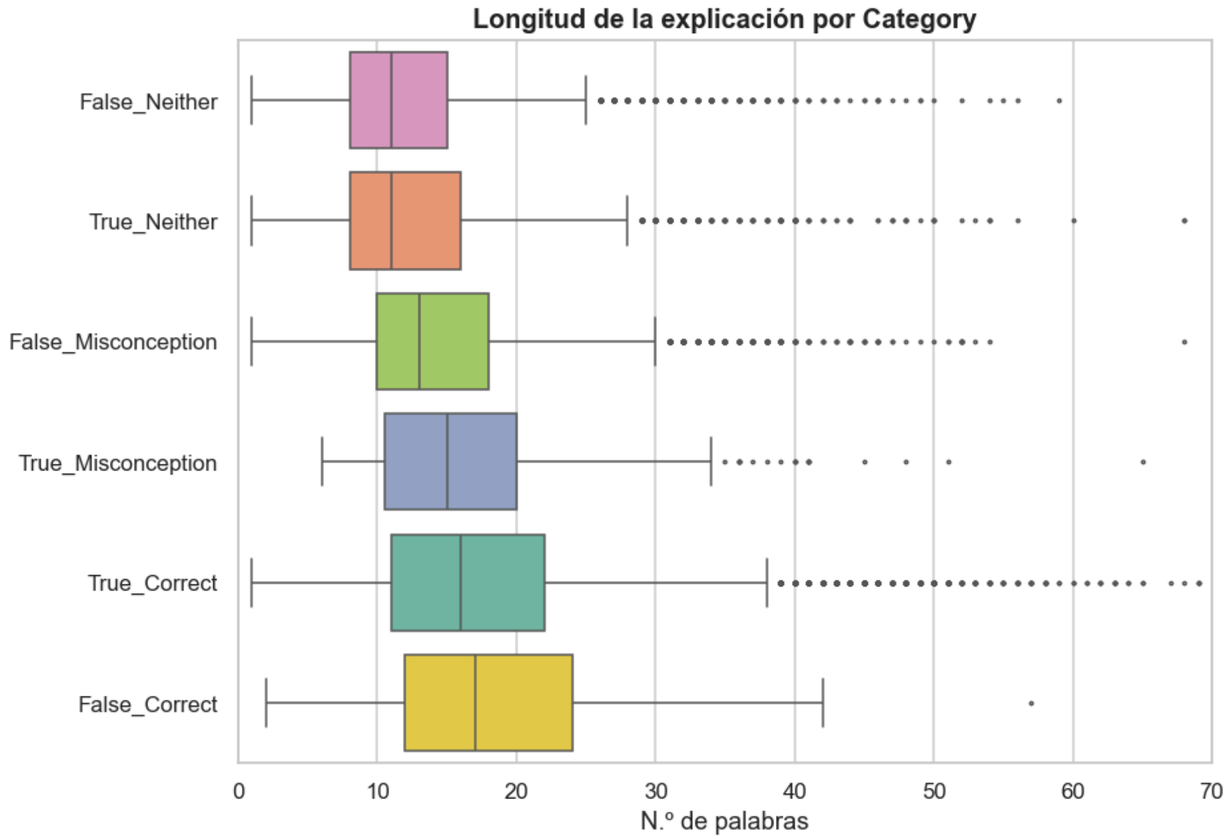
Una clase dominante y una cola larga

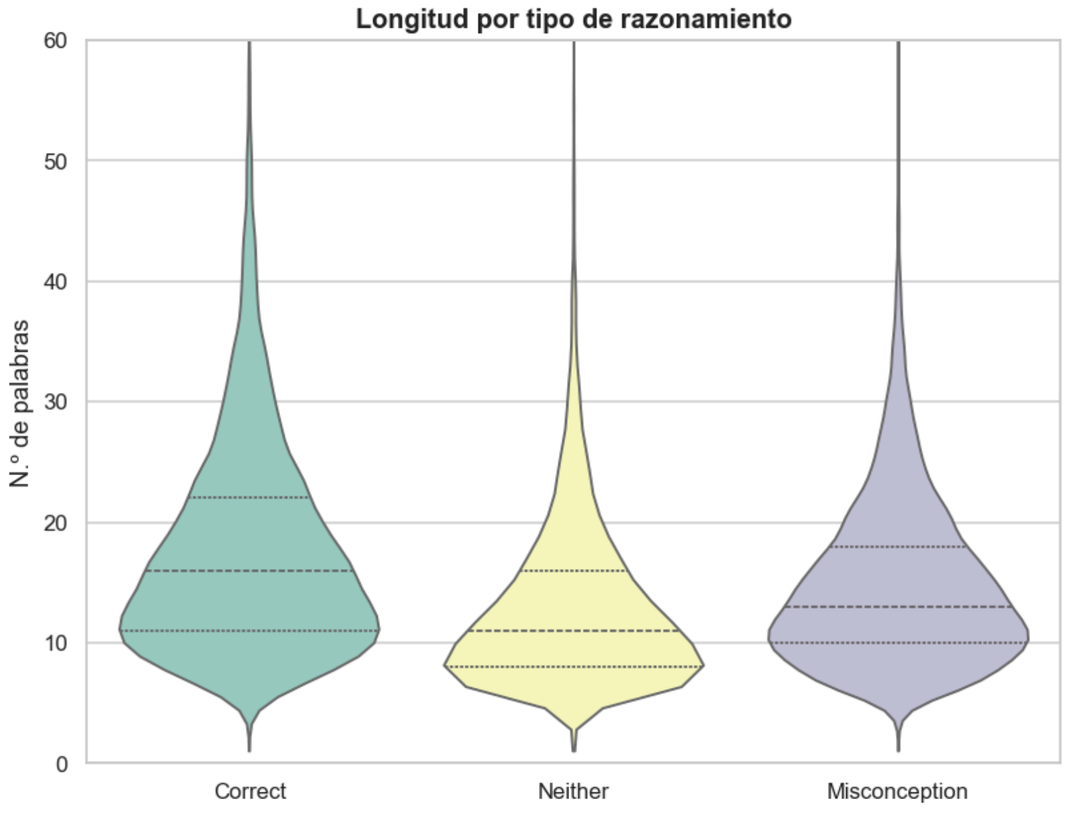




True_Correct concentra 40.34% · 32 de 65 pares tienen < 50 casos · 24 tienen < 10

La longitud no explica por sí sola la etiqueta

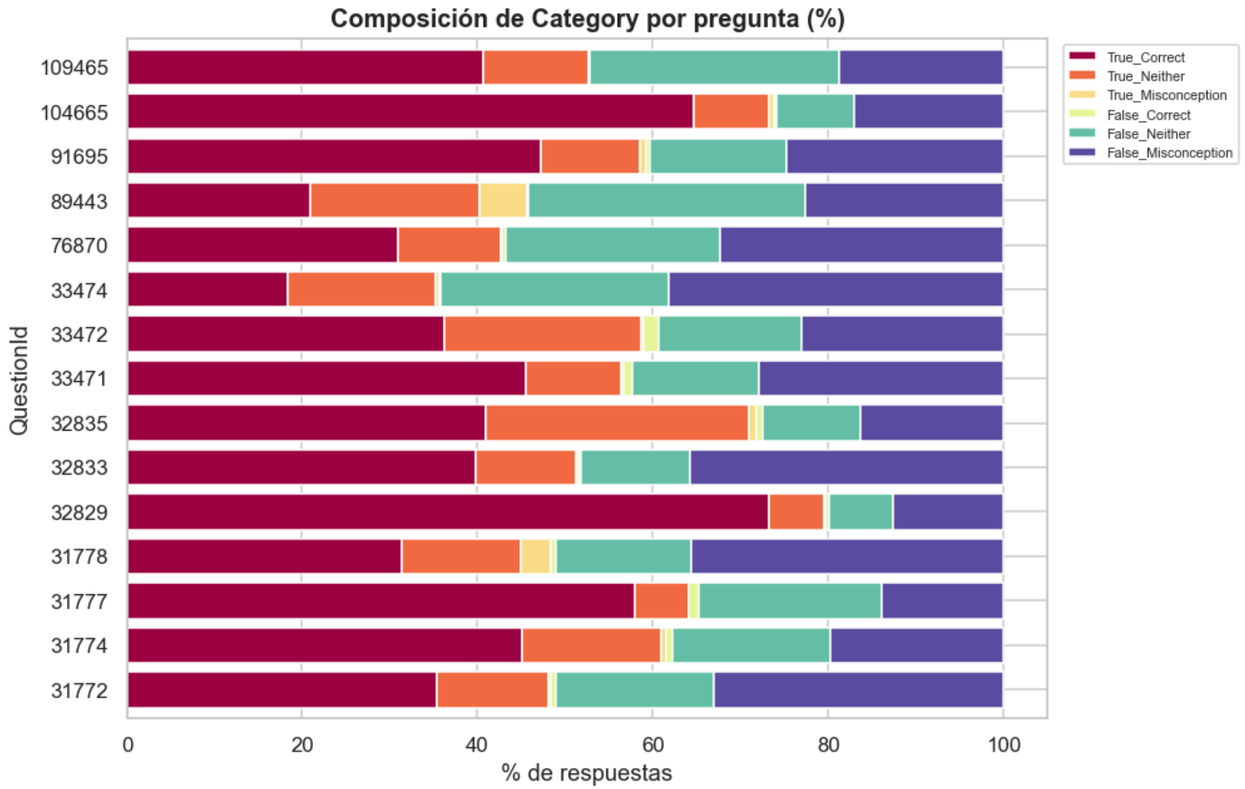


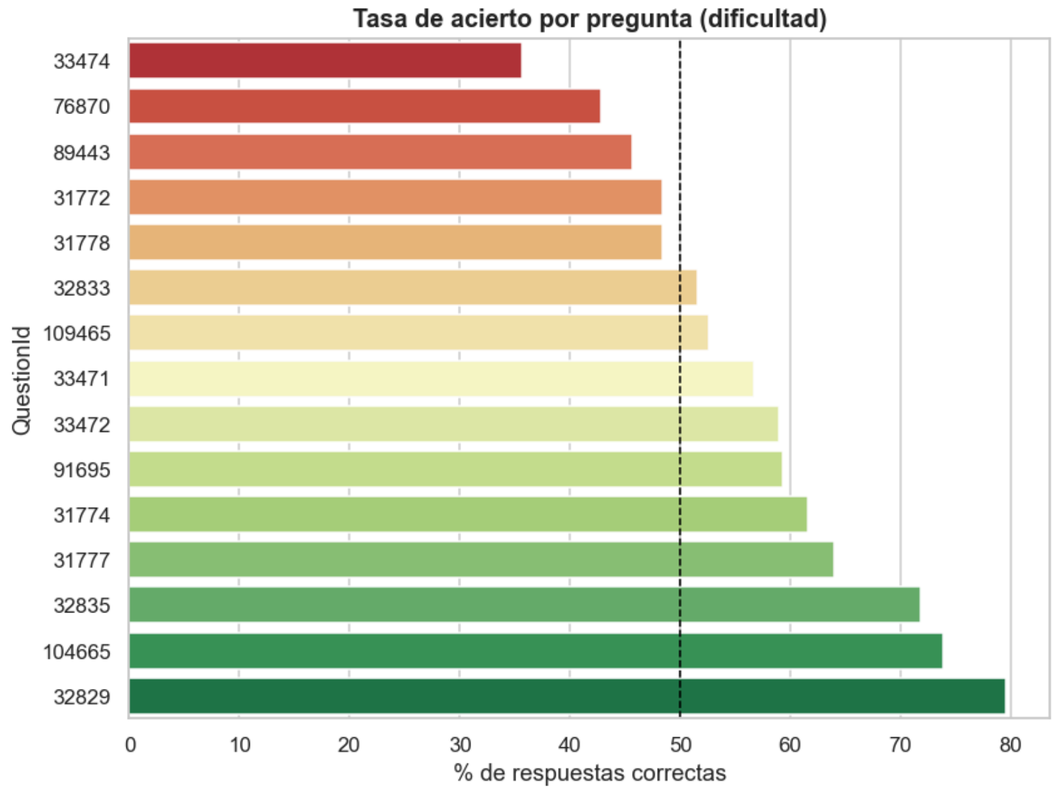


Mediana 13 · Media 15.36 · Máximo 177 · ρ(diversidad, palabras) ≈ −0.59

Los outliers no se eliminan automáticamente porque pueden contener razonamiento válido, se auditan

La pregunta estructura el espacio de errores





32/35 errores aparecen en una sola pregunta · True_Correct varía de 35.7% a 79.6%

Implicación: evitar QuestionId como atajo y comprobar generalización con GroupKFold.

EVOLUCIÓN DE ALGORITMOS

De similitud léxica a adaptación de dominio

1

Reglas y similitud

Soluciones interpretables aunque frágiles ante paráfrasis.

2

TF–IDF + SVM

Baseline competitivo y barato para texto corto.

3

BERT / DeBERTa

Contexto bidireccional y atención desacoplada.

4

MathBERT / DAPT

Vocabulario y patrones del dominio matemático.

Criterio de avance: adoptar complejidad solo si mejora MAP@3 y macro F1 bajo el mismo protocolo de validación.

Burrows et al. (2015); Devlin et al. (2019); He et al. (2021); Shen et al. (2021)

EVIDENCIA REVISADA

La literatura converge en cuatro decisiones

Contexto completo

Combinar pregunta y respuesta mejora la representación frente a usar solo la explicación.

Transferencia y aumento

La transferencia ayuda cuando las clases tienen pocos ejemplos y la distribución es desigual.

Adaptación de dominio

El preentrenamiento específico puede capturar vocabulario y estructuras educativas.

Confiabilidad

Calibración, robustez y supervisión humana son requisitos, no detalles posteriores.

Traducción al proyecto: entrada contextual + comparación controlada + resultados desagregados + revisión humana.

Zhang et al. (2020); Bonthu et al. (2023, 2024); Schneider et al. (2023); Filighera et al. (2024)

MODELOS CANDIDATOS

Selección preliminar en cuatro niveles

BASELINE	**TF–IDF palabra/carácter + LR/SVM**	Costo bajo · referencia interpretable
PRINCIPAL	**DeBERTa-v3-base o BERT/RoBERTa**	Pregunta + opción + explicación
DOMINIO	**MathBERT o preentrenamiento continuado**	Solo si mejora clases raras y preguntas nuevas
SALIDA	**Ensamble calibrado y ranking top-3**	Optimizar MAP@3 sin ocultar incertidumbre

Selección final por: generalización · clases raras · calibración · costo computacional · interpretabilidad

Sahu & Bhowmick (2020); Zhu et al. (2022); del Gobbo et al. (2023)

Un protocolo que separa desempeño y generalización

Validación A

StratifiedKFold por etiqueta compuesta, con duplicados agrupados.

"¿Funciona con nuevas respuestas a preguntas conocidas?"

Validación B

GroupKFold por QuestionId.

"¿Transfiere a preguntas no vistas sin memorizar el identificador?"

Métricas y ablaciones

MAP@3, macro F1, calibración y resultados por clase/pregunta.

- Comparar texto solo
- Texto + pregunta
- Texto + pregunta + opción

Secuencia: baseline → Transformer → adaptación de dominio → ensamble; mismas particiones y semillas comparables.

Confiabilidad antes de automatización

Sesgo y cola larga

Las clases frecuentes pueden dominar. Reportar macro F1, errores por clase y umbrales de abstención.

Atajos y robustez

Controlar fuga por pregunta, probar perturbaciones inocuas y revisar sensibilidad a números, signos y negaciones.

Uso responsable

Apoyo para priorizar revision no calificacion autonoma. Conservar semillas y versiones.

Si la incertidumbre es alta, el sistema se abstiene y deriva el caso al docente

Schneider et al. (2023); Filighera et al. (2024); Grévisse (2024)

Lo que ya sabemos y lo que sigue

- El problema es contextual, jerárquico y fuertemente desbalanceado.
- Los nulos de Misconception son estructurales y deben conservarse.
- 32 de 35 errores están ligados a una sola pregunta: la validación por grupos es obligatoria.
- TF–IDF/SVM será la línea base; DeBERTa/BERT, el modelo principal.
- No se reportan resultados de entrenamiento: la selección aún es preliminar.

Siguiente paso: entrenar → comparar Transformer → calibrar top-3 → auditar errores

Primer lugar vs. nuestro enfoque

MAP — Charting Student Math Misunderstandings · comparación técnica y experimental

Aspecto	Nuestro proyecto	Solución de primer lugar
Modelos	TF-IDF con modelos clásicos: **Naive Bayes, regresión logística y SVM**	LLM de 7B–32B parámetros: **Qwen3, GLM-Z1 y DeepSeek**
MAP@3	Mejor resultado: **0.882 · SVM lineal**	Mejor resultado aproximado: **0.950 · ensamble de LLM**
Validación	Partición estratificada 80/20 + prueba con preguntas no vistas	Validación de 5 folds + múltiples semillas y ensambles
Formulación	Clasificación directa entre **65 etiquetas compuestas**	Clasificación de sufijos y candidatos restringidos según QuestionId
Recursos	Económico, rápido, reproducible **e interpretable**	GPU de alta gama, cuantización, inferencia por capas y ensambles

Lectura: el primer lugar prioriza máximo desempeño; nuestro proyecto establece un baseline accesible y auditable.

Referencias y preguntas

Referencias APA 7 (selección)

- Bonthu, S., Sree, S. R., & Krishna Prasad, M. H. M. (2024). Framework for automation of short answer grading based on domain-specific pre-training. Engineering Applications of Artificial Intelligence, 137, 109163. https://doi.org/10.1016/j.engappai.2024.109163

- Burrows, S., Gurevych, I., & Stein, B. (2015). The eras and trends of automatic short answer grading. International Journal of Artificial Intelligence in Education, 25(1), 60–117. https://doi.org/10.1007/s40593-014-0026-8

- Otero, N., Druga, S., & Lan, A. (2025). A benchmark for math misconceptions: Bridging gaps in middle school algebra with AI-supported instruction. Discover Education, 4, 277. https://doi.org/10.1007/s44217-025-00742-w

- Zhu, X., Wu, H., & Zhang, L. (2022). Automatic short-answer grading via BERT-based deep neural networks. IEEE Transactions on Learning Technologies, 15(3), 364–375. https://doi.org/10.1109/TLT.2022.3175537

Repositorio

¿Preguntas?

Análisis y código disponibles en el repositorio del proyecto.

¡MUCHAS

GRACIAS

POR SU ATENCIÓN!