PROYECTO 2 · ANÁLISIS EXPLORATORIO DE DATOS

Charting Student Math Misunderstandings

Qué revelan 36 696 explicaciones escritas por estudiantes sobre la distancia entre marcar la opción correcta y razonar correctamente.

EQUIPO

Jorge Gabriel Palacios Sales
Pablo Daniel Barillas Moreno
Roberto Emiliano Otoniel Camposeco Torres
Abby Sofía Donis Agreda

CURSO

CC3084 · Data Science
Sección 10 · Grupo 1

INSTITUCIÓN

Universidad del Valle de Guatemala
Semestre II · 2026

CONTENIDO

Recorrido de la presentación

01 · MARCO

- Introducción y contexto
- Base conceptual del *benchmark*
- Problema a resolver
- Objetivos del análisis

02 · LOS DATOS

- Conjunto: filas y columnas
- Descripción de las variables
- Limpieza y preprocesamiento

03 · HALLAZGOS

- Análisis univariado
- Análisis bivariado
- Análisis multivariado
- Conclusiones y siguientes pasos

Alcance de esta entrega: caracterización exploratoria del conjunto y decisiones de diseño derivadas de ella. El entrenamiento del modelo predictivo corresponde a la fase siguiente.

Marcar la respuesta correcta no prueba que el razonamiento lo sea

Cuando un estudiante resuelve un ejercicio de opción múltiple, la opción elegida es apenas la superficie. La explicación que escribe es donde aparece **cómo** llegó ahí: qué regla aplicó, qué concepto confundió, o si simplemente adivinó.

36 696

explicaciones escritas por estudiantes de matemática

1.1%

acertó la opción *y aun así* razonó desde una concepción errónea

35

concepciones erróneas distintas catalogadas por especialistas

Por qué importa: un sistema que solo cuenta aciertos deja invisible al estudiante que llega al resultado correcto por el camino equivocado — y al que razona bien pero se equivoca al final.

Un benchmark educativo anotado por especialistas, no un volcado de datos

52 463
explicaciones en el benchmark completo

15
preguntas de matemática con imagen y enunciado

27%
respuestas sintéticas añadidas al corpus original

.70–.90
κ de Cohen entre evaluadores humanos

PROCEDENCIA

Respuestas reales de la plataforma **Eedi**, complementadas con ejemplos sintéticos y revisadas con rúbricas construidas por investigadores en educación matemática.

LECTURA CRÍTICA

Parte del ruido ortográfico y el paso a minúsculas fue **inyectado artificialmente**. No todo el desorden textual debe interpretarse como conducta natural del estudiante.

Rittle-Johnson et al. (2025), *Detecting Math Misconceptions: An AI Benchmark Dataset*; The Learning Agency (2025).

Una predicción jerárquica evaluada con MAP@3

ENTRADA
Pregunta + opción elegida + explicación escrita

→

NIVEL 1
Category
veracidad × tipo de razonamiento

→

NIVEL 2
Misconception
solo cuando aplica

MÉTRICA DE EVALUACIÓN

MAP@3 — el modelo entrega hasta **tres hipótesis ordenadas** y recibe más crédito cuanto antes aparezca la etiqueta correcta.

1.ª · peso 1	2.ª · peso ½	3.ª · peso ⅓

LO QUE IMPLICA PARA EL DISEÑO

- Predecir primero **Category** y condicionar **Misconception** a ella respeta la jerarquía real de la tarea.
- Admitir tres candidatas favorece a modelos **calibrados**, no solo precisos.
- La validación debe separar **por pregunta** para medir generalización y no memorización del ítem.

King et al. (2025), Kaggle: *MAP — Charting Student Math Misunderstandings*.

PROBLEMA A RESOLVER

Diagnosticar el error a escala exige un tiempo docente que no existe

SEÑAL OBSERVABLE

La opción marcada y un texto libre con vocabulario informal, símbolos, fracciones y pasos abreviados.

VARIABLE LATENTE

La concepción matemática que generó la respuesta. **Puede estar presente incluso cuando el resultado es correcto.**

OPORTUNIDAD

El NLP puede **priorizar** hipótesis de diagnóstico para que el docente revise primero lo que más importa.

PREGUNTA CIENTÍFICA

¿Qué patrones lingüísticos y estructurales permiten distinguir la relación entre **corrección de la respuesta**, **calidad del razonamiento** y **concepción errónea subyacente**?

Límite explícito: el objetivo es apoyar la retroalimentación docente, nunca sustituir el juicio pedagógico ni etiquetar al estudiante.

OBJETIVOS

Qué debe responder este análisis exploratorio

OBJETIVO GENERAL

Caracterizar la **estructura, calidad, desbalance y señales lingüísticas** del conjunto MAP para fundamentar un pipeline de clasificación reproducible y pedagógicamente responsable.

ESPECÍFICO 1 · DESCRIBIR

Cuantificar observaciones, variables, tipos, valores faltantes, duplicados y calidad del texto libre.

ESPECÍFICO 2 · EXPLORAR

Analizar distribuciones y relaciones entre pregunta, opción, explicación, categoría y concepción errónea.

ESPECÍFICO 3 · DECIDIR

Traducir los hallazgos en criterios concretos de preprocesamiento, validación, métricas y modelos candidatos.

Criterio de éxito: cada decisión técnica de la siguiente fase debe poder rastrearse hasta una evidencia de este análisis, no hasta una convención heredada.

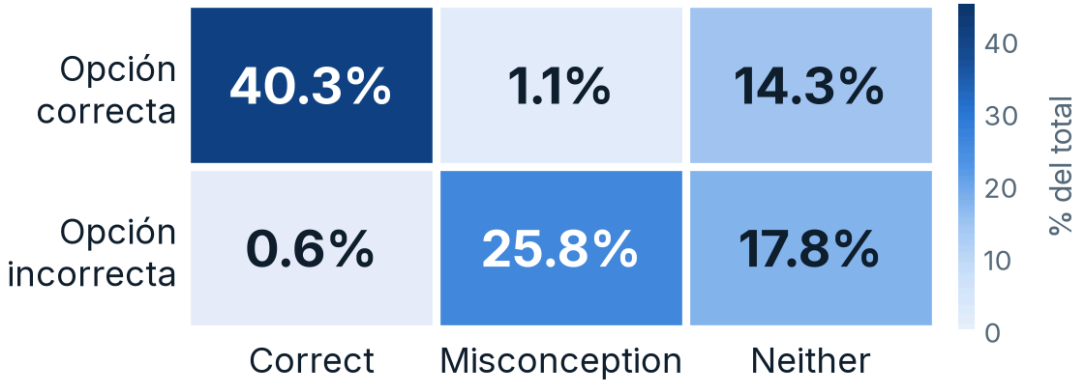
36 696 filas × 7 columnas en el archivo de entrenamiento

36 696
filas · una explicación por fila
7 columnas originales

15
preguntas únicas
49 opciones de respuesta distintas

6
valores de *Category*
veracidad × tipo de razonamiento

65
etiquetas compuestas observadas
35 concepciones erróneas distintas



UNIDAD DE ANÁLISIS

Una explicación vinculada a una pregunta y a la opción elegida. **No existe identificador de estudiante**, por lo que no puede haber fuga de información entre personas — pero sí entre preguntas.

INTEGRIDAD

Sin explicaciones vacías. **797 filas** repiten la combinación pregunta + opción + texto: respuestas cortas y frecuentes, no errores de carga.

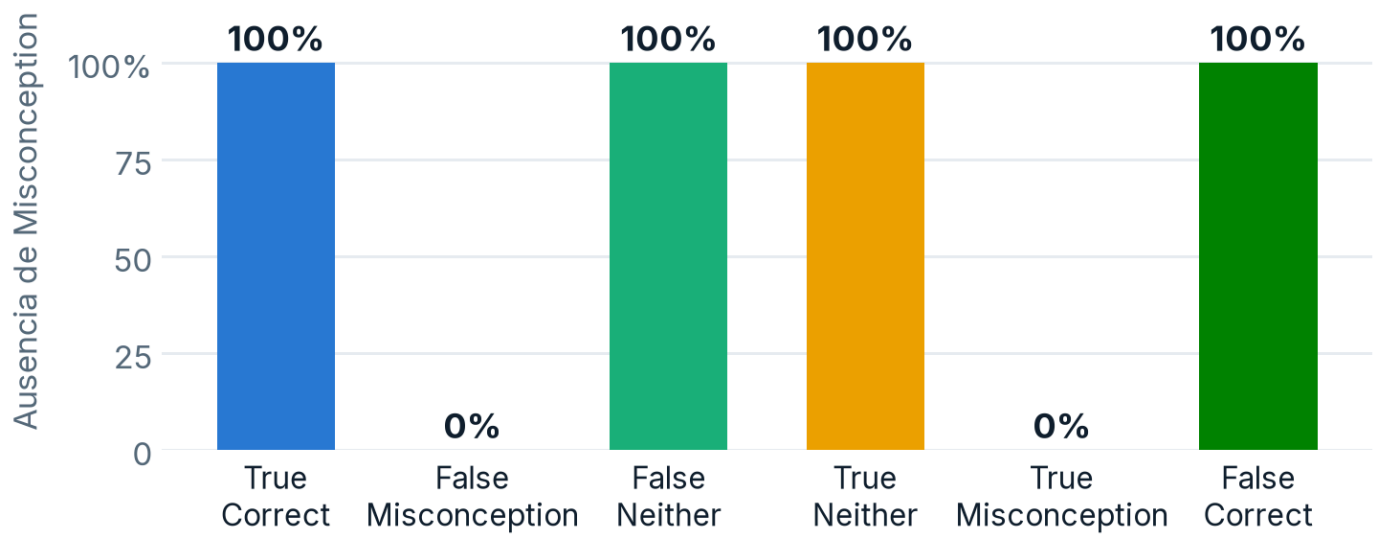
DESCRIPCIÓN DE LAS VARIABLES DISPONIBLES

Cinco predictoras, dos objetivos y un identificador

VARIABLE	TIPO	ROL	DESCRIPCIÓN Y FUNCIÓN EN EL ANÁLISIS
row_id	Entera	Índice	Identificador único de la observación. No aporta información predictiva y se excluye del modelado.
QuestionId	Entera · categórica	Predictora	Identifica el ítem. Aporta contexto y define los grupos de validación; **no** identifica al estudiante.
QuestionText	Texto	Predictora	Enunciado matemático, con descripción de la imagen cuando existe. Da sentido a la explicación.
MC_Answer	Texto · categórica	Predictora	Opción seleccionada, en notación LaTeX. Junto con QuestionId determina casi por completo la veracidad.
StudentExplanation	Texto libre	Predictora	**Predictor principal.** Justificación escrita por el estudiante; mediana de 13 palabras.
Category	Categórica · 6 niveles	Objetivo	Combina veracidad de la opción y tipo de razonamiento (*Correct / Misconception / Neither*).
Misconception	Categórica · anulable	Objetivo	Concepción errónea específica, con 35 valores. Ausente por diseño cuando la categoría no la admite.

Variables derivadas para el EDA: longitud en palabras y caracteres, longitud media de token, diversidad léxica, proporción de dígitos y número de símbolos matemáticos. Son instrumentos de diagnóstico, no rasgos definitivos del modelo.

La ausencia en Misconception es estructural, no un defecto



26 836

valores ausentes en *Misconception*

100 % de ellos en categorías *Correct* o *Neither*

REGLA QUE NO SE NEGOCIA

No imputar con la moda. La ausencia **codifica** que la etiqueta no aplica en ese nivel del esquema jerárquico.

CONSERVAR

Negaciones, operadores, fracciones, porcentajes, dígitos y verbos de operación (*times*, *divide*): son la señal, no el ruido.

NORMALIZAR CON CUIDADO

Espacios, variantes tipográficas y campos de etiqueta, sin tocar la semántica matemática del texto.

DOCUMENTAR

Las 797 duplicaciones se conservan y se marcan: eliminarlas alteraría la frecuencia real de las respuestas breves.

03

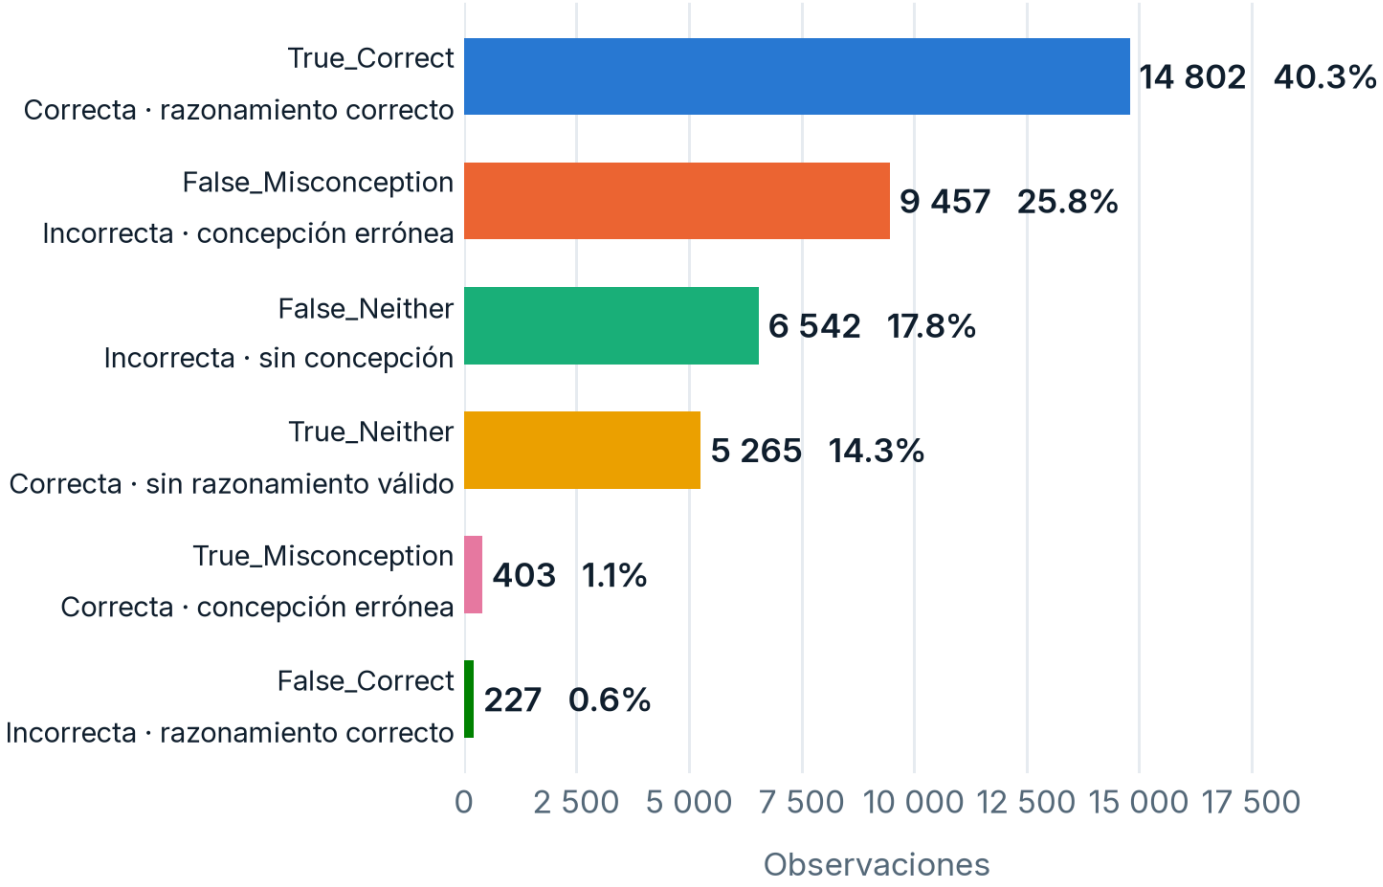
HALLAZGOS DEL ANÁLISIS EXPLORATORIO

Nueve lecturas que cambiaron nuestras decisiones de diseño

Del recuento de una variable a la interacción entre pregunta, opción y lenguaje: cada gráfico responde a una decisión pendiente del pipeline.

Univariado · 4 hallazgos | Bivariado · 3 hallazgos | Multivariado · 2 hallazgos

Seis categorías, pero dos concentran dos tercios de los casos



40.3%

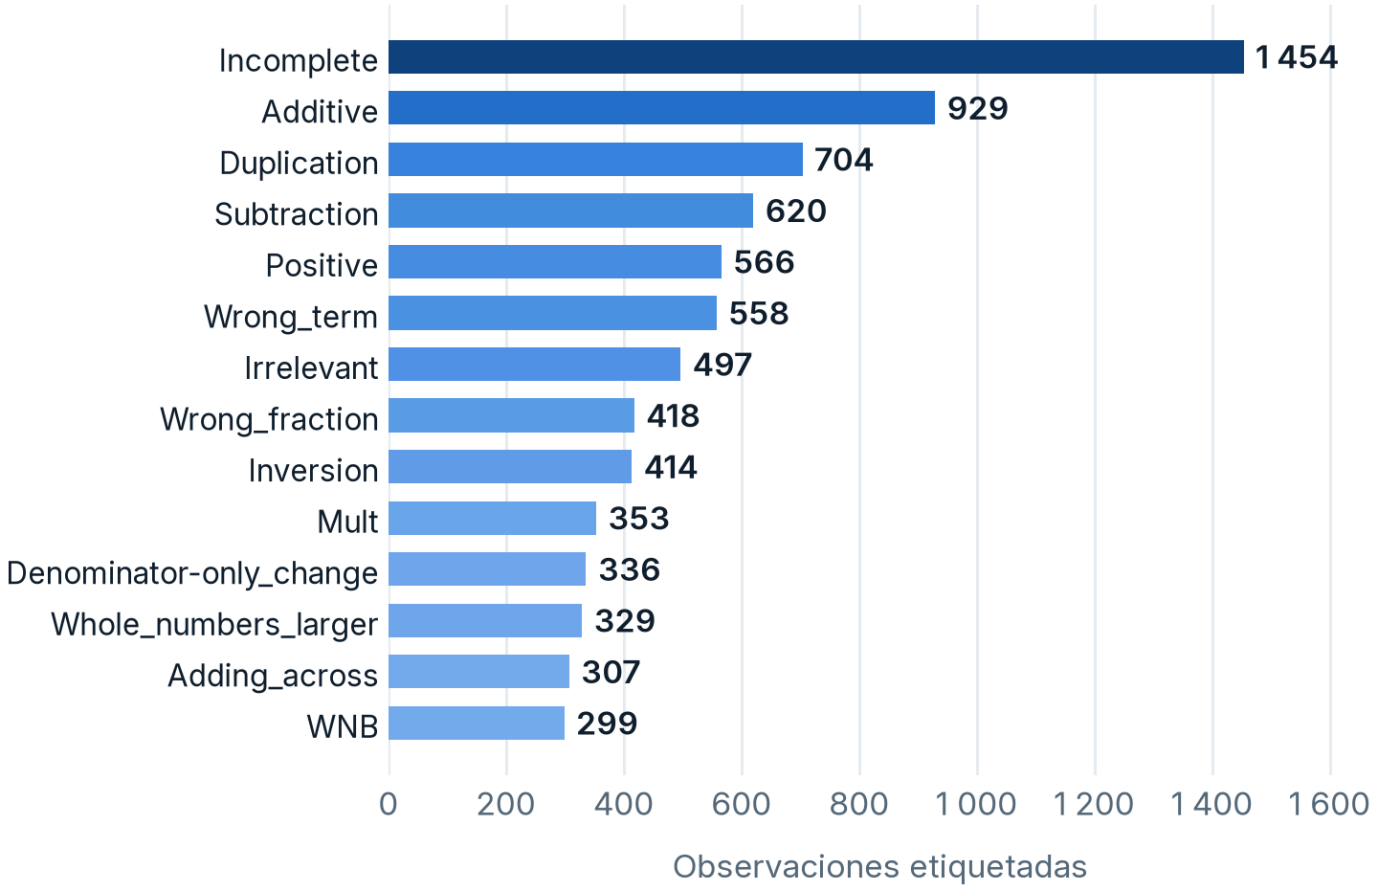
es **True_Correct**: opción correcta con razonamiento correcto

65 : 1

razón entre la categoría más frecuente y la más rara (*False_Correct*, 227 casos)

Decisión: reportar macro-F1 junto a la exactitud. Un clasificador que solo predijera la clase mayoritaria acertaría el 40 % sin diagnosticar nada.

14 de las 35 concepciones aparecen en menos de 100 casos



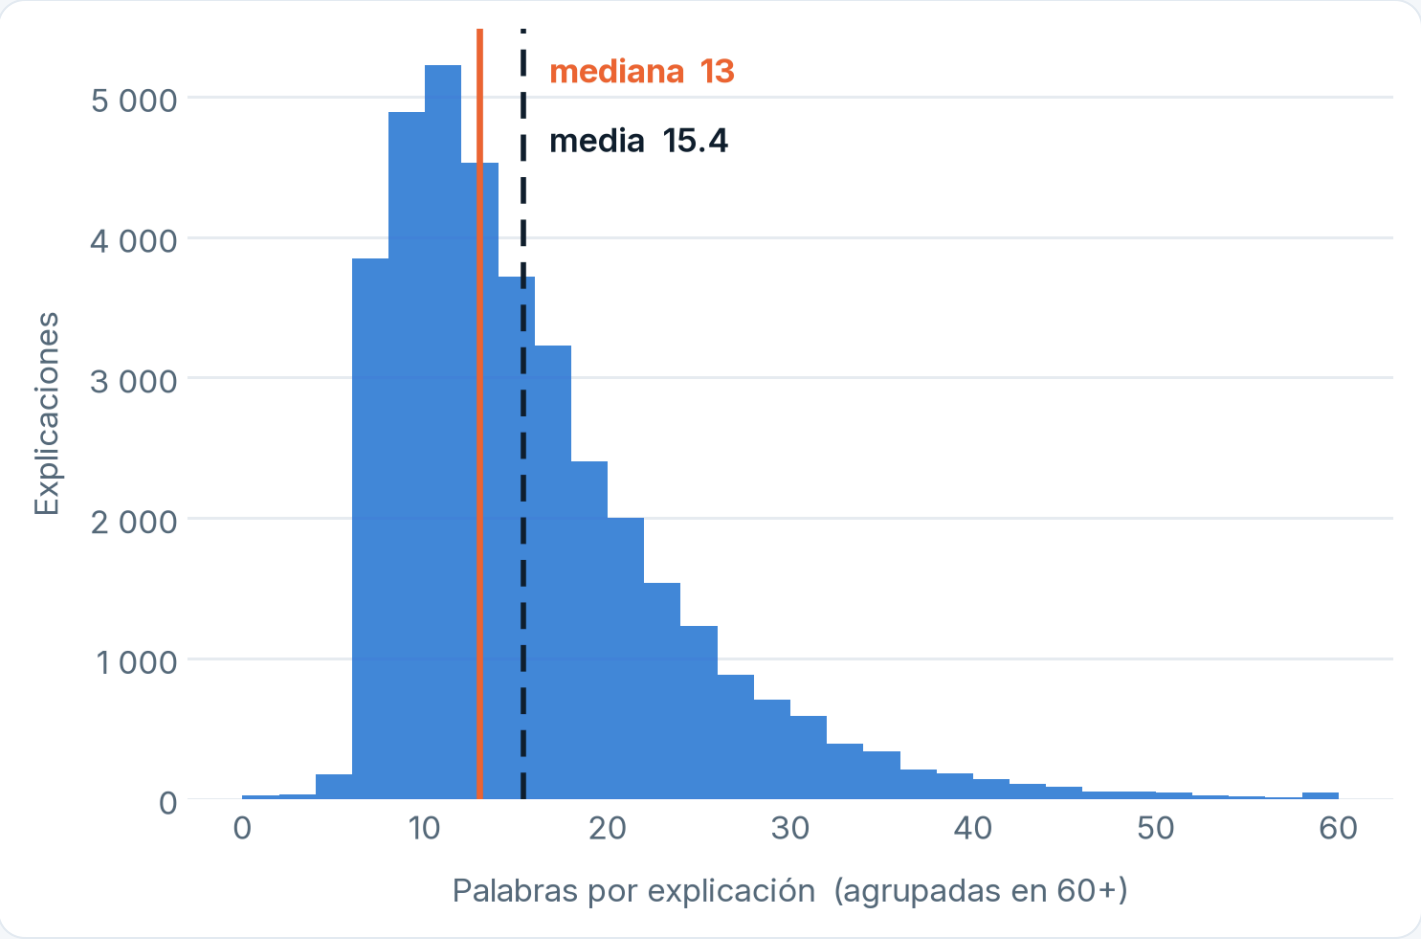
43.3%

de las etiquetas se concentra en solo **cinco** concepciones

CONSECUENCIA DIRECTA

- Ponderar clases o muestrear con cuidado en el entrenamiento.
- Analizar el error **por etiqueta**, no solo en agregado.
- Aceptar que las concepciones raras tendrán intervalos de confianza amplios.

Explicaciones breves y muy asimétricas: mediana de 13 palabras



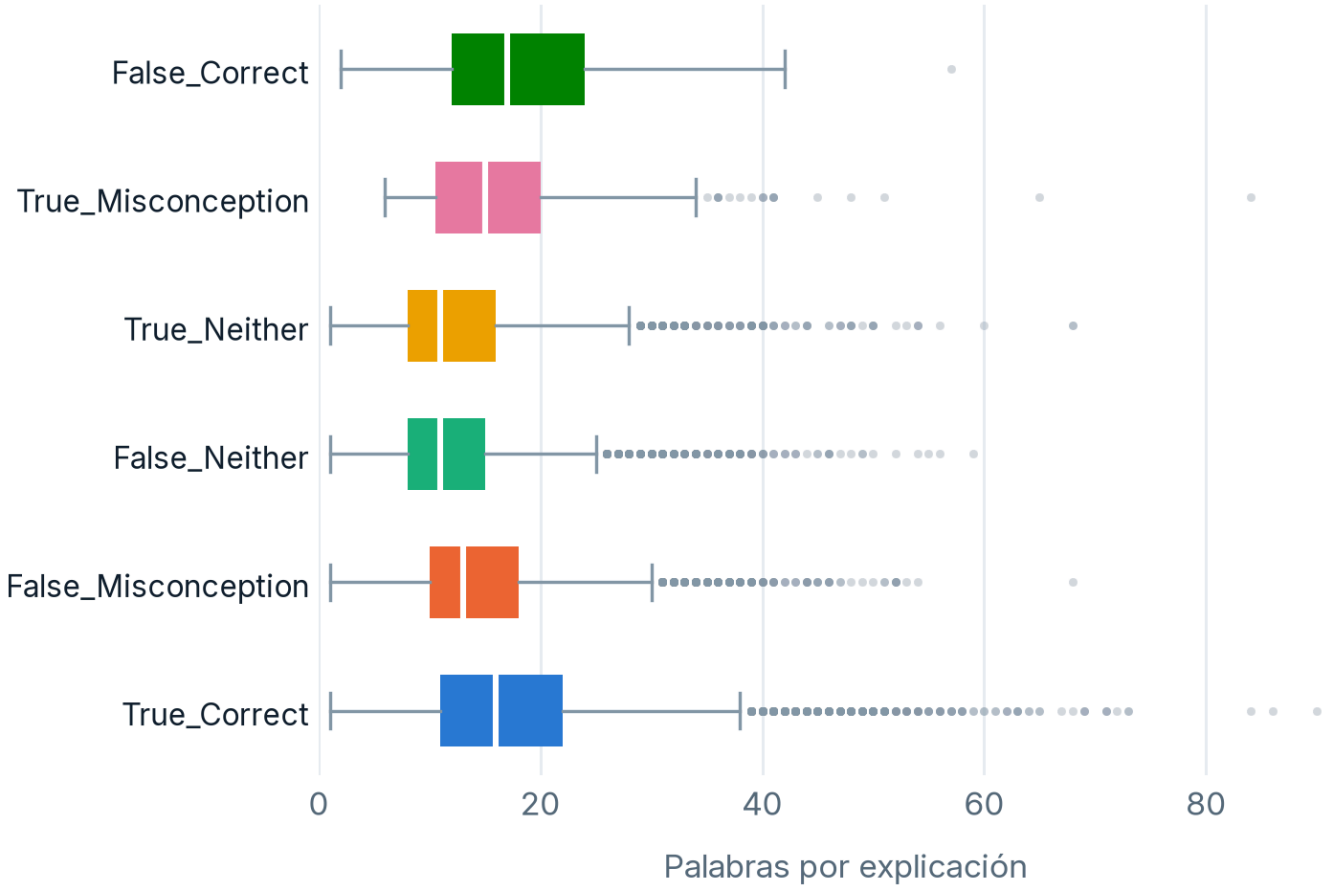
LO QUE DICE LA FORMA

- Media **15.4** por encima de la mediana **13**: cola derecha larga.
- El **95 %** cabe en 31 palabras; el máximo llega a 177.
- Ninguna explicación está vacía; solo 30 tienen una o dos palabras.

DECISIÓN DE PREPROCESAMIENTO

Un límite de **64 tokens** cubre prácticamente todo el corpus sin truncar los casos informativos. La longitud entra como rasgo auxiliar, nunca como sustituto del significado.

Los textos largos informan: no son valores atípicos



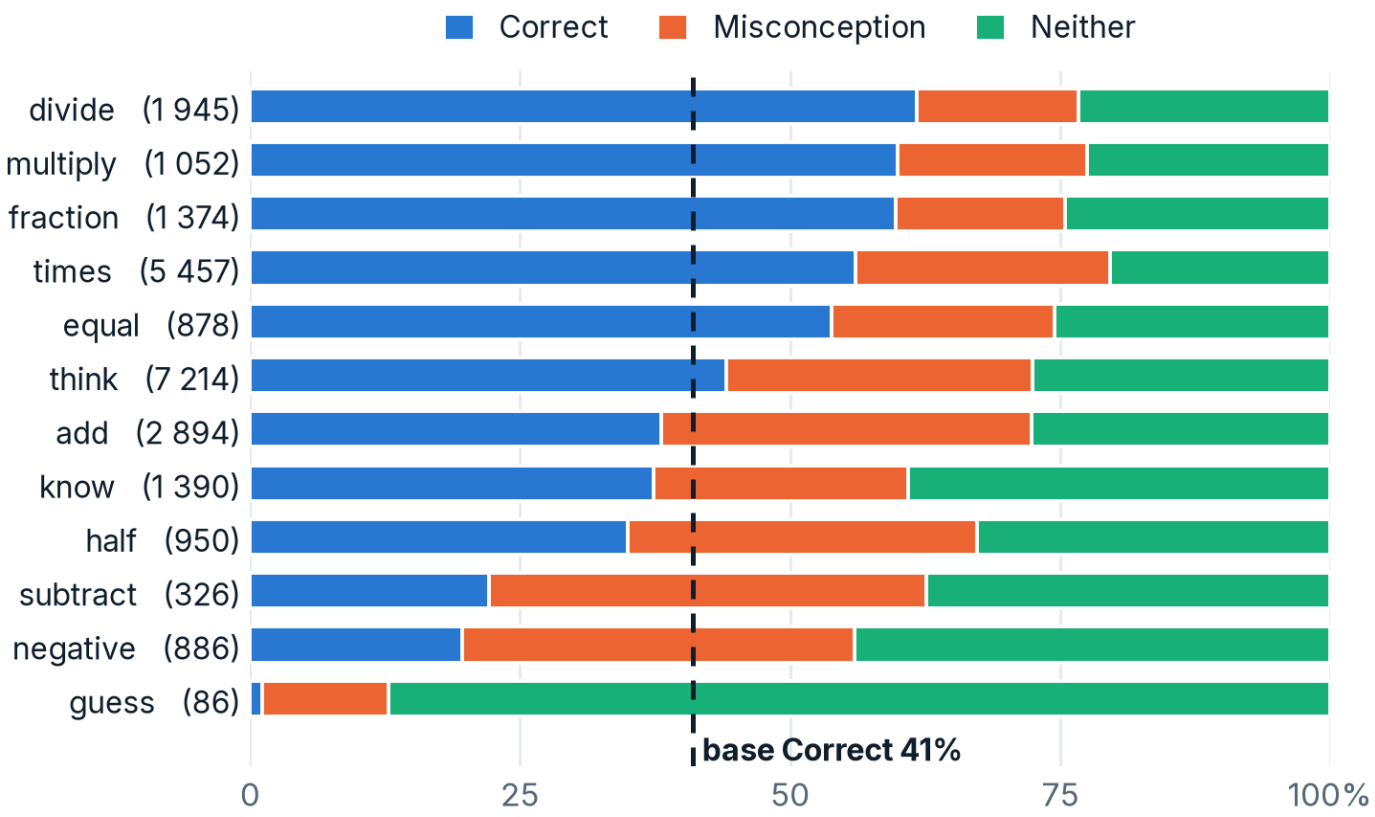
LECTURA

- Las medianas son **muy parecidas** entre categorías: la longitud sola no separa el razonamiento.
- Todas las categorías tienen valores extremos; no se concentran en una clase.

CONSECUENCIA

Descartar por longitud eliminaría explicaciones ricas de las clases minoritarias, que son justo las que menos ejemplos tienen. **Se revisan manualmente en lugar de recortarse.**

Palabras que anticipan el razonamiento — con un techo claro



Composición del razonamiento entre las explicaciones que usan la palabra

1.2%

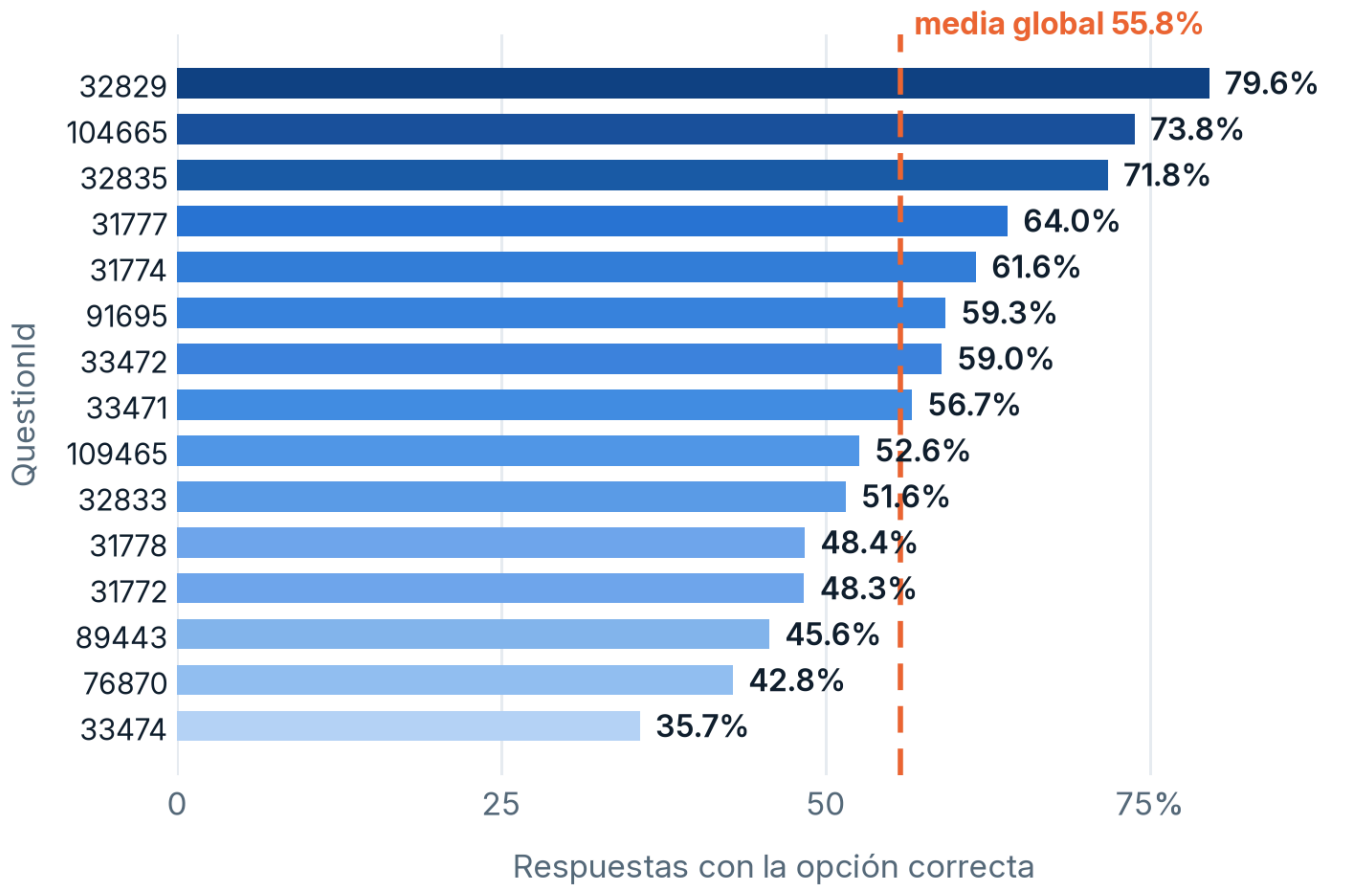
de quienes escriben **"guess"** razona correctamente, frente al 41 % de base

QUÉ HABILITA

Un baseline **TF-IDF con n-gramas** es interpretable y suficiente para capturar estos marcadores y las negaciones locales.

Y su límite: ninguna palabra determina la clase por sí sola. Todas las barras mezclan los tres tipos — el contexto de la pregunta sigue siendo indispensable.

La tasa de acierto va de 35.7 % a 79.6 % según la pregunta



44 pts

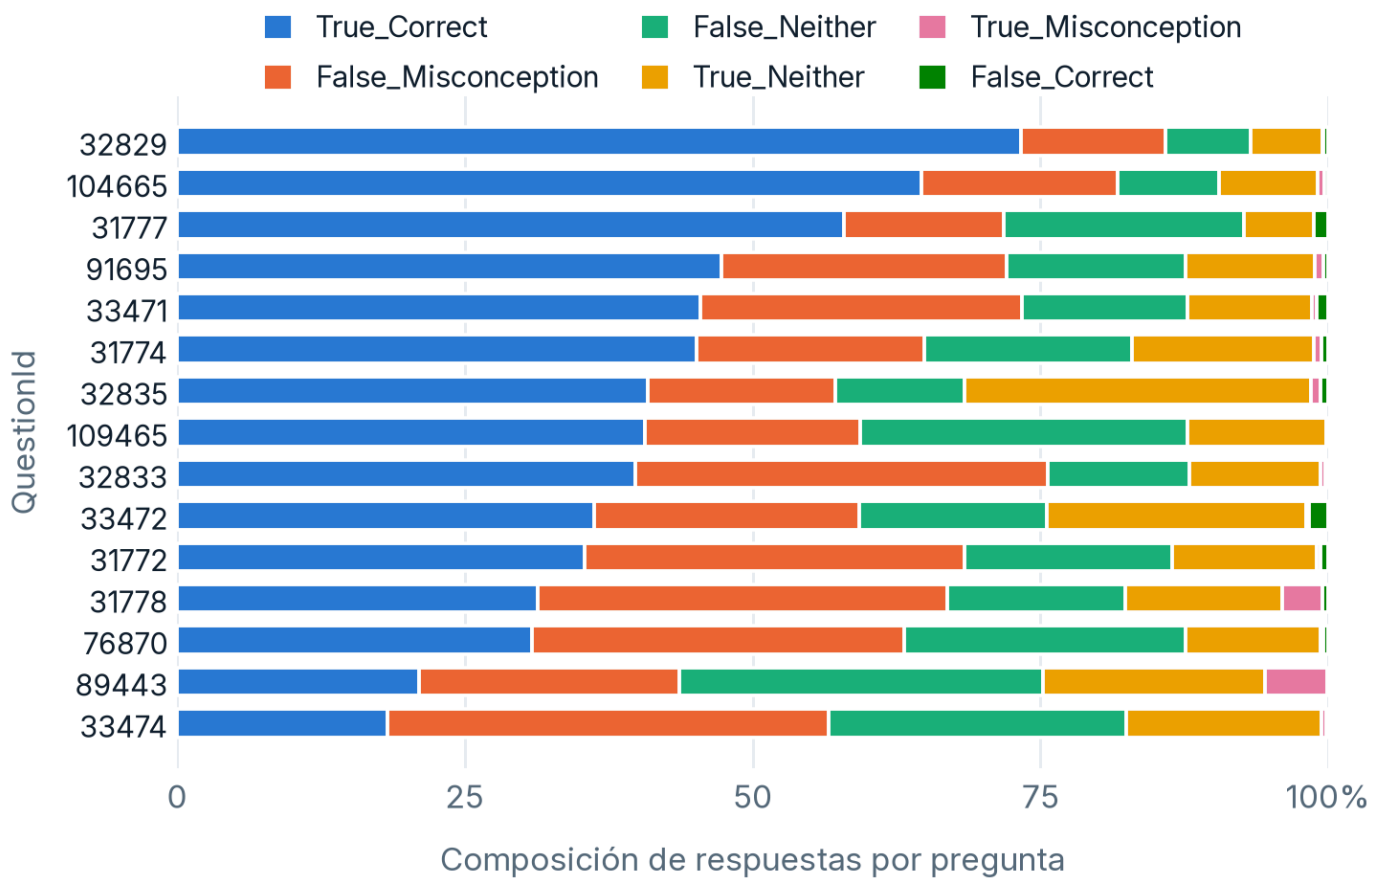
de diferencia entre la pregunta más fácil y la más difícil

RIESGO QUE INTRODUCE

La proporción de clases **depende de qué preguntas caigan en cada partición**. Una división aleatoria produce métricas optimistas y poco estables.

Decisión: estratificar por categoría y reportar también el desempeño desagregado por pregunta.

Cada pregunta tiene su propio perfil de error



EL HALLAZGO CENTRAL DEL ANÁLISIS

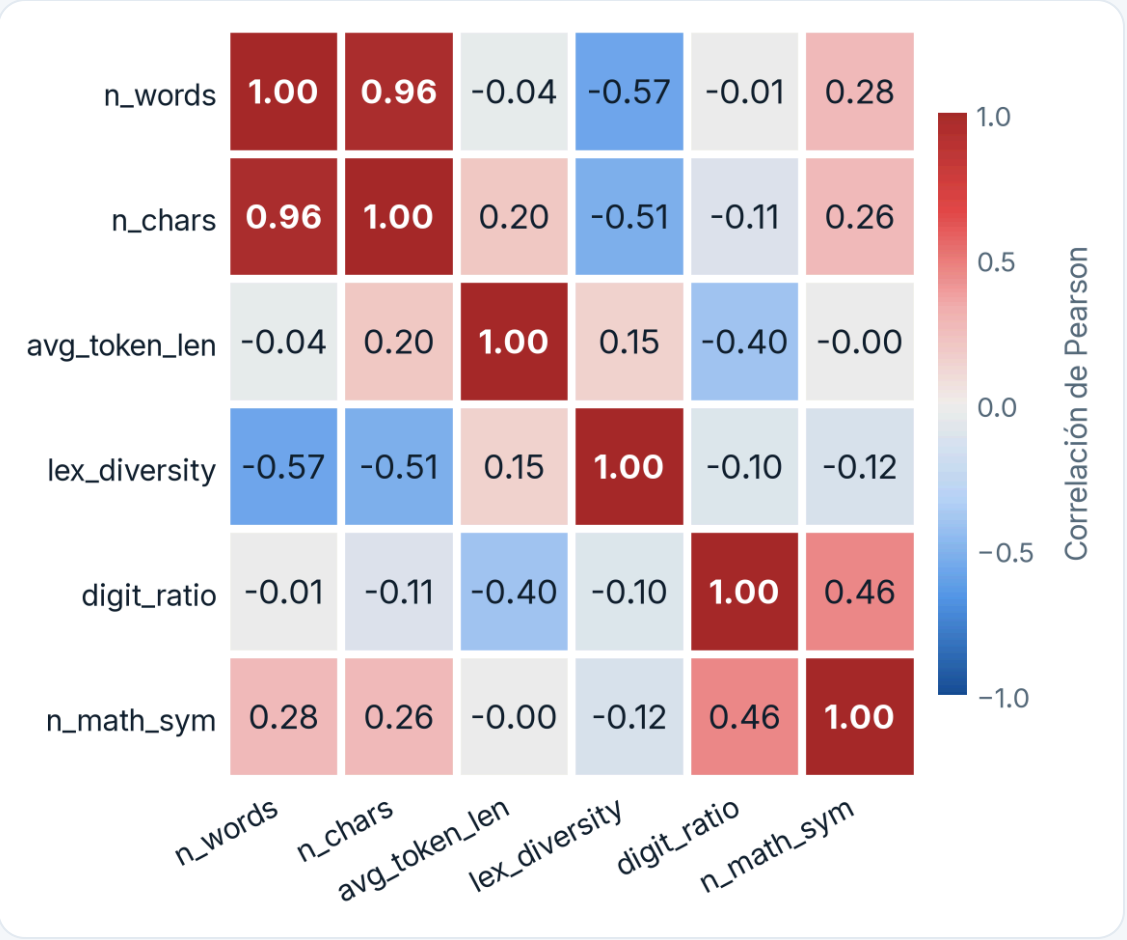
La distribución de categorías **cambia radicalmente** entre ítems. Además, **32 de las 35** concepciones aparecen en una sola pregunta.

LA TENSIÓN DE VALIDACIÓN

- **Aleatoria:** filtra patrones del ítem y sobreestima el desempeño.
- **GroupKFold por pregunta:** honesta, pero deja etiquetas sin ningún ejemplo de entrenamiento.

Resolución: reportar ambos escenarios como cota superior e inferior del desempeño real.

Las métricas superficiales del texto miden casi lo mismo



0.96

correlación entre *n_words* y *n_chars*: describen un único eje de longitud

LO QUE SÍ APORTA INFORMACIÓN DISTINTA

- **−0.57** entre longitud y diversidad léxica: los textos largos repiten vocabulario.
- **0.46** entre proporción de dígitos y símbolos matemáticos: un eje de *notación* independiente del de longitud.

Decisión: conservar un solo indicador de longitud y quedarse con notación y diversidad como ejes complementarios. Estas correlaciones no capturan equivalencia matemática ni causalidad.

CONCLUSIONES

Cinco conclusiones y lo que cada una decide

01 · JERARQUÍA

La ausencia de *Misconception* es informativa. **Category debe predecirse primero** y condicionar el segundo nivel.

02 · CONTEXTO

La pregunta no es un identificador neutral: define el perfil de error. **Validación dual**, aleatoria y agrupada.

03 · DESBALANCE

De 40.3 % a 0.6 % entre clases y 14 concepciones casi vacías. **Macro-F1 y MAP@3**, nunca exactitud sola.

04 · TEXTO

La señal vive en negaciones, notación y verbos de operación. **Normalizar sin destruir la semántica matemática.**

05 · PRUDENCIA

El 1.1 % que acierta con concepción errónea prueba que **la corrección no basta** como diagnóstico.

SIGUIENTE PASO

Baseline **TF-IDF + regresión logística** con validación dual, como referencia interpretable antes de pasar a modelos transformer.

La lectura de fondo: el problema no es “detectar palabras equivocadas”, sino modelar la relación entre contexto, elección y razonamiento. Un modelo que ignore la pregunta memoriza ítems; uno que ignore el texto pierde el diagnóstico.

REPRODUCIBILIDAD

Todo el análisis es ejecutable desde el repositorio

```
Proyecto-2_Grupo-1_DS_Sec-10/
├── data/raw/        dataset local (no versionado)
├── instructions/    enunciado del proyecto
├── notebooks/       01_analisis_exploratorio.ipynb
├── presentation/    figuras, deck y PDF
├── report/          informe LaTeX y assets
├── README.md
└── requirements.txt
```

ESTADO VERIFICADO

Notebook ejecutado de principio a fin sin errores · dependencias fijadas en *requirements.txt* · figuras regeneradas por script desde el dataset · datos crudos excluidos del control de versiones.

github.com/DanielBarillasM/
Proyecto-2_Grupo-1_DS_Sec-10

REFERENCIAS

Fuentes consultadas · APA 7.ª edición

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *NAACL-HLT 2019*, 4171–4186. https://doi.org/10.18653/v1/N19-1423

He, P., Liu, X., Gao, J., & Chen, W. (2021). DeBERTa: Decoding-enhanced BERT with disentangled attention. *ICLR 2021*.

King, J., Smith, K., Burleigh, L., Crossley, S., Demkin, M., & Reade, W. (2025). *MAP — Charting student math misunderstandings*. Kaggle.

Otero, V., Rodrigues, A., Saporta, J., Musco, C., & Musco, C. (2025). A benchmark for math misconceptions. *Discover Education, 4*, 277. https://doi.org/10.1007/s44217-025-00742-w

Rittle-Johnson, B., Adler, R., Durkin, K., Burleigh, L., King, J., & Crossley, S. (2025). Detecting math misconceptions: An AI benchmark dataset. *AIME-Con WIP*, 20–24.

Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management, 24*(5), 513–523.

Shen, J. T., Yamashita, M., Prihar, E., Heffernan, N., Wu, X., Graff, B., & Lee, D. (2021). *MathBERT: A pre-trained language model for general NLP tasks in mathematics education* [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2106.07340

The Learning Agency. (2025, 12 de noviembre). *Case study: Math misconceptions competition*.

La bibliografía completa, con enlaces activos y la revisión de algoritmos candidatos, se encuentra en el informe PDF del repositorio.

CIERRE

Comprender el error es el primer paso para enseñar mejor.

El análisis exploratorio convirtió 36 696 explicaciones abiertas en hipótesis verificables para un sistema de apoyo pedagógico responsable.

GRACIAS

¿Preguntas?

GRUPO 1 · SECCIÓN 10

CC3084 Data Science · UVG · 2026