ANÁLISIS EXPLORATORIO · PROYECTO 2

Charting Student Math Misunderstandings

Procesamiento del lenguaje natural para identificar patrones de razonamiento matemático

Integrantes

Jorge Gabriel Palacios Sales
Pablo Daniel Barillas Moreno
Roberto Emiliano Otoniel Camposeco Torres
Abby Sofia Donis Agreda

Curso y contexto

CC3084 · Data Science
Sección 10 · Universidad del Valle de Guatemala
Semestre II · 2026

Fuente de datos: competencia MAP de Kaggle

SITUACIÓN PROBLEMÁTICA

Una respuesta correcta no garantiza comprensión

El reto educativo

Dos estudiantes pueden seleccionar la misma opción y justificarla con razonamientos distintos. La corrección binaria pierde la señal pedagógica contenida en el lenguaje.

El reto analítico

Las explicaciones son breves, desbalanceadas, dependientes de la pregunta y combinan lenguaje natural con símbolos matemáticos.

La oportunidad

Clasificar categoría y concepción errónea permite priorizar retroalimentación y descubrir patrones sin sustituir el juicio docente.

Pregunta científica y unidad de análisis

¿Qué patrones textuales y contextuales distinguen las categorías de respuesta y las concepciones erróneas en las explicaciones estudiantiles?

Unidad

Una respuesta estudiantil a una pregunta de opción múltiple.

Contexto

QuestionText + MC_Answer + StudentExplanation.

Resultado

Category y, cuando aplica, Misconception.

Objetivos medibles del análisis

Objetivo general

Caracterizar la estructura, calidad, desbalance y señales lingüísticas del conjunto MAP para fundamentar un pipeline de clasificación reproducible.

01 · Describir

Cuantificar observaciones, variables, tipos, faltantes y duplicados.

02 · Explorar

Comparar distribuciones, relaciones por pregunta y marcadores léxicos.

03 · Decidir

Traducir los hallazgos en validación, preprocesamiento y modelos candidatos.

Perfil verificado de los datos

36,696	15	49	35	65
RESPUESTAS	PREGUNTAS	OPCIONES ÚNICAS	MISCONCEPTIONS	TARGETS COMPUESTOS

Esquema de entrenamiento

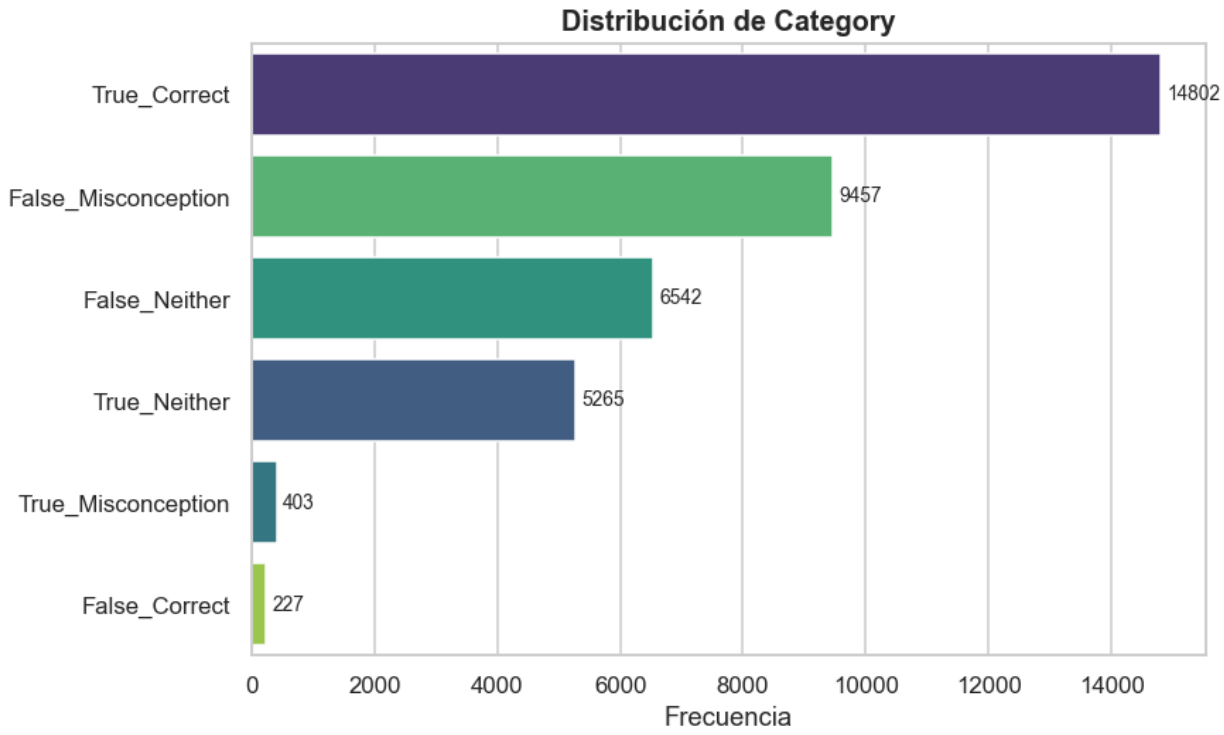
row_id · QuestionId · QuestionText · MC_Answer · StudentExplanation · Category · Misconception

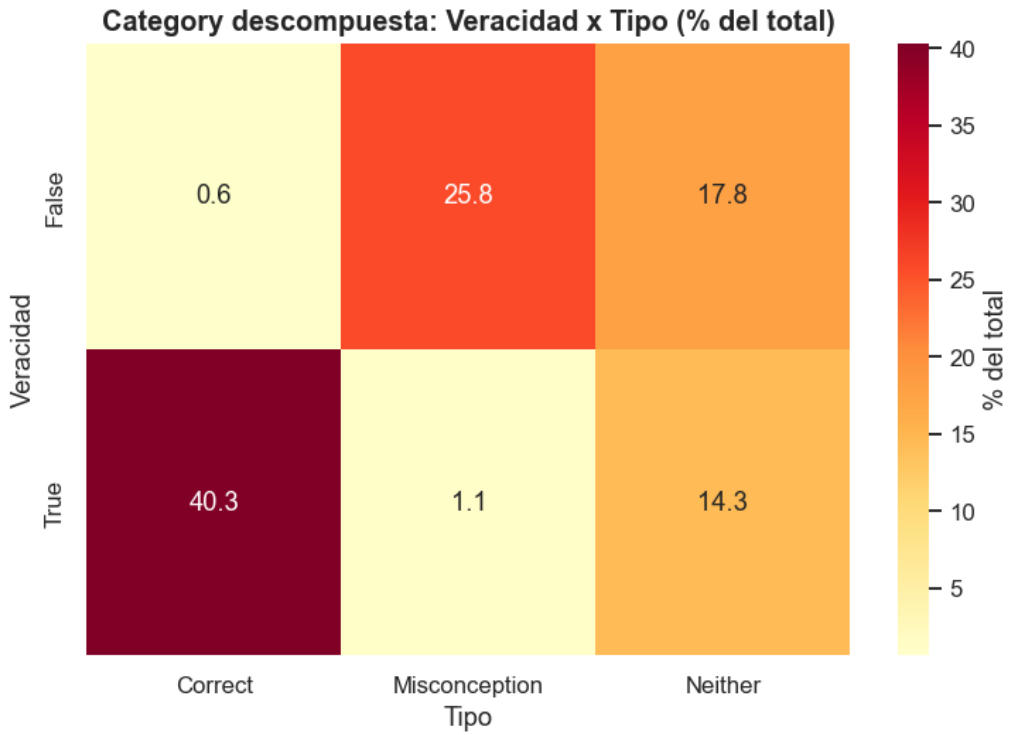
Integridad

0 duplicados de fila completa. Existen 736 duplicados al excluir row_id y 970 textos repetidos; se controlan por grupos durante la validación.

VARIABLE OBJETIVO

La categoría combina dos decisiones





Resultado

40.34% True_Correct.

Ruta

Tipo × Correctness.

Uso

Modelado jerárquico.

Los nulos son estructurales, no aleatorios

26,836

MISSING MISCONCEPTION

73.13%

DEL TOTAL

100%

COINCIDE CON NO-MISCONCEPTION

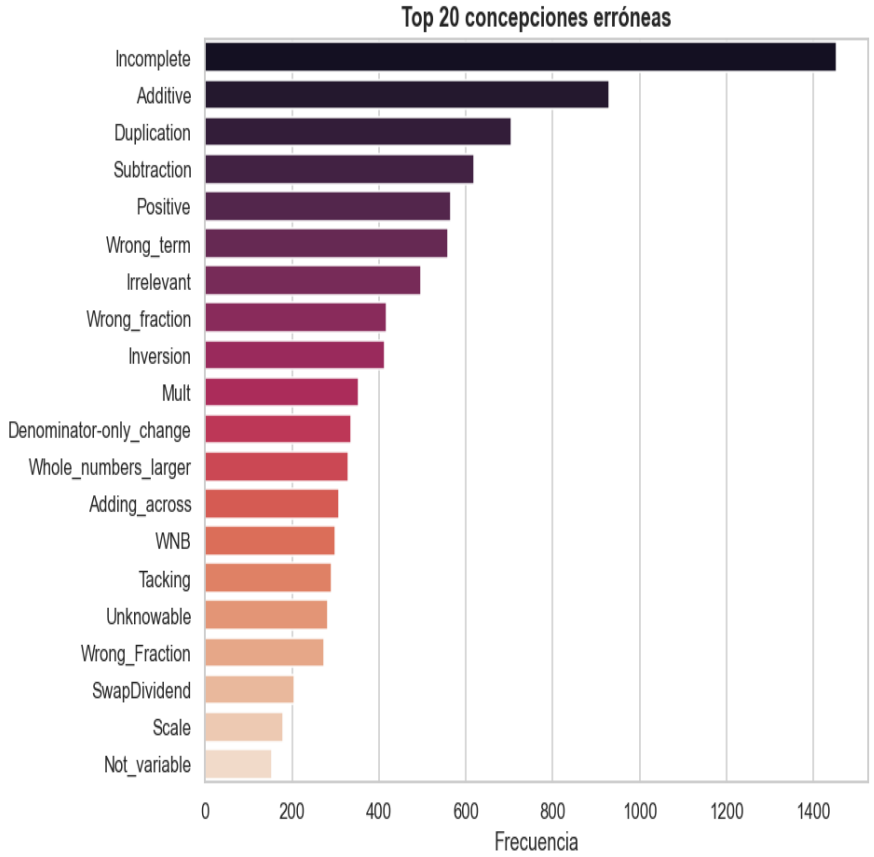
Decisión

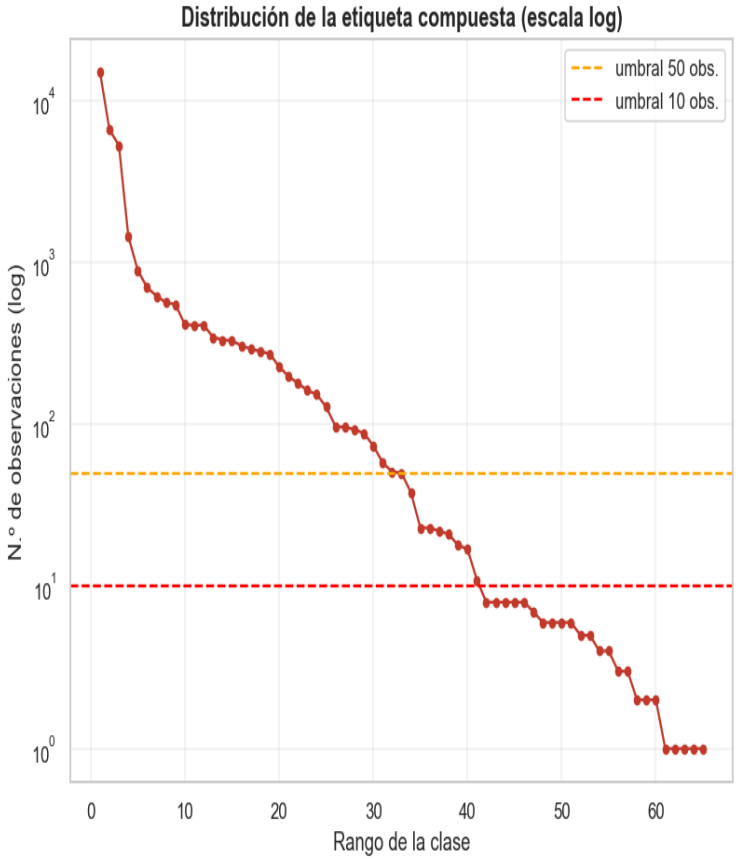
Conservar el nulo como estado semántico. No imputar una concepción errónea donde la categoría indica que no existe.

Preprocesamiento

Normalizar espacios y Unicode sin borrar números, operadores, signos o negaciones; esas marcas pueden cambiar el razonamiento.

La etiqueta compuesta presenta una cola larga





32 clases

tienen menos de 50 casos

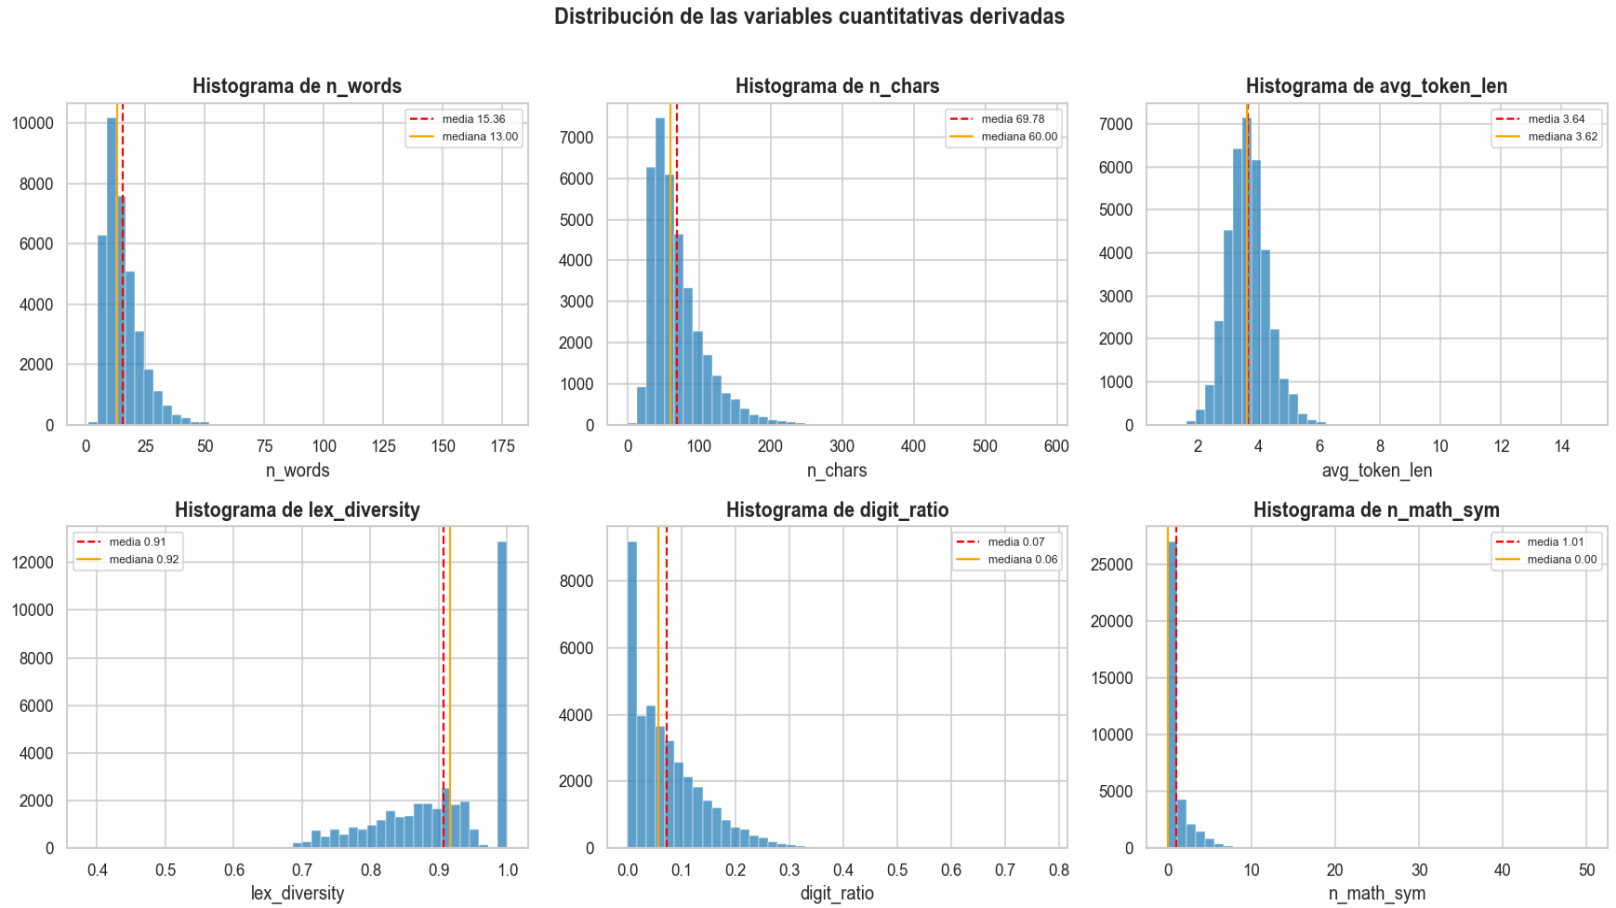
24 clases

tienen menos de 10 casos

Implicación

Usar macro F1, MAP@3, pesos y análisis por clase.

Explicaciones breves, pero heterogéneas



13

MEDIANA DE PALABRAS

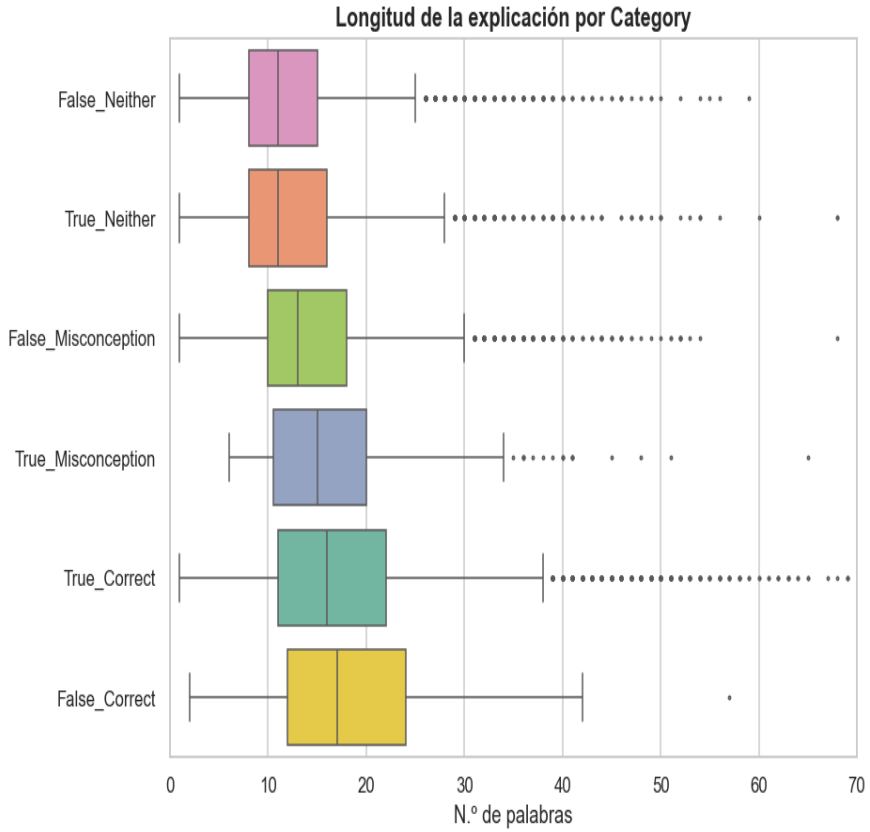
15.36

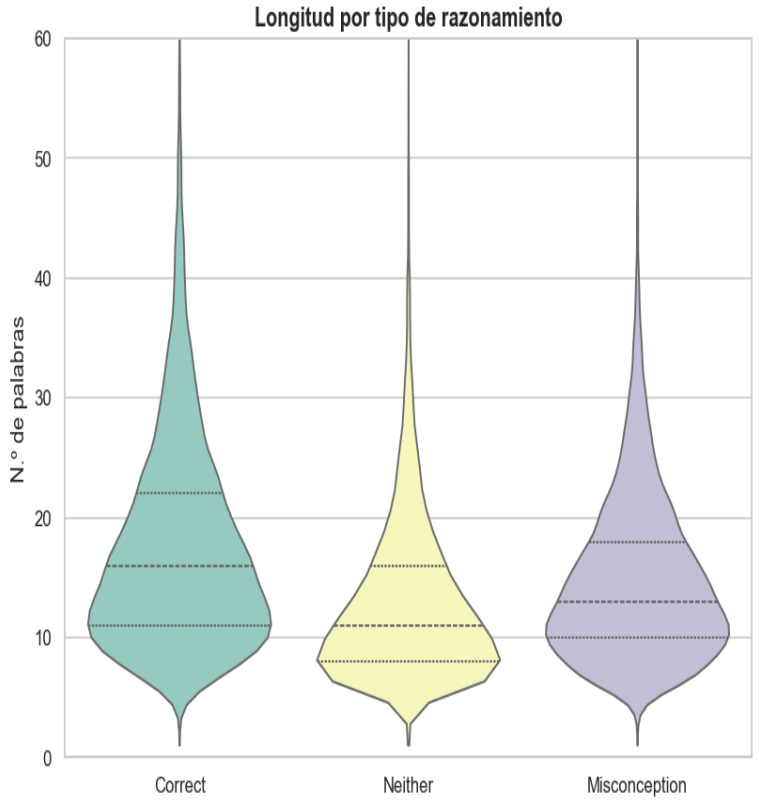
MEDIA DE PALABRAS

177

MÁXIMO

Los valores extremos contienen señal potencial





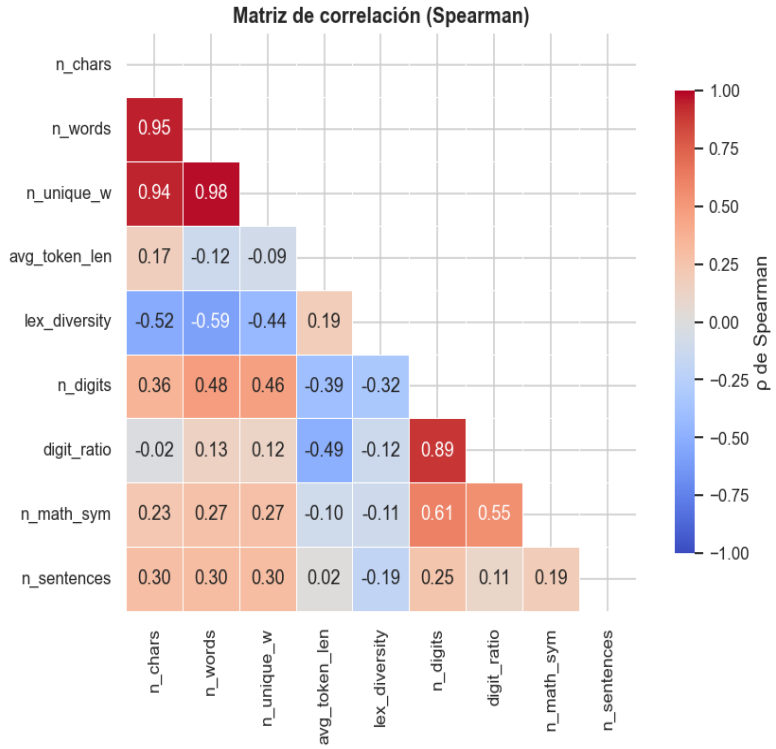
No eliminar automáticamente

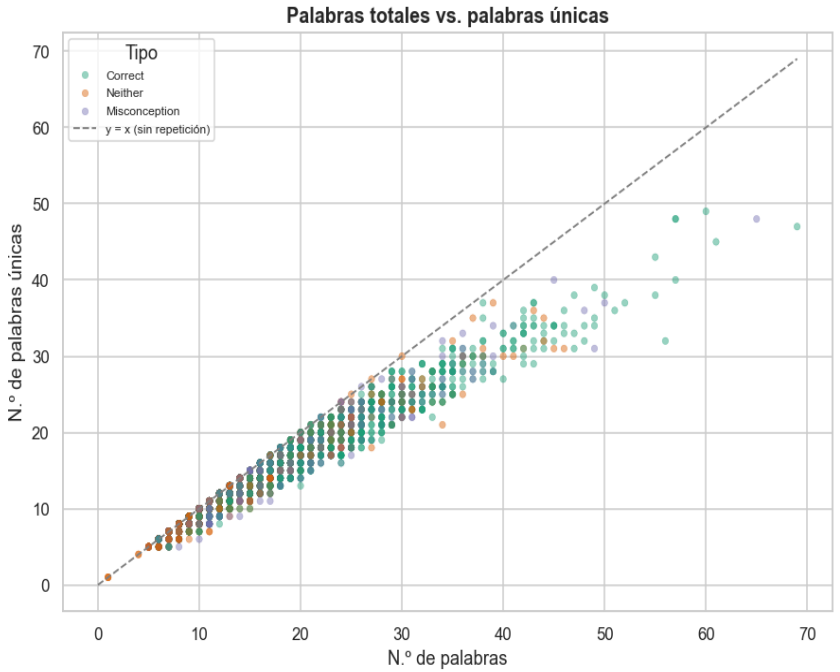
Una explicación extensa puede reflejar duda, justificación detallada o copia.

Sí auditar

Revisar casos extremos, truncamiento y robustez del tokenizador.

Longitud y diversidad no significan lo mismo





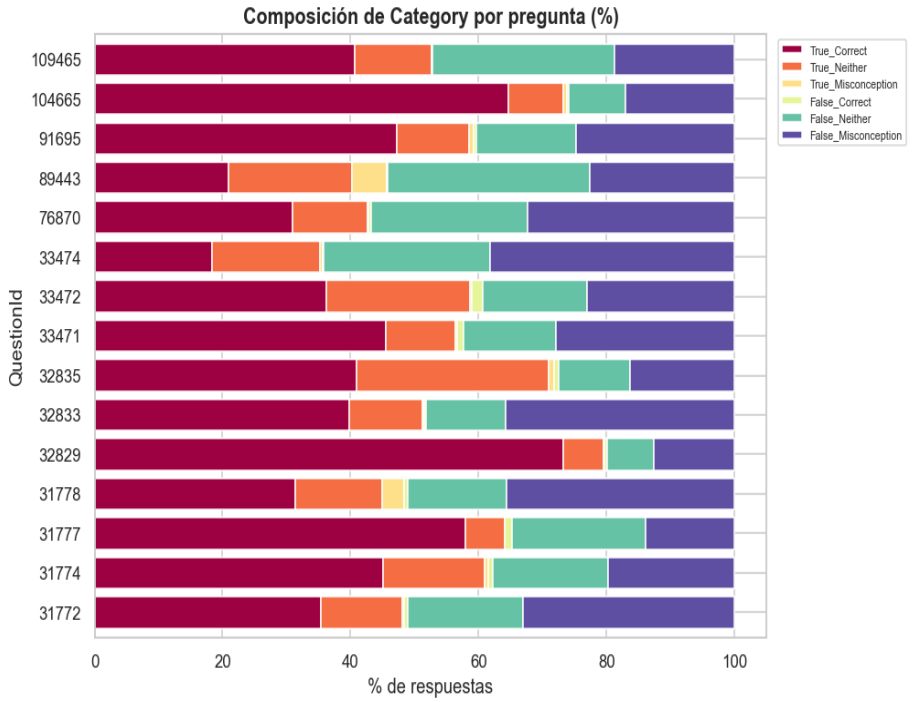
Relación clave

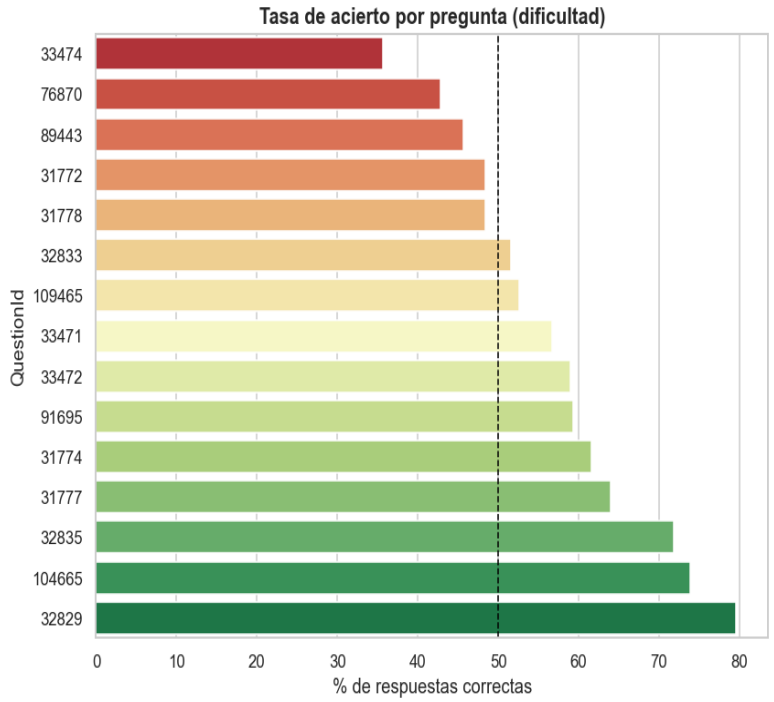
Diversidad léxica vs. palabras: ≈ −0.59.

Lectura

Las respuestas largas repiten más vocabulario; ninguna variable aislada explica la etiqueta.

El contexto de la pregunta cambia el problema





Rango

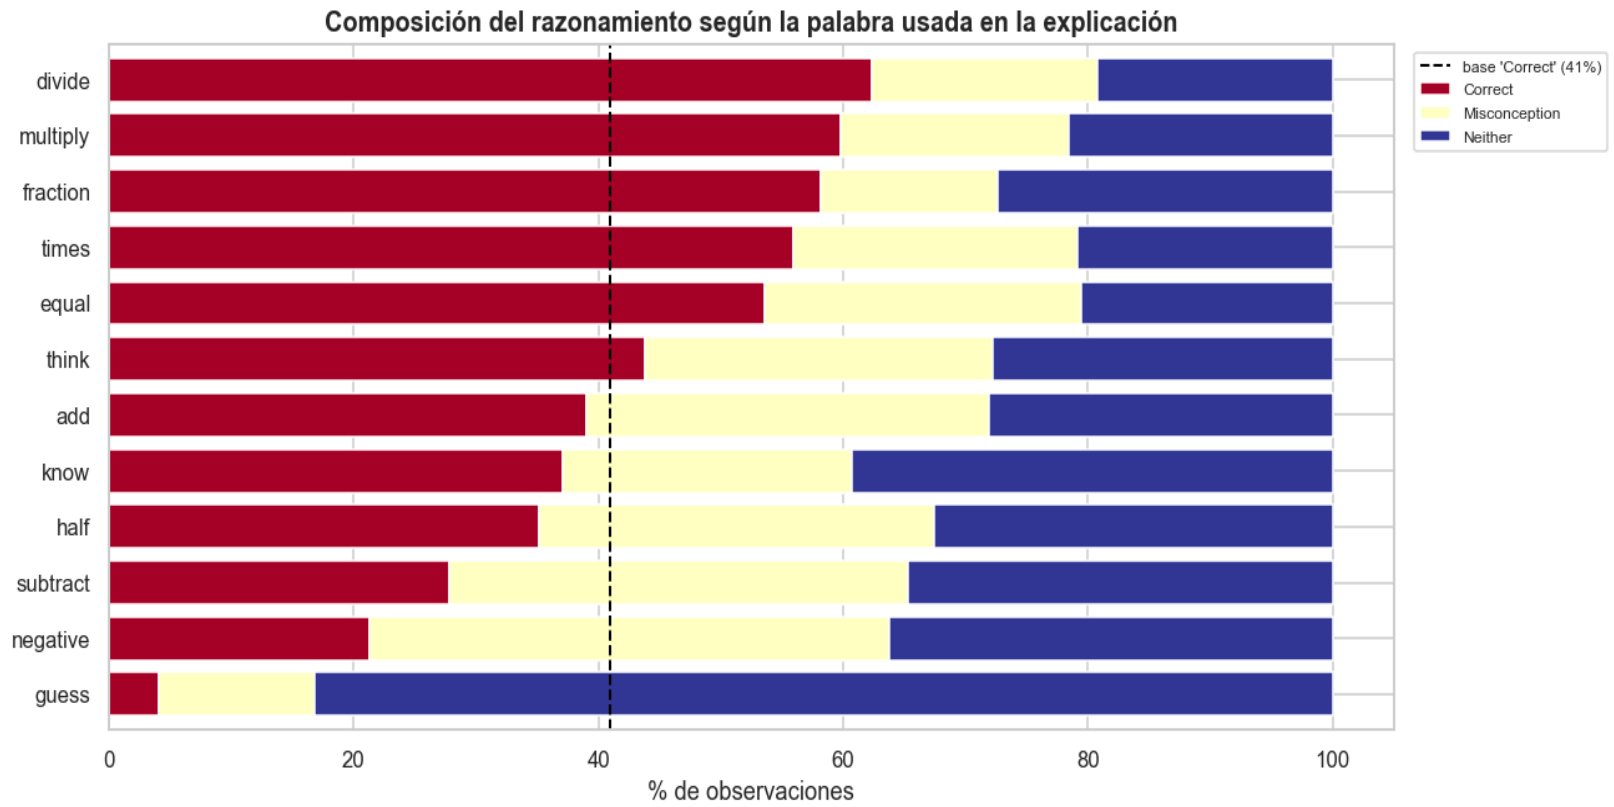
35.7%–79.6% de True_Correct.

Cuidado

QuestionId ayuda en preguntas conocidas, pero el ID crudo no generaliza a nuevas.

32 de 35 concepciones erróneas aparecen en una sola pregunta.

Los marcadores léxicos son señales, no explicaciones



Ejemplos

divide · multiply · denominator · because

Interpretación

Su frecuencia cambia por categoría, pero debe evaluarse junto con pregunta, opción y explicación.

De líneas base interpretables a modelos contextuales

1 · Baseline

TF–IDF de palabras y caracteres con regresión logística y SVM.

Ventaja: costo bajo, transparencia y referencia fuerte para texto corto.

2 · Modelo principal

BERT/DeBERTa con pregunta, opción y explicación; salida multitarea para categoría y misconception.

Ventaja: contexto semántico.

3 · Experimento

MathBERT o adaptación de dominio, ensamble calibrado y ranking top–3.

Condición: mejora consistente y costo justificable.

SÍNTESIS

Cinco hallazgos que condicionan el modelado

- Desbalance severo: 32 de 65 targets tienen menos de 50 ejemplos.
- Dependencia contextual: casi todas las misconceptions están ligadas a una pregunta.
- Nulos semánticos: 73.13% de Misconception representa ausencia legítima.
- Duplicación: 736 registros coinciden al excluir row_id.
- Texto corto y ruidoso: mediana 13 palabras; conservar notación matemática.

Dos validaciones responden preguntas distintas

StratifiedKFold

Escenario principal: rendimiento en nuevas respuestas a preguntas conocidas. Estratificar por etiqueta compuesta y agrupar duplicados.

GroupKFold por QuestionId

Prueba de transferencia: extrapolación a preguntas no vistas. Reportarla por separado porque muchas etiquetas son específicas de pregunta.

Métricas: MAP@3 + macro F1 + desempeño por pregunta/clase + calibración

TRAZABILIDAD

Repositorio reproducible y entregables

github.com/DanielBarillasM/
Proyecto-2_Grupo-1_DS_Sec-10

Evidencia

- Notebook ejecutable
- Datos versionados localmente
- 7 figuras persistidas
- Informe EDA en PDF/TeX
- Revisión bibliográfica APA
- README y documento del repo

Presentación

- HTML navegable
- PowerPoint editable
- Rutas relativas a report/assets
- Dependencias fijadas
- Cifras verificadas contra train.csv

CONCLUSIÓN

Comprender el error requiere leer el razonamiento.

El EDA demuestra que la pregunta, la opción y la explicación deben modelarse juntas; el desbalance y la dependencia por pregunta exigen evaluación dual y resultados desagregados.

Siguiente paso: baseline TF–IDF/SVM → Transformer contextual multitarea → ensamble calibrado

Gracias