INTRODUCCIÓN · PROYECTO 2

Charting Student Math Misunderstandings

Exploración de razonamientos matemáticos abiertos para reconocer respuestas correctas, errores y concepciones erróneas mediante Procesamiento del Lenguaje Natural.

CC3084 — Data Science · Sección 10

Jorge Gabriel Palacios Sales · Pablo Daniel Barillas Moreno

Roberto Emiliano Otoniel Camposeco Torres · Abby Sofia Donis Agreda

Universidad del Valle de Guatemala · 2026

PROBLEMA A RESOLVER · SITUACIÓN PROBLEMÁTICA

Una opción correcta no garantiza un razonamiento correcto

Las respuestas abiertas revelan **cómo** piensa el estudiante, pero revisarlas manualmente a escala exige tiempo y conocimiento pedagógico.

Señal observable

Opción seleccionada y explicación escrita con vocabulario, símbolos y pasos informales.

Variable latente

La concepción matemática que originó el error puede aparecer aun cuando la respuesta sea correcta.

Oportunidad

NLP puede priorizar patrones probables para apoyar retroalimentación docente, no reemplazarla.

Pregunta científica: ¿qué patrones lingüísticos y estructurales permiten distinguir la relación entre corrección, calidad del razonamiento y concepción errónea?

Rittle-Johnson et al. (2025); The Learning Agency (2025).

OBJETIVOS

Qué buscamos responder con el análisis exploratorio

Objetivo general

Caracterizar la estructura, calidad, desbalance y señales lingüísticas del conjunto MAP para fundamentar un pipeline de clasificación reproducible y pedagógicamente responsable.

Objetivo específico 1 · Describir

Cuantificar observaciones, variables, tipos, valores faltantes, duplicados y calidad del texto.

Objetivo específico 2 · Explorar

Analizar distribuciones y relaciones entre pregunta, opción, explicación, categoría y concepción errónea.

Objetivo específico 3 · Decidir

Traducir los hallazgos en criterios de preprocesamiento, validación, métricas y modelos candidatos.

Alcance: esta entrega realiza EDA y selección preliminar; el entrenamiento predictivo corresponde a una fase posterior.

BASE CONCEPTUAL · INVESTIGACIÓN PREVIA

El conjunto surge de un benchmark educativo cuidadosamente anotado

52,463
explicaciones en el benchmark completo

15
preguntas de matemática

27%
respuestas sintéticas añadidas

.70–.90
κ de Cohen reportada entre evaluadores

Procedencia

Respuestas reales de la plataforma Eedi, complementadas con ejemplos sintéticos y revisadas mediante rúbricas construidas por especialistas.

Lectura crítica

Parte de los errores ortográficos y del cambio a minúsculas fue inyectada artificialmente. El ruido textual no debe interpretarse por completo como conducta natural.

Rittle-Johnson et al. (2025), *Detecting Math Misconceptions: An AI Benchmark Dataset*.

BASE CONCEPTUAL · RETO MAP

Una tarea jerárquica evaluada con MAP@3

Pregunta + opción + explicación → **Category** →

Misconception

La salida combina la categoría del razonamiento con una concepción errónea específica cuando corresponde.

1.ª predicción | **2.ª** | **3.ª**

AP@3 = promedio de aciertos ponderados por su posición

- Premia que la etiqueta correcta aparezca temprano.
- Admite hasta tres hipótesis ordenadas.
- La validación debe separar por pregunta para medir generalización real.

King et al. (2025), Kaggle: *MAP — Charting Student Math Misunderstandings*.

DESCRIPCIÓN DEL CONJUNTO DE DATOS

36,696 filas × 7 columnas en el archivo de entrenamiento

36,696 × 7
filas × columnas

15
preguntas únicas

49
opciones distintas

35 / 65
concepciones / etiquetas compuestas

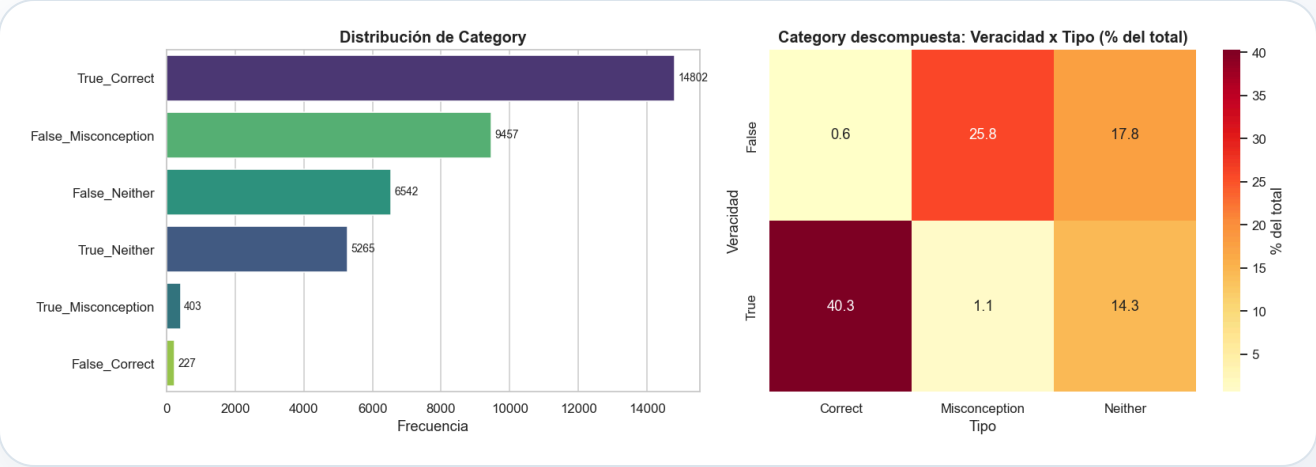
Variable	Tipo	Descripción y función
`row_id`	Entera	Identificador único de la observación; no es predictor.
`QuestionId`	Entera/categórica	Identifica el ítem y aporta contexto; no identifica al estudiante.
`QuestionText`	Texto	Enunciado matemático de la pregunta; variable contextual.
`MC_Answer`	Texto/categórica	Opción seleccionada por el estudiante; variable predictora.
`StudentExplanation`	Texto libre	Justificación escrita; predictor principal del problema NLP.
`Category`	Categórica	Combina veracidad y tipo de razonamiento; primera parte del objetivo.
`Misconception`	Categórica anulable	Concepción errónea, cuando aplica; segunda parte del objetivo.

Unidad de análisis: una explicación vinculada con una pregunta y la opción elegida. No existe identificador de estudiante.

Fuente: resultados reproducidos en *01_analisis_exploratorio.ipynb*.

EDA UNIVARIADO · DISTRIBUCIÓN DE ETIQUETAS

La categoría dominante es respuesta correcta con razonamiento correcto



40.34%

corresponde a **True_Correct**.

- Las clases no tienen igual frecuencia.
- El error requiere separar opción, razonamiento y concepción.
- Accuracy aislada sería una medida engañosa.

Cálculos y figura almacenados en el notebook del proyecto.

LIMPIEZA Y PREPROCESAMIENTO

El 73.1% de ausencia en “Misconception” es principalmente estructural

26,836

Valores ausentes

No equivalen automáticamente a mala calidad: muchas categorías no requieren una concepción errónea.

Conservar

Negaciones, operadores, fracciones, porcentajes, números y expresiones como “times” o “divide”.

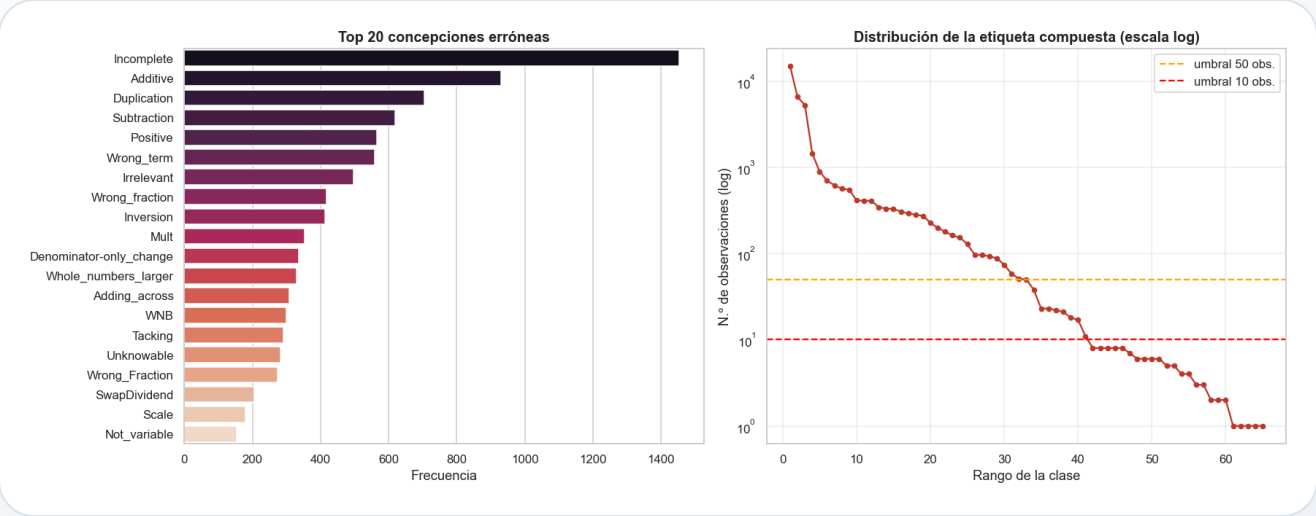
Normalizar con cuidado

Espacios, variantes tipográficas y campos de etiqueta, manteniendo intacta la semántica matemática.

Regla clave: no imputar “Misconception” con la moda. La ausencia codifica que la etiqueta no aplica en parte del esquema jerárquico.

EDA UNIVARIADO · DESBALANCE

La taxonomía presenta una cola larga de concepciones erróneas

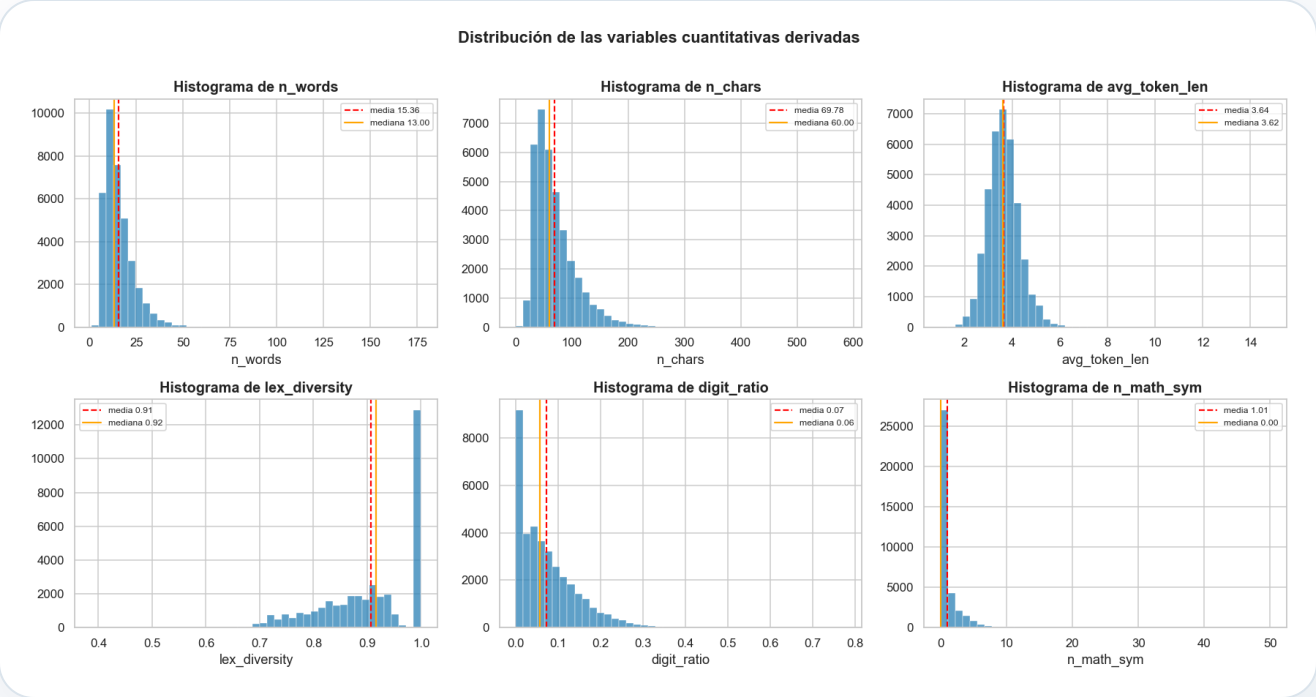


Pocas etiquetas concentran muchos ejemplos; numerosas concepciones son raras.

- Reportar macro-F1 además de métricas globales.
- Usar ponderación o muestreo cuidadoso.
- Analizar errores por etiqueta y por pregunta.
- Predecir primero la categoría y después la concepción.

EDA UNIVARIADO · CALIDAD TEXTUAL

Las explicaciones son breves, heterogéneas y con señales matemáticas

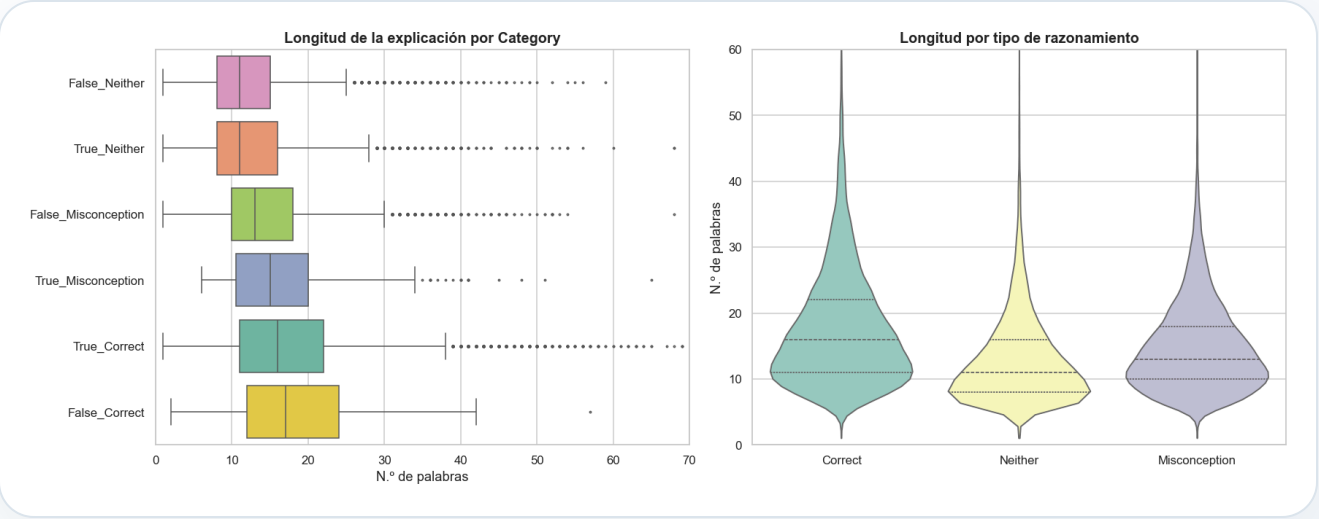


- Mediana: 13 palabras; media: 15.36.
- No hay explicaciones vacías; 30 tienen una o dos palabras.
- La ortografía y la puntuación varían.
- El largo no determina por sí solo la corrección.

La representación debe combinar texto, números, opción elegida y contexto de la pregunta.

EDA BIVARIADO · OUTLIERS POR CATEGORÍA

Los textos largos son casos informativos, no errores automáticos

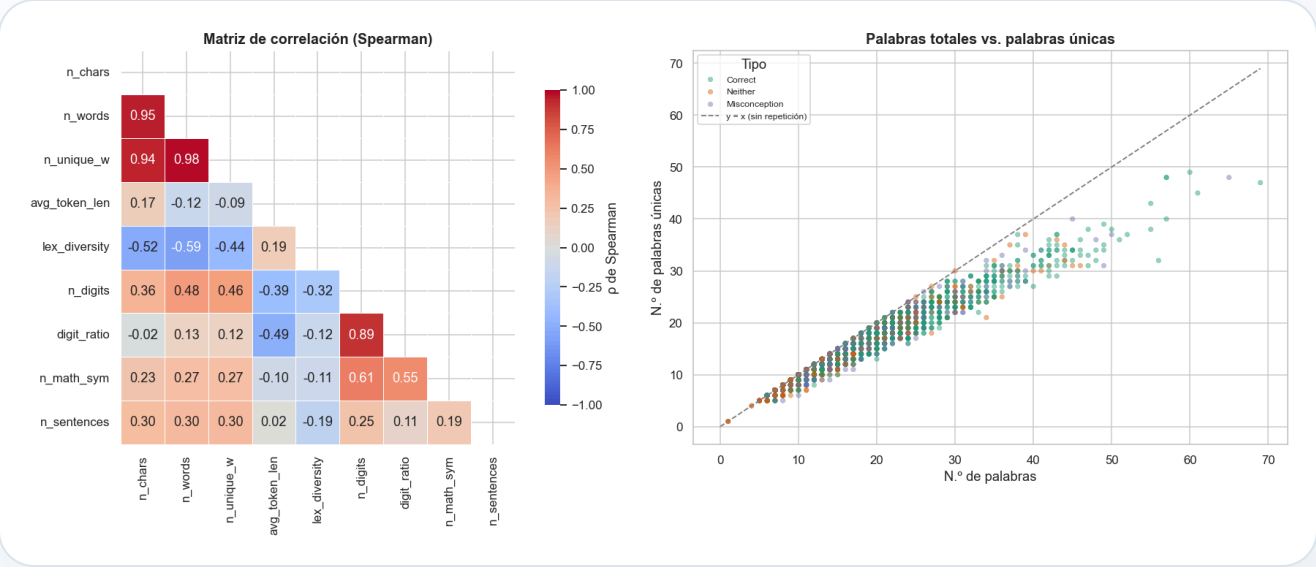


Los diagramas de caja muestran dispersión y valores extremos en todas las categorías.

- Revisar manualmente textos mínimos y anómalos.
- Evitar truncamiento agresivo.
- Usar longitud como rasgo auxiliar, no como sustituto del significado.

EDA MULTIVARIADO · RELACIONES NUMÉRICAS

Las métricas superficiales del texto están correlacionadas entre sí

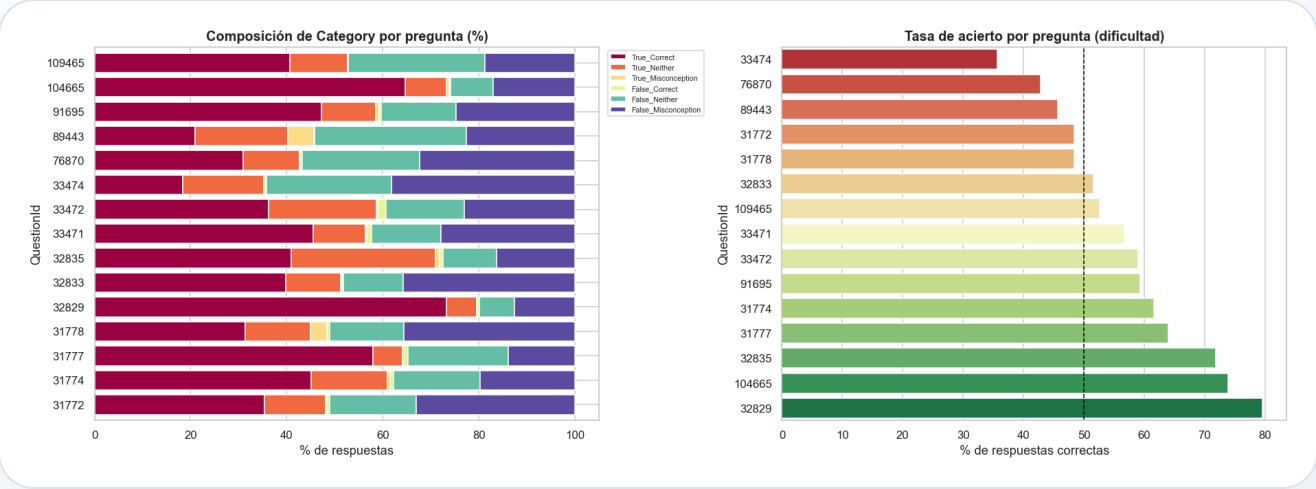


- Palabras y caracteres describen casi el mismo eje de longitud.
- No conviene tratarlos como evidencias independientes.
- Las correlaciones no capturan equivalencia matemática ni causalidad.

Las variables de longitud sirven para diagnóstico de calidad y control de truncamiento.

EDA BIVARIADO Y MULTIVARIADO · DEPENDENCIA CONTEXTUAL

La distribución cambia sustancialmente entre preguntas



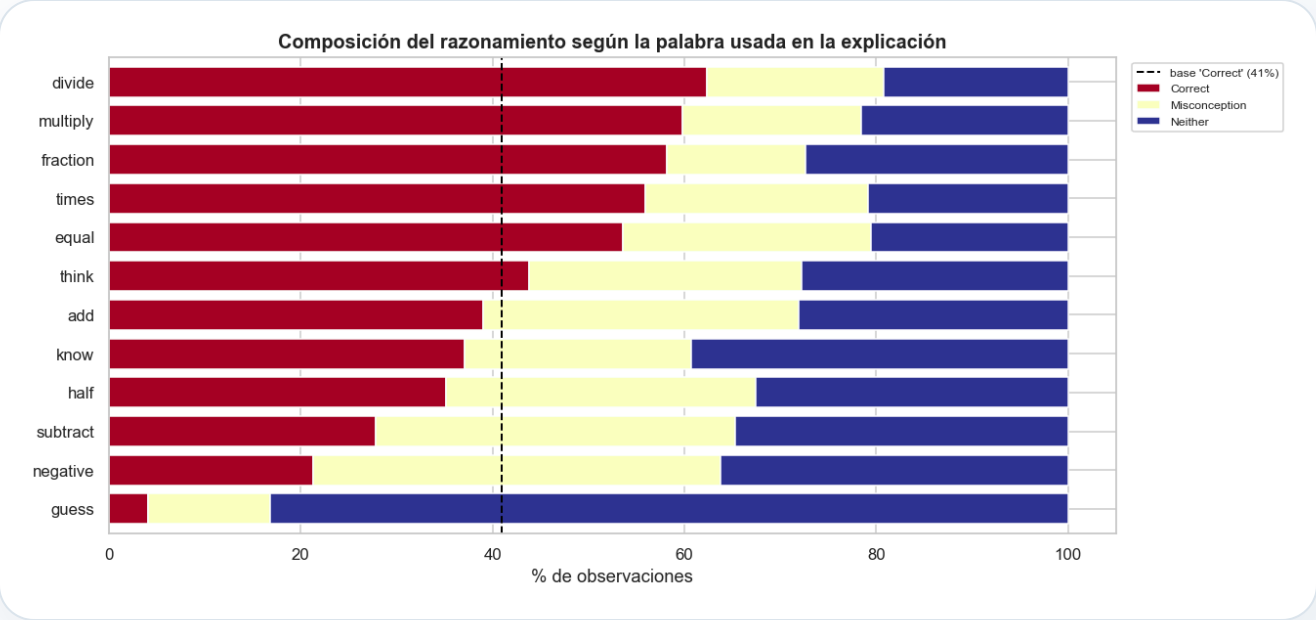
Pregunta, opción y lenguaje están entrelazados.

- Un split aleatorio puede filtrar patrones específicos.
- GroupKFold deja numerosas etiquetas sin ejemplos de entrenamiento.
- Se deben reportar ambos escenarios y resultados por pregunta.

StratifiedKFold **GroupKFold** **MAP@3**

EDA BIVARIADO · SEÑALES LÉXICAS

Los marcadores frecuentes orientan, pero no explican por sí solos



- Expresiones como *times*, *divide* o *not shaded* se asocian con contextos concretos.
- TF-IDF ofrece una línea base interpretable.
- N-gramas capturan frases y negaciones locales.
- Los patrones deben contrastarse con la pregunta y la opción.

CONCLUSIONES · HALLAZGOS Y DECISIONES

Cinco conclusiones accionables del análisis

1 · Jerarquía

Category debe preceder a Misconception.

2 · Contexto

La pregunta no es un identificador neutral.

3 · Desbalance

Evaluar más allá de accuracy.

4 · Texto

Preservar notación, números y negaciones.

5 · Prudencia

El modelo apoya la revisión docente.

Siguiente paso

Baseline TF-IDF y validación dual.

La mejor explicación del dataset no es “detectar palabras equivocadas”, sino modelar la relación entre contexto, elección y razonamiento.

REPOSITORIO Y REPRODUCIBILIDAD

Artefactos del proyecto

```
Proyecto-2_Grupo-1_DS_Sec-10/
├── data/          dataset local (no versionado)
├── instructions/  guía del proyecto
├── notebooks/     análisis exploratorio
├── report/        informes y figuras
├── presentation/  HTML, PowerPoint y PDF
├── file/          documento del repositorio
├── README.md
└── requirements.txt
```

github.com/DanielBarillasM/Proyecto-2_Grupo-1_DS_Sec-10

Escanee para abrir el repositorio

Estado verificado: ruta de datos flexible, dependencias fijadas, notebook ejecutado sin errores y PowerPoint editable incluido.

REFERENCIAS

Fuentes principales · APA 7.ª edición

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *NAACL-HLT 2019*, 4171–4186. https://doi.org/10.18653/v1/N19-1423

He, P., Liu, X., Gao, J., & Chen, W. (2021). DeBERTa: Decoding-enhanced BERT with disentangled attention. *ICLR 2021*.

King, J., Smith, K., Burleigh, L., Crossley, S., Demkin, M., & Reade, W. (2025). *MAP—Charting student math misunderstandings*. Kaggle.

Otero, V., Rodrigues, A., Saporta, J., Musco, C., & Musco, C. (2025). A benchmark for math misconceptions. *Discover Education, 4*, 277. https://doi.org/10.1007/s44217-025-00742-w

Rittle-Johnson, B., Adler, R., Durkin, K., Burleigh, L., King, J., & Crossley, S. (2025). Detecting math misconceptions: An AI benchmark dataset. *AIME-Con WIP*, 20–24.

Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management, 24*(5), 513–523.

Shen, J. T., Yamashita, M., Prihar, E., Heffernan, N., Wu, X., Graff, B., & Lee, D. (2021). *MathBERT* [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2106.07340

The Learning Agency. (2025, November 12). *Case study: Math misconceptions competition*.

La bibliografía completa y los enlaces activos se encuentran en el informe PDF.

CONCLUSIONES · CIERRE

Comprender el error es el primer paso para enseñar mejor.

El análisis exploratorio transforma explicaciones abiertas en hipótesis verificables para un sistema de apoyo pedagógico responsable.

¿Preguntas?