Universidad del Valle de Guatemala

Facultad de Ingeniería

Departamento de Ciencias de la Computación

Proyecto 2 – Análisis Exploratorio

MAP: Charting Student Math Misunderstandings

Caracterización de explicaciones matemáticas estudiantiles mediante Procesamiento del Lenguaje Natural

Curso:	CC3084 – Data Science
Docente:	Lynette García Pérez
Grupo y sección:	Grupo 1, sección 10
Integrantes:	Jorge Gabriel Palacios Sales Pablo Daniel Barillas Moreno Roberto Emiliano Otoniel Camposeco Torres Abby Sofia Donis Agreda
Tema:	Procesamiento del Lenguaje Natural (NLP)

Guatemala, agosto de 2026

Ficha del informe

Propósito

Este informe presenta el análisis exploratorio del reto 6, *MAP – Charting Student Math Misunderstandings*. Su propósito es caracterizar la estructura, calidad, desbalance y contenido lingüístico de las explicaciones escritas por estudiantes, y traducir la evidencia en decisiones justificadas de preprocesamiento, validación y modelado.

Cuadro 1: Identificación y alcance del documento.

Elemento	**Descripción**
Curso	CC3084 – Data Science, sección 10
Período académico	Segundo semestre de 2026
Reto	6: MAP – Charting Student Math Misunderstandings
Área	Procesamiento del Lenguaje Natural
Unidad de análisis	Respuesta de un estudiante a una pregunta matemática, acompañada de una explicación libre
Base principal	`train.csv`: 36,696 observaciones y 7 variables
Objetivo de la competencia	Predecir la etiqueta compuesta `Category:Misconception`
Alcance del informe	Exploración, limpieza, interpretación y próximos pasos; no incluye entrenamiento de un modelo final
Fuente de evidencia	Contenido, tablas, salidas y siete figuras almacenadas en el notebook del proyecto

Trazabilidad del análisis

Para elaborar este documento no se ejecutaron celdas del notebook. Las cifras y figuras proceden de sus salidas ya almacenadas. Cuando una afirmación textual del notebook difería de una tabla, una gráfica o una salida numérica guardada, se priorizó la evidencia numérica y la discrepancia se documentó como limitación de reproducibilidad.

Resumen

Se analizaron 36,696 respuestas estudiantiles distribuidas entre 15 preguntas matemáticas. Cada registro contiene el enunciado, la opción elegida y una explicación breve en lenguaje natural; en entrenamiento también incluye la categoría del razonamiento y, cuando aplica, la concepción errónea. El espacio de salida contiene seis valores de `Category`, 35 concepciones erróneas y 65 etiquetas compuestas.

La investigación previa muestra que las 36,696 filas locales son la porción etiquetada de un benchmark de 52,463 explicaciones. El conjunto completo fue construido con 38,095 explicaciones originales y 14,368 paráfrasis sintéticas (27%), calificadas con rúbricas por ítem y controles de acuerdo entre evaluadores (Rittle-Johnson et al., 2025). Esta procedencia obliga a interpretar la ortografía, las minúsculas y las repeticiones como una mezcla de producción estudiantil y aumento controlado.

El conjunto está completo en sus variables obligatorias. Los 26,836 valores nulos de `Misconception` (73.1%) son ausencias estructurales: aparecen exactamente cuando el razonamiento no fue clasificado como concepción errónea. Por ello se codifican como `NA` y no se imputan. No hay filas idénticas si se conserva el identificador único; sin embargo, existen 736 duplicados al ignorar `row_id` y 970 repeticiones adicionales de texto. La ausencia de un identificador de estudiante impide demostrar independencia, de modo que estas observaciones se conservan, pero se reconoce su posible efecto sobre una partición aleatoria.

La variable objetivo presenta una cola larga severa: 32 de las 65 clases compuestas tienen menos de 50 observaciones y 24 tienen menos de 10, mientras `True_Correct:NA` concentra 40.3% del total. El texto también impone retos particulares: la explicación mediana tiene 13 palabras, 62.8% comienza en minúscula, 78.3% contiene dígitos y 27.2% usa una barra de fracción. Por consiguiente, eliminar números o símbolos matemáticos destruiría información central.

El hallazgo metodológico más importante es la dependencia entre etiquetas y preguntas. Treinta y dos de las 35 concepciones erróneas aparecen en una sola pregunta; además, 58 de los 60 pares `(QuestionId, MC_Answer)` determinan la veracidad sin necesidad de leer el texto. Esto favorece un modelo jerárquico, pero también crea riesgo de memorización y fuga contextual. Se recomienda reportar dos esquemas de validación: uno estratificado para preguntas conocidas y otro agrupado por pregunta para medir transferencia a preguntas nuevas.

Conclusión ejecutiva

El reto no es una clasificación plana homogénea. La veracidad de la opción es casi determinista a partir de la pregunta y la respuesta; la dificultad real consiste en interpretar la explicación y distinguir razonamiento correcto, concepción errónea o evidencia insuficiente. El diseño de validación es tan importante como el algoritmo y debe hacer visible la diferencia entre memorizar una pregunta y generalizar el razonamiento matemático.

Índice

Ficha del informe i

Resumen ii

1 Introducción 1

1.1 Situación problemática . . . 1

1.2 Problema científico . . . 1

1.3 Objetivos . . . 2

1.3.1 Objetivo general . . . 2

1.3.2 Objetivos específicos . . . 2

1.4 Alcance . . . 2

2 Investigación previa y antecedentes 3

2.1 Por qué estudiar concepciones erróneas . . . 3

2.2 El reto MAP . . . 3

2.3 Procedencia y construcción del benchmark . . . 4

2.4 Técnicas investigadas para detectar patrones escritos . . . 5

2.5 Consecuencias para este análisis exploratorio . . . 5

3 Marco conceptual de NLP 7

3.1 Patrones en lenguaje escrito . . . 7

3.2 Por qué el contexto matemático importa . . . 7

3.3 Métrica de la competencia . . . 7

4 Descripción de los datos 9

4.1 Archivos disponibles . . . 9

4.2 Diccionario de variables . . . 9

4.3 Estructura de la etiqueta . . . 10

5 Limpieza y preprocesamiento 11

5.1 Valores faltantes . . . 11

5.2 Duplicados y textos repetidos . . . 11

5.3 Calidad y convenciones del texto . . . 11
5.4 Decisiones de transformación . . . 12

6 Análisis exploratorio 13
6.1 Variables categóricas . . . 13
6.1.1 Distribución de `Category` . . . 13
6.1.2 Concepciones erróneas y etiqueta compuesta . . . 13
6.2 Variables cuantitativas derivadas del texto . . . 15
6.3 Longitud y tipo de razonamiento . . . 15
6.4 Valores atípicos . . . 17
6.5 Correlaciones . . . 17
6.6 Cruces entre pregunta, respuesta y etiqueta . . . 17
6.6.1 Dificultad heterogénea . . . 18
6.6.2 Concepciones ligadas a la pregunta . . . 18
6.6.3 Veracidad casi determinista . . . 19
6.7 Contenido léxico . . . 19

7 Implicaciones para validación y modelado 20
7.1 Amenazas de fuga de información . . . 20
7.2 Propuesta de validación doble . . . 20
7.3 Arquitectura jerárquica propuesta . . . 20
7.4 Línea base e ingeniería de características . . . 21

8 Hallazgos, conclusiones y recomendaciones 22
8.1 Síntesis de hallazgos . . . 22
8.2 Conclusiones . . . 22
8.3 Recomendaciones y próximos pasos . . . 23
8.4 Limitaciones . . . 23

A Matriz de cumplimiento de la rúbrica 25

B Notas de consistencia y reproducibilidad 26

Referencias 27

Índice de figuras

6.1 Distribución de `Category` y descomposición entre veracidad y tipo de razonamiento. Figura extraída de la salida almacenada del notebook. 13

6.2 Concepciones erróneas más frecuentes y cola larga de las 65 etiquetas compuestas. Las líneas horizontales marcan 50 y 10 observaciones. 14

6.3 Histogramas de seis variables cuantitativas derivadas. Las explicaciones son cortas y las medidas de longitud presentan cola derecha. 16

6.4 Diagramas de caja y violín para la longitud de la explicación. Las medianas por tipo son 16 palabras para `Correct`, 13 para `Misconception` y 11 para `Neither`. . . 16

6.5 Matriz de correlaciones de Spearman y relación entre palabras totales y palabras únicas. 18

6.6 Composición de las categorías y tasa de acierto para cada pregunta. La línea vertical discontinua marca 50% de respuestas correctas. 18

6.7 Composición del tipo de razonamiento condicionada a palabras seleccionadas. La línea discontinua representa la tasa base de razonamientos correctos. 19

Índice de cuadros

1 Identificación y alcance del documento. i

2.1 Procedencia del benchmark MAP según su artículo metodológico. 4

4.1 Archivos de datos identificados en el proyecto. 9
4.2 Variables del conjunto de entrenamiento. 9
4.3 Interpretación de los seis valores de `Category`. 10

5.1 Disponibilidad de `Misconception` por tipo de razonamiento. 11
5.2 Indicadores de calidad de `StudentExplanation`. 12
5.3 Plan de limpieza y justificación. 12

6.1 Frecuencia y proporción de las categorías. 13
6.2 Quince concepciones erróneas más frecuentes. 14
6.3 Variables cuantitativas derivadas. 15
6.4 Resumen estadístico de las variables derivadas. 15
6.5 Longitud de explicación por categoría. 16
6.6 Atípicos según el criterio IQR. 17
6.7 Pares ambiguos de pregunta y respuesta. 19

7.1 Esquemas complementarios de validación. 20

8.1 Hallazgos principales y consecuencias. 22

A.1 Correspondencia entre los criterios de evaluación y el informe. 25

1

Introducción

1.1 Situación problemática

Una respuesta matemática incorrecta revela que existe un problema, pero no explica su causa. Para intervenir pedagógicamente, el docente necesita conocer el razonamiento que condujo al resultado. Una *misconception* o concepción errónea es un patrón de pensamiento incorrecto y relativamente estable; no es equivalente a un simple descuido aritmético ni a la ausencia de explicación.

Dos estudiantes pueden seleccionar la misma opción equivocada por causas distintas: uno puede invertir numerador y denominador y otro contar de forma incorrecta las partes de una figura. Aunque el resultado observable sea el mismo, las intervenciones educativas deberían ser diferentes. También puede ocurrir que un estudiante acierte por casualidad con un razonamiento erróneo, o que razone correctamente y cometa un error final de cálculo. Una calificación basada únicamente en la opción marcada no detecta estas diferencias.

La dificultad práctica es la escala. Leer y diagnosticar manualmente cada explicación después de una evaluación demanda tiempo especializado. El reto, organizado en torno a datos de la plataforma educativa Eedi, propone automatizar una primera caracterización para apoyar retroalimentación oportuna. El sistema no sustituye el juicio docente: busca priorizar y organizar evidencia escrita.

Relevancia educativa

Los 403 casos `True_Misconception` son especialmente importantes: la opción marcada es correcta, pero la explicación revela una concepción errónea. Un examen que solo califique el resultado los consideraría éxitos y perdería la oportunidad de intervenir.

1.2 Problema científico

Pregunta de investigación

¿Es posible predecir automáticamente, a partir de la explicación en lenguaje natural escrita por un estudiante, el enunciado y la opción seleccionada, si su razonamiento es correcto y, cuando no lo es, qué concepción errónea específica lo explica?

Formalmente, se trata de clasificación multiclase sobre texto corto y contenido matemático. Para cada observación (i), los predictores son:

$$X_i = \{Q_i,\ T_i,\ A_i,\ E_i\}, \tag{1.1}$$

donde Q_i es el identificador de la pregunta, T_i su enunciado, A_i la opción seleccionada y E_i la explicación libre. La salida es la etiqueta compuesta:

$$Y_i = \text{Category}_i : \text{Misconception}_i. \tag{1.2}$$

Las dificultades anticipadas son texto corto y ruidoso, errores ortográficos, notación matemática informal, desbalance severo, clases con soporte mínimo y dependencia entre la pregunta y la etiqueta.

1.3 Objetivos

1.3.1 Objetivo general

Caracterizar mediante análisis exploratorio la estructura, calidad y principales dificultades del conjunto de datos MAP, de modo que las decisiones de preprocesamiento, validación y diseño del modelo de clasificación queden fundamentadas en evidencia empírica.

1.3.2 Objetivos específicos

1. Cuantificar el desbalance de `Category`, `Misconception` y la etiqueta compuesta, identificando las clases con menos de 50 y menos de 10 observaciones.
2. Evaluar la calidad y el poder discriminante del texto mediante longitud, densidad numérica, diversidad léxica y símbolos matemáticos, además de detectar valores atípicos y ausencias.
3. Analizar la relación entre pregunta, opción seleccionada, veracidad, tipo de razonamiento y concepción errónea para identificar dependencias que condicionen la validación.
4. Proponer decisiones de limpieza y próximos pasos de modelado que conserven la información matemática y reduzcan el riesgo de fuga.

1.4 Alcance

El informe cubre investigación conceptual de NLP, descripción de datos, limpieza, estadística descriptiva, frecuencias, proporciones, cruces, correlaciones, atípicos, interpretación léxica, conclusiones y próximos pasos. No entrena ni compara modelos finales. El `test.csv` local tiene solo tres filas de ejemplo; cualquier evaluación futura deberá construirse con una partición controlada de entrenamiento.

2

Investigación previa y antecedentes

2.1 Por qué estudiar concepciones erróneas

Una concepción errónea no es simplemente una respuesta incorrecta. Es una forma sistemática de interpretar o aplicar conocimiento matemático que puede producir el mismo patrón de error en situaciones relacionadas. Esta diferencia es pedagógicamente central: una equivocación de cálculo puede requerir práctica o revisión, mientras que una regla conceptual mal generalizada exige hacer visible el razonamiento y reconstruir su significado.

La literatura reciente sobre diagnóstico asistido por inteligencia artificial coincide en que las explicaciones abiertas contienen información que la opción marcada no ofrece. En un benchmark independiente de álgebra de nivel medio, Otero, Druga y Lan (2025) mostraron que restringir los candidatos por tema y añadir revisión de educadores mejoró notablemente la identificación de concepciones erróneas. Este resultado respalda dos decisiones del presente proyecto: incorporar el contexto de la pregunta y conservar supervisión humana en cualquier uso pedagógico.

Los aciertos con razonamiento defectuoso merecen atención particular. Un trabajo reciente presentado en el taller PEAF estudió este fenómeno con respuestas de Eedi y advirtió que, aun cuando modelos de razonamiento mejoran la detección, los falsos positivos pueden superar ampliamente los casos reales; por ello propuso un flujo de detectar, verificar y escalar, en vez de generar diagnósticos automáticos definitivos (Imran & Bulathwela, 2026). Esta evidencia se considera emergente porque corresponde a un trabajo de taller, pero coincide con la necesidad de interpretar con cautela la clase `True_Misconception`.

2.2 El reto MAP

La competencia *MAP – Charting Student Math Misunderstandings* fue organizada por Vanderbilt University y The Learning Agency en Kaggle. Su objetivo oficial fue construir modelos de NLP capaces de proponer concepciones erróneas candidatas a partir de explicaciones abiertas, para facilitar que los docentes identifiquen razonamientos incorrectos que son costosos de etiquetar manualmente (King et al., 2025). La competencia inició el 10 de julio de 2025 y cerró el 15 de octubre de 2025.

El reto no se limita a predecir si la opción es correcta. La salida integra:

1. la veracidad de la opción elegida;
2. la calidad de la explicación: correcta, concepción errónea o ninguna;
3. el nombre de la concepción errónea cuando existe.

La meta declarada es que las concepciones aprendidas puedan generalizar entre problemas diferentes, no solo que se reproduzca el inventario de etiquetas de una pregunta conocida (King et al., 2025). Esta aspiración vuelve especialmente relevante el hallazgo exploratorio de que 32 de las 35 concepciones presentes en el entrenamiento local aparecen en una sola pregunta.

El estudio retrospectivo de la entidad organizadora reportó más de 1,850 equipos, cerca de 40,000 envíos y resultados MAP@3 superiores a 0.94 entre las soluciones principales. También destacó que la taxonomía fue desarrollada por expertos de contenido para diferenciar corrección, errores comunes y concepciones específicas (The Learning Agency, 2025). Un desempeño alto en la competencia demuestra viabilidad técnica dentro de ese benchmark, pero no garantiza por sí solo validez externa en nuevos currículos, idiomas o poblaciones.

2.3 Procedencia y construcción del benchmark

Rittle-Johnson et al. (2025) documentaron académicamente la construcción del conjunto MAP. El benchmark completo contiene 52,463 explicaciones sobre 15 preguntas de matemática de nivel medio, principalmente números racionales, ecuaciones y funciones. Los ítems provienen de Eedi; cada uno contiene una opción correcta y tres distractores diseñados, cuando es posible, para capturar errores conocidos. A la selección de opción múltiple le sigue una solicitud de explicación abierta.

Cuadro 2.1: Procedencia del benchmark MAP según su artículo metodológico.

Elemento	**Descripción documentada**
Plataforma de origen	Eedi, plataforma de aprendizaje de matemáticas del Reino Unido.
Cobertura	15 preguntas de nivel medio, con énfasis en números racionales, ecuaciones y funciones.
Tamaño completo	52,463 explicaciones; el `train.csv` local contiene 36,696, es decir, solo la porción etiquetada disponible para entrenamiento.
Explicaciones originales	38,095 registros.
Explicaciones aumentadas	14,368 paráfrasis generadas con Coedit-XL, equivalentes al 27% del benchmark completo.
Anotación	Rúbricas específicas por ítem, desarrolladas por tres especialistas en cognición matemática y concepciones erróneas.
Control de calidad	24% de explicaciones codificadas por dos evaluadores; κ de Cohen entre 0.70 y 0.90.
Privacidad	Explicaciones revisadas para retirar información identificable; no se distribuyeron datos demográficos.

La generación sintética buscó aumentar el soporte de concepciones poco frecuentes y facilitar la capacitación de evaluadores. Se permitió como máximo una paráfrasis por explicación auténtica. Para imitar la escritura estudiantil, la mitad de los textos aumentados recibió un error ortográfico aleatorio y la mitad fue convertida completamente a minúsculas (Rittle-Johnson et al., 2025).

Implicación para el análisis de calidad

No todo el ruido observado puede atribuirse directamente a estudiantes. Parte de las minúsculas, ortografía y repetición léxica fue introducida de manera controlada en las explicaciones sintéticas. Como los archivos de competencia no incluyen un indicador de procedencia, el análisis local no puede separar textos originales de aumentados ni medir su distribución por clase.

La anotación también impone límites. Cada explicación recibe un solo código, aunque un razonamiento podría exhibir más de un error. El artículo reporta que 27% del benchmark completo contiene evidencia de una posible concepción errónea y que su frecuencia cambia considerablemente entre ítems (Rittle-Johnson et al., 2025). Esto coincide con la cola larga y la dependencia por pregunta encontradas en el EDA.

2.4 Técnicas investigadas para detectar patrones escritos

La investigación previa sugiere una progresión metodológica en cuatro niveles:

1. **Representaciones léxicas interpretables.** TF–IDF pondera los términos de acuerdo con su frecuencia local y su rareza en el corpus; constituye una referencia clásica para recuperación y clasificación de texto (Salton & Buckley, 1988).
2. **Modelos lineales supervisados.** Una regresión logística sobre unigramas y bigramas permite establecer una línea base rápida, reproducible y fácil de inspeccionar. Su desempeño indica cuánto del problema puede resolverse mediante asociaciones léxicas.
3. **Modelos contextuales.** BERT aprende representaciones bidireccionales que pueden adaptarse a clasificación con una capa de salida (Devlin et al., 2019); DeBERTa separa información de contenido y posición mediante atención desacoplada (He et al., 2021).
4. **Adaptación al dominio matemático.** MathBERT fue preentrenado con currículo, libros, sílabos y resúmenes matemáticos. En tareas de educación matemática, incluida calificación de respuestas abiertas, superó a BERT base, lo que evidencia el valor de preservar vocabulario, ecuaciones y símbolos especializados (Shen et al., 2021).

La comparación no debe reducirse a escoger el modelo de mayor capacidad. El benchmark de Otero et al. (2025) encontró que restringir el espacio de concepciones por tema y revisar errores con educadores produjo mejoras considerables. Por tanto, contexto, taxonomía y evaluación experta pueden ser tan importantes como la arquitectura.

2.5 Consecuencias para este análisis exploratorio

La investigación previa conduce a cinco criterios concretos que guían el EDA:

- conservar números, fracciones, signos y expresiones matemáticas;
- analizar pregunta, opción y explicación como campos distintos;
- cuantificar la cola larga y la asociación entre concepción e ítem;

- tratar las faltas ortográficas y minúsculas como mezcla de escritura auténtica y aumento sintético;
- evaluar por separado desempeño en preguntas conocidas y transferencia a preguntas nuevas, manteniendo revisión docente.

3

Marco conceptual de NLP

3.1 Patrones en lenguaje escrito

El NLP convierte texto en representaciones que un algoritmo puede comparar. En este reto, una limpieza agresiva sería contraproducente: expresiones como `3/9`, `-13`, `divide`, `half` o `two negatives` contienen el procedimiento y la posible fuente del error. Las técnicas relevantes son:

Normalización controlada. Homogeneizar mayúsculas, espacios y LaTeX en las opciones sin eliminar números, signos ni barras de fracción.

Tokenización y n-gramas. Separar unidades léxicas y conservar secuencias cortas como *divided by*, *not shaded* o *whole number*, cuyo significado supera al de palabras aisladas.

TF–IDF. Ponderar términos frecuentes en una explicación, pero raros en el corpus, para obtener una matriz dispersa interpretable (Salton & Buckley, 1988).

Clasificación lineal. Combinar TF–IDF con regresión logística como línea base fuerte, auditable y eficiente para texto corto.

Modelos contextuales. Evaluar posteriormente transformadores como BERT o DeBERTa, capaces de representar el contexto de una palabra (Devlin et al., 2019; He et al., 2021); su complejidad solo se justifica si mejoran una línea base bien validada.

Clasificación jerárquica. Separar veracidad, calidad del razonamiento y concepción específica, aprovechando la estructura pedagógica de la etiqueta en vez de tratar 65 clases como equivalentes.

3.2 Por qué el contexto matemático importa

Una frase no tiene una interpretación universal. “Se divide por 3” puede ser un procedimiento correcto en una pregunta y una regla aplicada indebidamente en otra. Por ello, el texto debe combinarse con el enunciado y la respuesta. Los modelos que solo usen `StudentExplanation` perderán contexto; los que usen solo `QuestionId` pueden memorizar asociaciones sin comprender el razonamiento.

3.3 Métrica de la competencia

El archivo de ejemplo solicita tres etiquetas ordenadas por confianza. Con una única etiqueta correcta por observación, la precisión promedio a tres posiciones se reduce al recíproco del rango

cuando la respuesta aparece en las tres primeras posiciones:

$$\mathrm{AP@3}_i = \begin{cases} 1/r_i, & r_i \le 3, \\ 0, & r_i > 3, \end{cases} \qquad \mathrm{MAP@3} = \frac{1}{n}\sum_{i=1}^{n} \mathrm{AP@3}_i \,. \tag{3.1}$$

Acertar en la primera, segunda o tercera posición aporta (1), (1/2) o (1/3), respectivamente. Esta métrica es más útil que la exactitud plana ante clases raras, aunque no elimina la necesidad de reportar resultados por clase y por pregunta.

4

Descripción de los datos

4.1 Archivos disponibles

Cuadro 4.1: Archivos de datos identificados en el proyecto.

Archivo	N.º obs.	Variables	Función
`train.csv`	36,696	7	Exploración y futuro entrenamiento
`test.csv`	3	5	Ejemplo local del formato de predicción; no permite evaluación real
`sample_submission.csv`	3	2	Plantilla de tres etiquetas ordenadas por fila
Archivo ZIP	–	–	Copia comprimida de los tres archivos anteriores

La unidad de análisis no es un estudiante completo ni una calificación final. Es una respuesta a una pregunta específica. El conjunto no incluye un identificador de estudiante, curso, centro educativo, edad ni secuencia temporal; por tanto, no es posible estudiar progreso individual o dependencia entre respuestas del mismo estudiante.

Además, la unidad debe interpretarse como un *registro de explicación* y no necesariamente como una producción original independiente. El benchmark completo combina explicaciones auténticas y paráfrasis sintéticas; la versión de competencia no proporciona una bandera que permita distinguirlas (Rittle-Johnson et al., 2025). Esta ausencia condiciona el análisis de duplicados, ortografía y estilo.

4.2 Diccionario de variables

Cuadro 4.2: Variables del conjunto de entrenamiento.

Variable	Tipo en archivo	Tipo estadístico	Descripción y rol
`row_id`	Entero	Identificador	Clave única de la observación; no representa magnitud.
`QuestionId`	Entero	Categórica nominal	Identificador de la pregunta; codifica contexto y dificultad.
`QuestionText`	Texto	Texto contextual	Enunciado matemático; tres preguntas incluyen una descripción textual de imagen.
`MC_Answer`	Texto	Categórica nominal	Opción seleccionada; 96% contiene notación LaTeX.

Variable	Tipo en archivo	Tipo estadístico	Descripción y rol
`Student_ Explanation`	Texto	Texto libre	Explicación escrita por el estudiante; predictor lingüístico principal.
`Category`	Texto	Categórica objetivo	Cruce de veracidad (`True/False`) y tipo (`Correct`, `Misconception` o `Neither`).
`Misconception`	Texto	Categórica objetivo	Nombre de la concepción errónea; solo aplica cuando el tipo es `Misconception`.

Los dos enteros son identificadores, no variables cuantitativas. Por eso no tiene sentido calcular su media como si representaran una escala. Las variables numéricas útiles se derivan del texto y se presentan en el Capítulo 6.

4.3 Estructura de la etiqueta

`Category` tiene la forma `Veracidad_Tipo`. La veracidad indica si la opción elegida es correcta; el tipo evalúa la explicación.

Cuadro 4.3: Interpretación de los seis valores de `Category`.

Categoría	Interpretación
`True_Correct`	Opción correcta y razonamiento correcto.
`True_Misconception`	Opción correcta, pero explicación basada en una concepción errónea; posible acierto casual.
`True_Neither`	Opción correcta, pero explicación insuficiente o no clasificable como correcta ni como concepción errónea.
`False_Correct`	Opción incorrecta con procedimiento esencialmente válido; posible error aritmético final.
`False_Misconception`	Opción incorrecta y explicación asociada a una concepción errónea identificable.
`False_Neither`	Opción incorrecta y explicación insuficiente, irrelevante o no clasificable dentro de una concepción específica.

5

Limpieza y preprocesamiento

5.1 Valores faltantes

La única columna con ausencias es `Misconception`: 26,836 registros, equivalentes a 73.1% del total. El cruce con el tipo de razonamiento demuestra una correspondencia perfecta.

Cuadro 5.1: Disponibilidad de `Misconception` por tipo de razonamiento.

Tipo	Nulo	Con valor
Correct	15,029	0
Misconception	0	9,860
Neither	11,807	0
Total	26,836	9,860

Decisión sobre ausencias

Los nulos significan "no aplica" y se sustituyen por la etiqueta explícita `NA`, que coincide con el formato de entrega. No se usa media, moda ni modelo de imputación: asignar una concepción errónea a casos `Correct` o `Neither` introduciría ruido en casi tres cuartas partes de la base.

5.2 Duplicados y textos repetidos

El diagnóstico guardado informa:

- 0 filas completamente duplicadas cuando se incluye `row_id`;
- 736 filas duplicadas al excluir `row_id`;
- 970 repeticiones adicionales de `StudentExplanation` (2.6%);
- frases frecuentes como *because it is a whole number* o *because two negatives make a positive*.

Una repetición puede ser legítima: estudiantes distintos pueden escribir la misma respuesta breve. Sin embargo, como no existe un identificador de estudiante, tampoco puede demostrarse que las 736 coincidencias sean independientes. Se conservan para respetar la unidad original, pero una futura validación debe evitar que copias idénticas queden a ambos lados de la partición.

5.3 Calidad y convenciones del texto

El corpus es informal, pero no está vacío ni corrupto. Las faltas ortográficas, minúsculas y expresiones improvisadas forman parte de la señal observada; no obstante, una fracción de esos rasgos fue inducida

Cuadro 5.2: Indicadores de calidad de `StudentExplanation`.

Indicador	**Proporción**
Empieza en minúscula	62.8%
Contiene dígitos	78.3%
Contiene barra "/"	27.2%
Contiene signo "="	15.9%
Tiene menos de 3 palabras	0.1%
Contiene LaTeX	0.0%
`MC_Answer` contiene LaTeX	96.0%
`QuestionText` contiene descripción de imagen	23.6%

durante el aumento sintético descrito por Rittle-Johnson et al. (2025). El contenido matemático aparece tanto en palabras como en números y símbolos.

5.4 Decisiones de transformación

Cuadro 5.3: Plan de limpieza y justificación.

Situación	**Decisión**	**Justificación**
Nulos estructurales	Reemplazar por `NA`	Conserva la semántica y el formato objetivo.
Textos y registros repetidos	Conservar y auditar la partición	Pueden ser respuestas legítimas, pero no deben causar fuga.
LaTeX en la opción	Convertir fracciones a texto plano	Homogeneiza `\frac{1}{3}` y `1/3`.
Mayúsculas inconsistentes	Minusculizar la explicación	Reduce variantes sin cambiar la operación matemática.
Dígitos y símbolos	Conservar	Son la señal matemática principal.
Ortografía estudiantil	No corregir automáticamente	Una corrección puede cambiar términos, números o pistas propias de la concepción errónea.
Descripciones de imágenes	Conservar como texto	La imagen original no está disponible; la descripción es el único contexto visual.
Espacios repetidos	Colapsar	Evita tokens vacíos sin pérdida semántica.

6

Análisis exploratorio

6.1 Variables categóricas

6.1.1 Distribución de `Category`

Cuadro 6.1: Frecuencia y proporción de las categorías.

Categoría	Frecuencia	Proporción
`True_Correct`	14,802	40.34%
`False_Misconception`	9,457	25.77%
`False_Neither`	6,542	17.83%
`True_Neither`	5,265	14.35%
`True_Misconception`	403	1.10%
`False_Correct`	227	0.62%

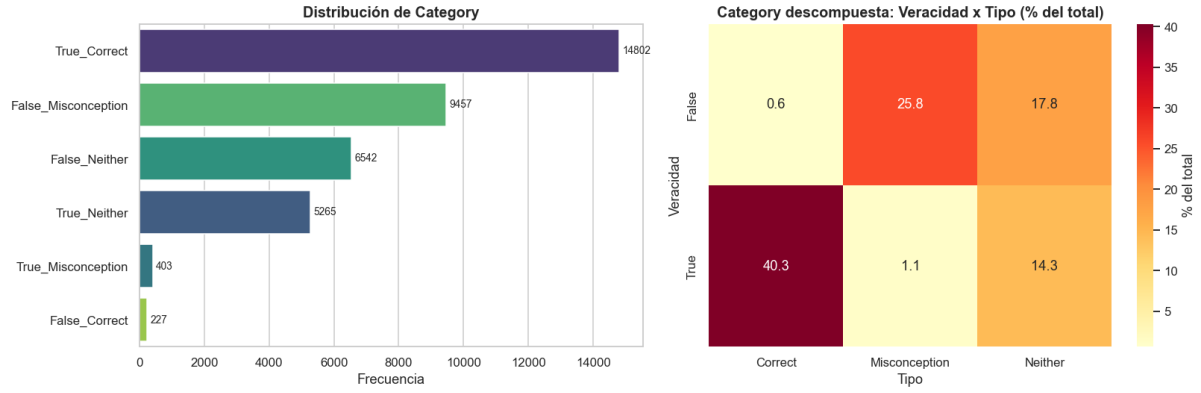


Figura 6.1: Distribución de `Category` y descomposición entre veracidad y tipo de razonamiento. Figura extraída de la salida almacenada del notebook.

El 55.78% de las opciones seleccionadas es verdadero y el 44.22% falso. Al agrupar por calidad de explicación, 40.96% es `Correct`, 32.18% `Neither` y 26.87% `Misconception`. La diferencia entre estas dimensiones demuestra que acertar la opción no equivale a razonar correctamente.

6.1.2 Concepciones erróneas y etiqueta compuesta

Hay 9,860 observaciones con una concepción errónea, distribuidas entre 35 clases. Las más frecuentes se presentan en la Tabla 6.2.

Cuadro 6.2: Quince concepciones erróneas más frecuentes.

Concepción	**Frecuencia**	**% entre concepciones**
Incomplete	1,454	14.75%
Additive	929	9.42%
Duplication	704	7.14%
Subtraction	620	6.29%
Positive	566	5.74%
Wrong_term	558	5.66%
Irrelevant	497	5.04%
Wrong_fraction	418	4.24%
Inversion	414	4.20%
Mult	353	3.58%
Denominator-only_change	336	3.41%
Whole_numbers_larger	329	3.34%
Adding_across	307	3.11%
WNB	299	3.03%
Tacking	290	2.94%

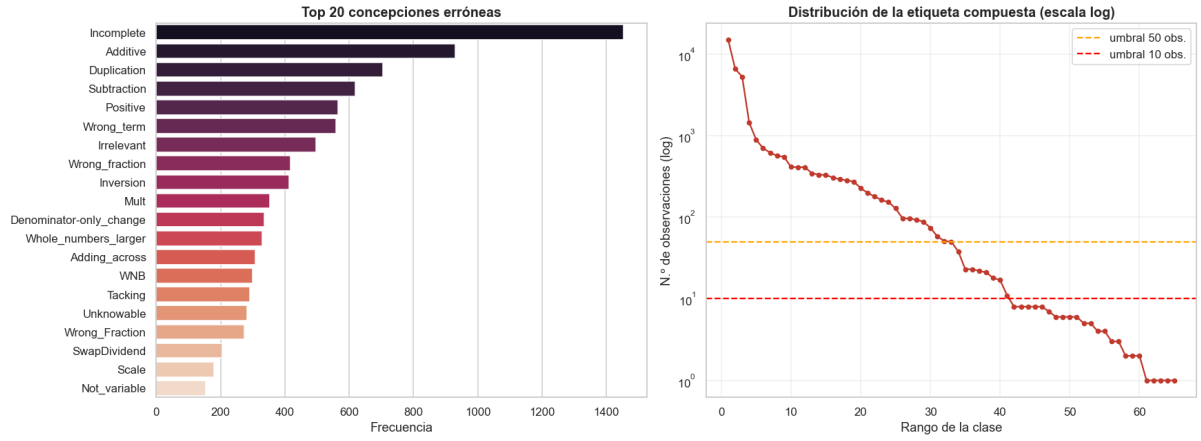


Figura 6.2: Concepciones erróneas más frecuentes y cola larga de las 65 etiquetas compuestas. Las líneas horizontales marcan 50 y 10 observaciones.

La clase mayoritaria `True_Correct:NA` tiene 14,802 registros. En el extremo contrario, la clase compuesta menos frecuente tiene un solo ejemplo. Treinta y dos clases (49.2%) tienen menos de 50 observaciones y 24 (36.9%) menos de 10. Predecir siempre la clase mayoritaria produciría aproximadamente 40% de exactitud, por lo que esa métrica aislada sería engañosa.

Cola larga

Las clases con menos de 10 casos no pueden dividirse de manera estable entre entrenamiento y validación. Cualquier resultado agregado debe acompañarse de soporte por clase y cobertura; sobremuestrear no crea diversidad lingüística nueva y puede aumentar la memorización.

6.2 Variables cuantitativas derivadas del texto

Debido a que la base no contiene medidas numéricas nativas, se construyeron características que describen forma y contenido de la explicación.

Cuadro 6.3: Variables cuantitativas derivadas.

Variable	Definición
`n_chars`	Número de caracteres de la explicación normalizada.
`n_words`	Número de palabras o tokens separados por espacios.
`n_unique_w`	Número de palabras distintas.
`avg_token_len`	Longitud media de los tokens separados por espacios; incluye signos adheridos al token.
`lex_diversity`	Cociente entre palabras distintas y palabras totales.
`n_digits`	Cantidad de dígitos.
`digit_ratio`	Proporción de caracteres que son dígitos.
`n_math_sym`	Conteo de símbolos como $+$, $-$, $*$, $/$, $=$, $<$, $>$ y %.
`n_sentences`	Aproximación al número de segmentos u oraciones.

Cuadro 6.4: Resumen estadístico de las variables derivadas.

Variable	Media	DE	Mín.	Q1	Mediana	Q3	Máx.	IQR	CV	Asimetría
n_chars	69.78	38.44	1.00	43.00	60.00	86.00	586.00	43.00	0.55	1.89
n_words	15.36	8.12	1.00	10.00	13.00	19.00	177.00	9.00	0.53	1.87
n_unique_w	13.51	6.22	1.00	9.00	12.00	17.00	125.00	8.00	0.46	1.56
avg_token_len	3.64	0.68	1.00	3.20	3.62	4.00	14.83	0.80	0.19	0.84
lex_diversity	0.91	0.09	0.39	0.85	0.92	1.00	1.00	0.15	0.10	-0.58
n_digits	4.72	4.61	0.00	1.00	4.00	7.00	101.00	6.00	0.98	1.63
digit_ratio	0.07	0.07	0.00	0.02	0.06	0.11	0.78	0.09	0.96	1.34
n_math_sym	1.01	1.66	0.00	0.00	0.00	2.00	50.00	2.00	1.64	2.92
n_sentences	1.11	0.41	1.00	1.00	1.00	1.00	11.00	0.00	0.37	5.23

La mediana es de 13 palabras y 60 caracteres, frente a máximos de 177 palabras y 586 caracteres. La diferencia entre media y mediana, junto con asimetrías de 1.89 y 1.87, confirma cola derecha. La mediana de símbolos matemáticos es cero, aunque una minoría concentra muchos. La aproximación revisada de `n_sentences` separa únicamente puntuación terminal seguida de espacio o fin de texto: su máximo es 11 y su mediana es 1. Sigue siendo una variable heurística, por lo que debe interpretarse con cautela.

6.3 Longitud y tipo de razonamiento

Los razonamientos correctos tienden a ser más extensos, posiblemente porque describen un procedimiento. Las explicaciones `Neither` son más cortas y con frecuencia no aportan evidencia evaluable. No obstante,

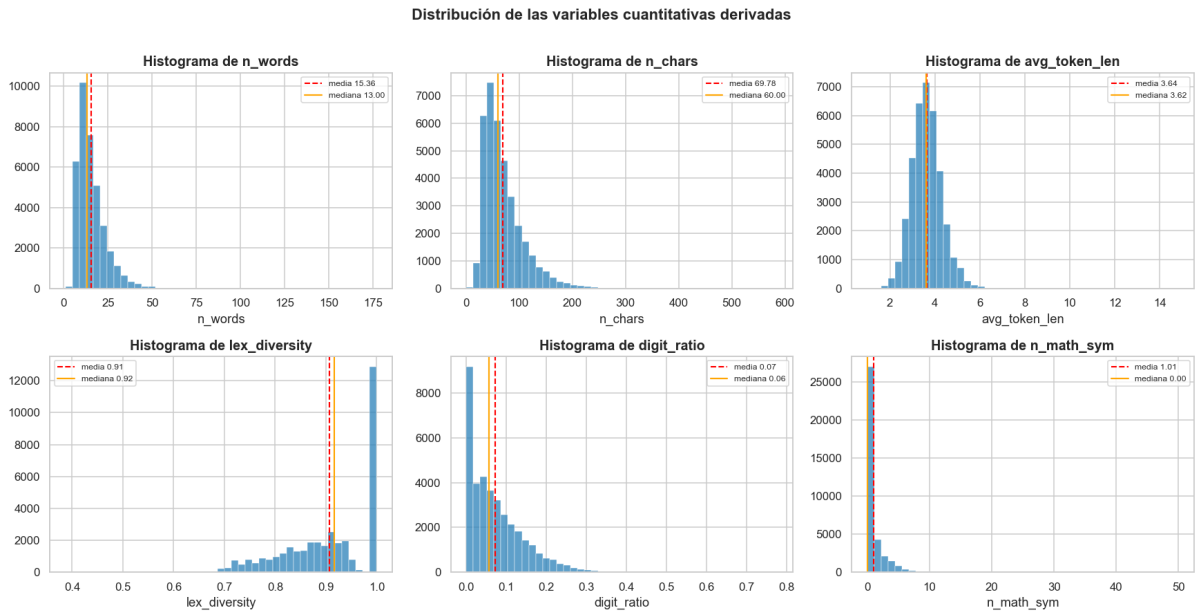


Figura 6.3: Histogramas de seis variables cuantitativas derivadas. Las explicaciones son cortas y las medidas de longitud presentan cola derecha.

Cuadro 6.5: Longitud de explicación por categoría.

Categoría	**Media**	**Mediana**	**DE**
False_Correct	18.55	17	8.23
True_Correct	17.62	16	9.03
True_Misconception	16.40	15	8.90
False_Misconception	14.80	13	6.86
True_Neither	13.04	11	7.38
False_Neither	12.74	11	6.53

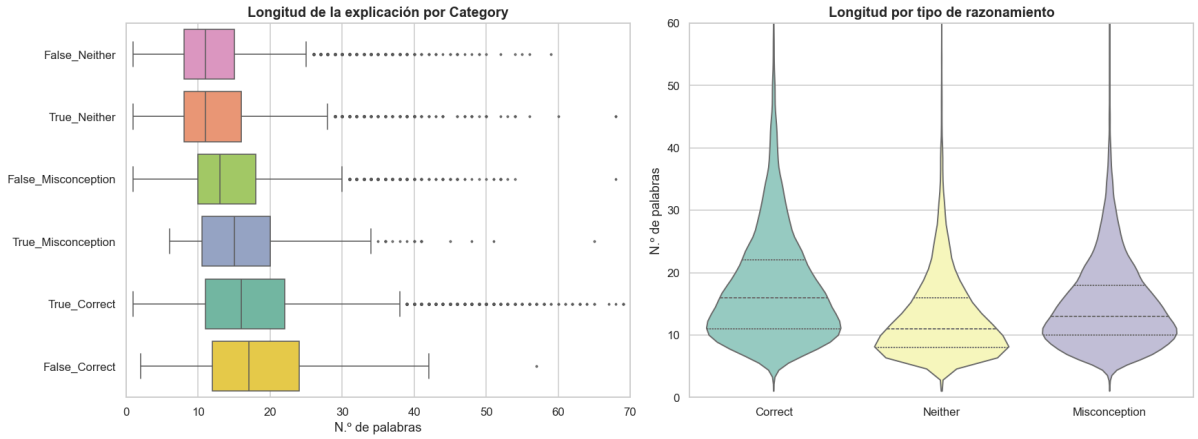


Figura 6.4: Diagramas de caja y violín para la longitud de la explicación. Las medianas por tipo son 16 palabras para `Correct`, 13 para `Misconception` y 11 para `Neither`.

las distribuciones se solapan ampliamente: la longitud es una característica auxiliar, no una regla de clasificación.

6.4 Valores atípicos

El criterio de rango intercuartílico $1.5 \times IQR$ identificó los siguientes extremos:

Cuadro 6.6: Atípicos según el criterio IQR.

Variable	Límite inferior	Límite superior	Atípicos	Proporción
n_chars	-21.50	150.50	1,556	4.24%
n_words	-3.50	32.50	1,499	4.08%
n_unique_w	-3.00	29.00	815	2.22%
avg_token_len	2.00	5.20	851	2.32%
lex_diversity	0.62	1.23	12	0.03%
n_digits	-8.00	16.00	742	2.02%
digit_ratio	-0.12	0.25	831	2.26%
n_math_sym	-3.00	5.00	882	2.40%
n_sentences	1.00	1.00	3,097	8.44%

Una explicación larga puede ser un procedimiento detallado y una explicación muy corta puede indicar respuesta mínima o ausencia de razonamiento. Hay 30 observaciones con dos palabras o menos (0.08%). También existe al menos una explicación de 177 palabras con contenido que parece una secuencia extensa de símbolos y asociaciones, por lo que no todos los extremos deben describirse automáticamente como alta calidad. La inspección contextual es necesaria.

Tratamiento de atípicos

No se eliminan solo por superar el umbral IQR. En texto humano, la longitud extrema puede ser señal predictiva. Para modelar conviene transformar `n_words` con $\log(1 + x)$, limitar la influencia numérica si fuera necesario y auditar manualmente los casos más extremos.

6.5 Correlaciones

Se utiliza Spearman porque las variables son asimétricas y las relaciones pueden ser monótonas sin ser lineales.

Los pares más correlacionados son `n_words` con `n_unique_w` ($\rho = 0.981$), `n_chars` con `n_words` ($\rho = 0.951$) y `n_chars` con `n_unique_w` ($\rho = 0.945$). `n_digits` y `digit_ratio` alcanzan $\rho = 0.894$. La diversidad léxica tiene correlación negativa moderada con el número de palabras ($\rho \approx -0.59$), en parte porque repetir alguna palabra se vuelve más probable conforme crece el texto.

Redundancia

Incluir caracteres, palabras y palabras únicas simultáneamente aportaría información muy similar. Una alternativa parsimoniosa es conservar `n_words`, una medida normalizada como `digit_ratio` y banderas matemáticas específicas.

6.6 Cruces entre pregunta, respuesta y etiqueta

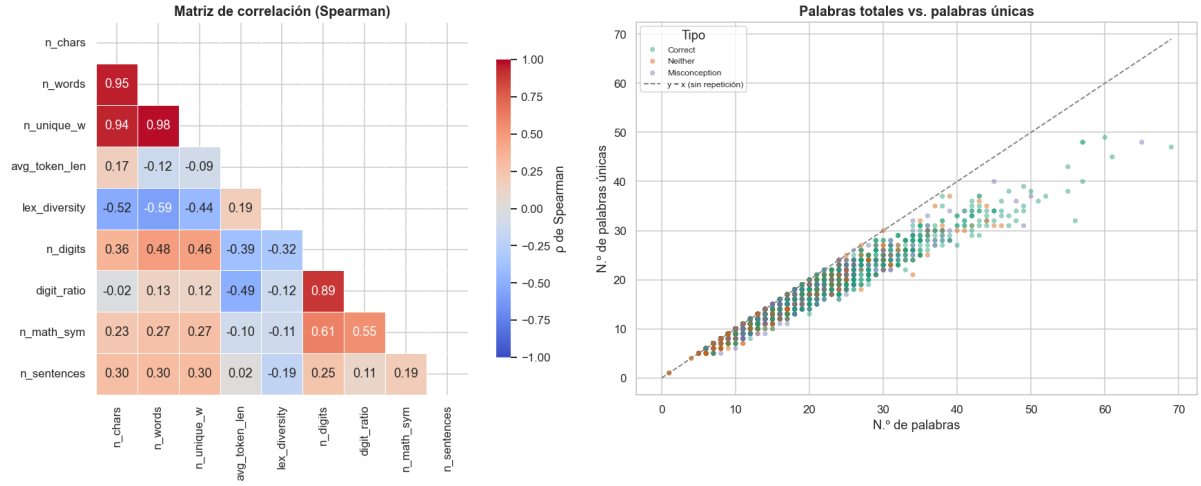


Figura 6.5: Matriz de correlaciones de Spearman y relación entre palabras totales y palabras únicas.

6.6.1 Dificultad heterogénea

Las 15 preguntas contienen entre 673 y 4,857 observaciones. La tasa de acierto varía entre 35.7% y 79.6%, con media no ponderada de 56.7%. Por ello, `QuestionId` contiene información contextual y de dificultad; no debe interpretarse como una cantidad continua.

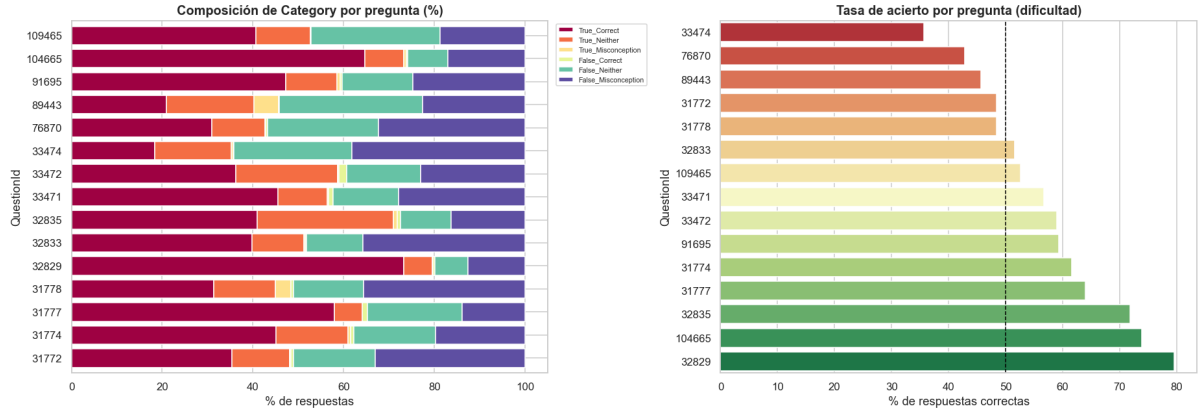


Figura 6.6: Composición de las categorías y tasa de acierto para cada pregunta. La línea vertical discontinua marca 50% de respuestas correctas.

La variabilidad se observa tanto en el acierto como en la proporción de `Neither` y `Misconception`. Una pregunta difícil no solo genera más respuestas falsas; puede inducir patrones de error distintos.

6.6.2 Concepciones ligadas a la pregunta

De las 35 concepciones erróneas, 32 aparecen en una sola pregunta, dos en dos preguntas y una en tres preguntas. Solo `Incomplete`, `Irrelevant` y `WNB` se describen como transversales. El 91% de las concepciones es, por tanto, exclusivo de un contexto local.

Esto crea dos escenarios de validación:

1. Una partición aleatoria conserva las mismas preguntas a ambos lados y estima desempeño en preguntas conocidas, pero puede premiar la memorización pregunta–etiqueta.
2. Una partición agrupada por `QuestionId` evalúa preguntas nuevas, pero deja fuera del entrenamiento

casi todas las concepciones que aparecen en validación; muchas resultan imposibles de predecir por construcción.

Con solo 15 preguntas, ninguno de los dos esquemas por sí solo describe toda la capacidad del sistema.

6.6.3 Veracidad casi determinista

Existen 60 combinaciones de pregunta y opción. En 58, la veracidad es única. Las dos excepciones pertenecen a la pregunta 31778:

Cuadro 6.7: Pares ambiguos de pregunta y respuesta.

Pregunta	Opción	True	False
31778	6	1,749	6
31778	9	12	138

Las minorías pueden representar ruido de etiquetado o una ambigüedad de anotación. En cualquier caso, la veracidad se resuelve casi por completo con una tabla de consulta; el NLP debe concentrarse en la calidad y naturaleza del razonamiento.

6.7 Contenido léxico

Una representación TF–IDF con unigramas y bigramas, vocabulario máximo de 3,000 términos y frecuencia mínima de cinco produce una matriz de 36,696 por 3,000 con densidad de 0.332%. La dispersión es esperable en textos de mediana 13 palabras.

Los términos almacenados como característicos incluyen *divided*, *times* y expresiones numéricas para *Correct*; *not shaded*, *positive* y *add* para `Misconception`; y *worked out*, *guess*, *sure*, *don't know* o *explain* para `Neither`.

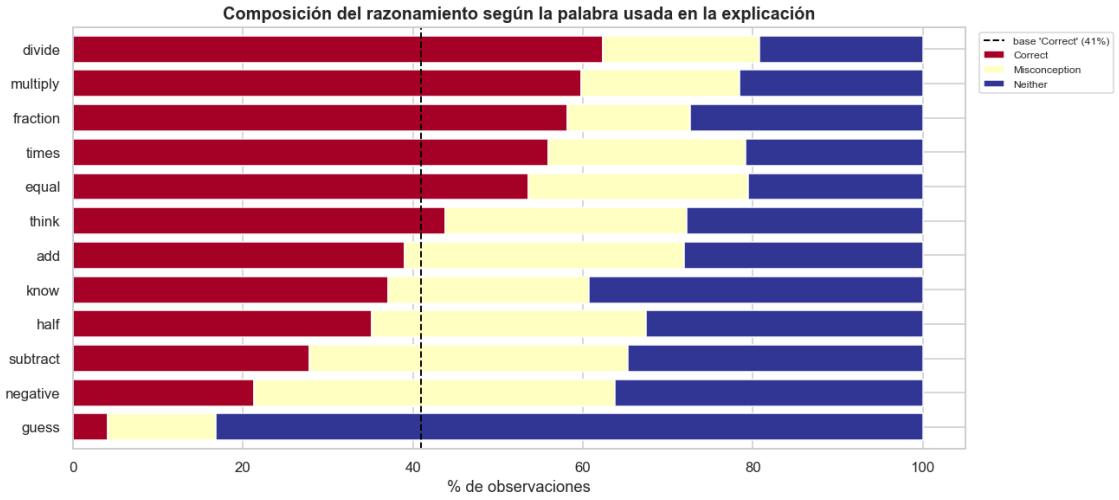


Figura 6.7: Composición del tipo de razonamiento condicionada a palabras seleccionadas. La línea discontinua representa la tasa base de razonamientos correctos.

Divide, *multiply*, *fraction*, *times* y *equal* se asocian con una proporción de razonamiento correcto superior a la base; *guess* se concentra claramente en `Neither`. Sin embargo, algunas palabras también identifican la pregunta concreta. El poder aparente del vocabulario debe comprobarse con una validación que separe contexto de generalización.

7

Implicaciones para validación y modelado

7.1 Amenazas de fuga de información

La repetición de preguntas, opciones y algunas explicaciones puede inflar una partición aleatoria. Una predicción correcta no demuestra comprensión si el modelo aprendió que cierta opción de cierta pregunta suele acompañarse de una etiqueta específica. Deben distinguirse tres fuentes de señal:

1. **Regla del ítem:** `QuestionId + MC_Answer` determina la veracidad en 96.7% de los pares distintos.
2. **Inventario local:** la pregunta restringe las concepciones plausibles.
3. **Lenguaje del razonamiento:** palabras, operaciones y expresiones distinguen cómo llegó el estudiante a la respuesta.

Un sistema útil puede explotar las tres, pero su evaluación debe indicar qué tipo de generalización mide.

7.2 Propuesta de validación doble

Cuadro 7.1: Esquemas complementarios de validación.

Esquema	Qué estima	Limitación
`StratifiedKFold` sobre etiqueta compuesta	Desempeño en preguntas y clases ya conocidas	Puede beneficiarse de memorizar pregunta, opción o texto repetido.
`GroupKFold` por `QuestionId`	Transferencia a preguntas nuevas	El 91% de concepciones del pliegue puede no existir en entrenamiento.
Agrupación adicional de duplicados	Robustez ante textos idénticos	Reduce ligeramente el tamaño útil y requiere definir una clave de grupo.

La distancia entre los dos primeros resultados es un hallazgo, no un error: cuantifica cuánto depende el sistema de preguntas conocidas.

7.3 Arquitectura jerárquica propuesta

1. **Etapa 1: veracidad.** Usar el par `(QuestionId, MC_Answer)` y tratar explícitamente los dos pares ambiguos.

2. **Etapa 2: tipo.** Clasificar la explicación como `Correct`, `Misconception` o `Neither`, combinando texto, pregunta y opción.
3. **Etapa 3: concepción.** Si el tipo es `Misconception`, ordenar las concepciones plausibles. Para preguntas conocidas puede restringirse el inventario; para preguntas nuevas debe mantenerse una ruta abierta o taxonomía más general.
4. **Composición.** Convertir las probabilidades en tres etiquetas `Category:Misconception` ordenadas para MAP@3.

7.4 Línea base e ingeniería de características

Antes de un transformador, se recomienda establecer TF–IDF de unigramas y bigramas con regresión logística. La línea base debe integrar texto de la pregunta, opción normalizada y explicación, distinguiendo cada campo con prefijos. Como variables auxiliares pueden incluirse:

- $\log(1 + \texttt{n_words})$;
- `digit_ratio`;
- presencia de fracción y operadores;
- dificultad estimada de la pregunta, calculada solo con el pliegue de entrenamiento;
- longitud relativa frente a otras explicaciones de la misma pregunta.

No conviene incluir simultáneamente todas las medidas de longitud por su alta correlación. Para la cola larga pueden evaluarse pesos de clase, agrupaciones pedagógicamente justificadas o recuperación de candidatos; un simple sobremuestreo duplica ejemplos, pero no añade variación lingüística.

8

Hallazgos, conclusiones y recomendaciones

8.1 Síntesis de hallazgos

Cuadro 8.1: Hallazgos principales y consecuencias.

N.º	Hallazgo	Evidencia	Consecuencia
1	Los nulos son estructurales	Correspondencia perfecta con tipo `Misconception`	Codificar `NA`; no imputar.
2	Hay repeticiones que requieren cautela	736 duplicados sin `row_id`; 970 textos repetidos	Conservar, pero agrupar copias en la validación.
3	El texto es informal y matemático	62.8% inicia en minúscula; 78.3% tiene dígitos	No eliminar números ni símbolos.
4	`Category` cruza dos dimensiones	Veracidad por tipo de razonamiento	Favorece clasificación jerárquica.
5	Existe desbalance extremo	32/65 clases con menos de 50 casos; 24 con menos de 10	Usar MAP@3, soporte por clase y estrategias de cola larga.
6	La longitud discrimina débilmente	Medianas 16, 13 y 11 palabras	Usarla como variable auxiliar, no como regla.
7	Los atípicos pueden ser informativos	4.08% de atípicos en palabras por IQR	Auditar y transformar; no eliminar automáticamente.
8	Las longitudes son redundantes	Correlaciones de Spearman superiores a 0.94	Elegir representación parsimoniosa.
9	La dificultad cambia por pregunta	Acierto entre 35.7% y 79.6%	Tratar `QuestionId` como contexto categórico.
10	Las concepciones están ligadas al ítem	32/35 aparecen en una pregunta	La validación debe separar preguntas conocidas y nuevas.
11	La veracidad es casi determinista	58/60 pares pregunta–opción sin ambigüedad	Separar veracidad del análisis del razonamiento.
12	El vocabulario contiene señal	TF–IDF de 3,000 términos y asociaciones interpretables	Línea base clásica viable antes de transformadores.

8.2 Conclusiones

1. El conjunto tiene una estructura clara y no presenta ausencias reales en las variables obligatorias. La principal tarea de limpieza es interpretar correctamente los nulos, normalizar convenciones y conservar

la notación matemática.

2. La procedencia es mixta: el benchmark completo incluye 27% de explicaciones aumentadas y los archivos no permiten distinguirlas. Por ello, la calidad textual no puede atribuirse exclusivamente a estudiantes.
3. La etiqueta no representa un único fenómeno. Separa la corrección de la opción y la calidad del razonamiento, lo que permite detectar aciertos casuales y errores finales de cálculo.
4. El desbalance es suficientemente severo para invalidar una lectura basada solo en exactitud. La cola larga debe analizarse con soporte, métricas de ranking y resultados desagregados.
5. La explicación contiene señal útil: longitud, símbolos y vocabulario cambian entre tipos de razonamiento. Sin embargo, ninguna característica superficial basta por sí sola y los grupos se solapan.
6. La amenaza principal a la validez es la dependencia entre pregunta y concepción. Un buen resultado aleatorio puede reflejar memorización; un resultado por pregunta puede penalizar clases nunca observadas.
7. La veracidad puede resolverse casi por completo sin NLP, mientras que interpretar el razonamiento y asignar la concepción específica concentra la dificultad científica.
8. Una línea base TF–IDF más regresión logística, evaluada con dos esquemas de validación, ofrece el punto de comparación necesario antes de modelos contextuales más costosos.

8.3 Recomendaciones y próximos pasos

1. Corregir la ruta de datos del notebook y ejecutar posteriormente una prueba de reproducibilidad en un ambiente limpio, registrando versiones de dependencias y semilla aleatoria.
2. Revisar los 736 registros idénticos sin identificador y construir grupos que impidan su separación entre entrenamiento y validación.
3. Reportar `StratifiedKFold` y `GroupKFold` por pregunta, además de MAP@3 global, soporte por clase y métricas por pregunta.
4. Construir el modelo jerárquico en etapas y comparar contra un clasificador plano de 65 clases.
5. Establecer TF–IDF con regresión logística antes de evaluar DeBERTa o un modelo especializado en lenguaje matemático.
6. Analizar manualmente errores por categoría, especialmente `True_Misconception`, `False_Correct` y clases con menos de 10 ejemplos.
7. Mantener supervisión docente: la predicción debe orientar revisión y retroalimentación, no convertirse en un diagnóstico pedagógico incuestionable.

8.4 Limitaciones

- Solo hay 15 preguntas, por lo que la variedad de conceptos y contextos es limitada.
- El archivo de prueba local contiene tres filas y no permite evaluar generalización externa.
- No existe identificador de estudiante; no se puede medir dependencia, progreso ni repetición individual.
- No existe una variable que identifique las paráfrasis sintéticas; no es posible comparar su distribución, dificultad o efecto por clase.
- Tres preguntas dependen de una descripción textual de imagen, no de la imagen original.
- Las etiquetas raras tienen soporte insuficiente para estimaciones estables.
- Los términos TF–IDF pueden reflejar el tema de la pregunta además del tipo de razonamiento.

- El análisis de este informe usa salidas almacenadas y no sustituye una futura auditoría de ejecución completa.

Cierre

La evidencia cumple el propósito exploratorio: describe variables y observaciones, justifica la limpieza, estudia categorías y medidas derivadas, analiza correlaciones y atípicos, cruza los factores esenciales y convierte los hallazgos en un plan verificable. El siguiente avance no debe comenzar por el modelo más complejo, sino por una validación honesta y una línea base interpretable.

A

Matriz de cumplimiento de la rúbrica

Cuadro A.1: Correspondencia entre los criterios de evaluación y el informe.

Criterio	**Evidencia en el documento**
Situación problemática	Capítulo 1: contexto educativo, relevancia, diferencia entre resultado y razonamiento, y valor de detectar aciertos casuales.
Problema científico	Pregunta específica y formulación formal de predictores y etiqueta en el Capítulo 1.
Objetivos	Un objetivo general y cuatro objetivos específicos medibles y alcanzables.
Investigación previa	Capítulos 2 y 3: competencia, procedencia del benchmark, anotación, aumento sintético y técnicas de NLP, con citas y referencias APA 7.
Descripción de los datos	Capítulo 4: archivos, unidad de análisis, 36,696 observaciones, siete variables, diccionario e interpretación de etiquetas.
Limpieza y preprocesamiento	Capítulo 5: ausencias estructurales, duplicados, calidad del texto y tabla de decisiones justificadas.
Estadística descriptiva	Tablas 6.1, 6.2, 6.4 y 6.5.
Gráficos exploratorios	Figuras 6.1–6.7: barras, mapa de calor, histogramas, cajas, violines, dispersión y correlación.
Correlaciones	Sección 6.5 y Figura 6.5, con elección justificada de Spearman.
Outliers	Sección 6.4 y Tabla 6.6; explicación contextual y decisión de conservación.
Variables categóricas	Frecuencias, proporciones, desbalance y cruces por pregunta en el Capítulo 6.
Hallazgos y conclusiones	Capítulo 8: síntesis de doce hallazgos, conclusiones actualizadas y próximos pasos.
Implicaciones	Capítulo 7: fuga, validación doble, arquitectura jerárquica e ingeniería de características.
Informe sin código	El cuerpo explica procedimientos y resultados sin incluir celdas de programación.

B

Notas de consistencia y reproducibilidad

Al convertir el notebook en informe se comparó la narrativa con las salidas almacenadas. Se adoptaron los siguientes valores verificables:

- asimetría de `n_chars`=1.89 y `n_words`=1.87, no valores aproximados superiores a 2;
- correlación de Spearman entre `lex_diversity` y `n_words` cercana a -0.59, no -0.85;
- densidad TF–IDF de 0.332%, según la salida de la matriz;
- tasa de acierto por pregunta entre 35.7% y 79.6%, no un rango de 20% a 85%;
- existencia de 736 duplicados al ignorar `row_id`, aunque no existan filas completas idénticas.

Estas correcciones no alteran las conclusiones centrales, pero mejoran la trazabilidad. Para una entrega definitiva se recomienda ejecutar el notebook de principio a fin después de corregir la ruta de datos y comprobar que texto, tablas y figuras se actualicen de forma automática.

Referencias

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. En *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (pp. 4171–4186). Association for Computational Linguistics. https://doi.org/10.18653/v1/N19-1423

García Pérez, L. (2026). *Guía del Proyecto 2: Análisis Exploratorio* [Guía de proyecto]. Universidad del Valle de Guatemala.

Grupo 1, Sección 10. (2026). *Proyecto 2: MAP – Charting Student Math Misunderstandings* [Repositorio de GitHub]. GitHub. https://github.com/DanielBarillasM/Proyecto-2_Grupo-1_DS_Sec-10

He, P., Liu, X., Gao, J., & Chen, W. (2021). DeBERTa: Decoding-enhanced BERT with disentangled attention. En *International Conference on Learning Representations*. https://openreview.net/forum?id=XPZIaotutsD

Imran, M., & Bulathwela, S. (2026). *The correct answer trap: Pedagogically-grounded detection and feedback for hidden misconceptions* [Trabajo de taller]. arXiv. https://arxiv.org/abs/2606.23205

King, J., Smith, K., Burleigh, L., Crossley, S., Demkin, M., & Reade, W. (2025). *MAP – Charting Student Math Misunderstandings* [Competencia de ciencia de datos]. Kaggle. https://www.kaggle.com/competitions/map-charting-student-math-misunderstandings

Otero, N., Druga, S., & Lan, A. (2025). A benchmark for math misconceptions: Bridging gaps in middle school algebra with AI-supported instruction. *Discover Education, 4*, artículo 277. https://doi.org/10.1007/s44217-025-00742-w

Rittle-Johnson, B., Adler, R., Durkin, K., Burleigh, L., King, J., & Crossley, S. (2025). Detecting math misconceptions: An AI benchmark dataset. En *Proceedings of the Artificial Intelligence in Measurement and Education Conference (AIME-Con): Works in Progress* (pp. 20–24). National Council on Measurement in Education. https://aclanthology.org/2025.aimecon-wip.3/

Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management, 24*(5), 513–523. https://doi.org/10.1016/0306-4573(88)90021-0

Shen, J. T., Yamashita, M., Prihar, E., Heffernan, N., Wu, X., Graff, B., & Lee, D. (2021). *MathBERT: A pre-trained language model for general NLP tasks in mathematics education* [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2106.07340

The Learning Agency. (2025, 12 de noviembre). *Case study: Math misconceptions competition.* the-learning-agency.com/the-cutting-ed/

Fin del informe