Universidad del Valle de Guatemala
Facultad de Ingeniería
Departamento de Ciencias de la Computación

Proyecto 2 – Aprendizaje automático

Revisión bibliográfica y selección preliminar de modelos

Identificación de errores conceptuales matemáticos en explicaciones estudiantiles mediante NLP

Caso de estudio:	MAP – Charting Student Math Misunderstandings
Curso:	CC3084 – Data Science
Docente:	Lynette García Pérez
Grupo y sección:	Grupo 1, sección 10
Integrantes:	Jorge Gabriel Palacios Sales Pablo Daniel Barillas Moreno Roberto Emiliano Otoniel Camposeco Torres Abby Sofia Donis Agreda
Área:	Procesamiento del Lenguaje Natural y analítica educativa

Guatemala, agosto de 2026

Resumen

Este documento revisa la literatura sobre calificación automática de respuestas cortas, clasificación de explicaciones estudiantiles y detección de errores conceptuales, con énfasis en modelos aplicables al reto *MAP – Charting Student Math Misunderstandings*. El corpus local analizado contiene 36,696 explicaciones asociadas con 15 preguntas, 49 opciones distintas, 35 concepciones erróneas y 65 etiquetas compuestas. Esta combinación hace que el problema no sea una simple clasificación de texto: la interpretación depende de la pregunta, la respuesta seleccionada, la corrección matemática y la distribución de clases de cola larga.

La evidencia revisada muestra una evolución desde similitud léxica, ingeniería de características y máquinas de vectores de soporte, hacia redes recurrentes, Transformers ajustados y adaptación de dominio. Los hallazgos convergen en cuatro ideas: (a) los modelos lineales con TF–IDF siguen siendo líneas base competitivas, baratas e interpretables; (b) incluir la pregunta y el contexto supera el uso aislado de la respuesta; (c) los Transformers capturan paráfrasis y relaciones semánticas, pero requieren validación estricta y control de sesgos; y (d) la adaptación al dominio y los ensambles híbridos suelen mejorar la robustez cuando el corpus etiquetado es limitado o desbalanceado.

Se selecciona preliminarmente una estrategia de cuatro niveles. Primero, un baseline de TF–IDF de palabras y caracteres con regresión logística y SVM lineal. Segundo, un modelo principal basado en DeBERTa/BERT que reciba conjuntamente pregunta, opción y explicación, con cabezas jerárquicas para `Category` y `Misconception`. Tercero, adaptación de dominio mediante preentrenamiento continuado o MathBERT. Cuarto, un ensamble calibrado que produzca las tres parejas `Category:Misconception` mejor posicionadas, coherente con MAP@3. Los LLM generativos se reservan como comparación y herramienta de auditoría, no como solución primaria, por reproducibilidad, costo, privacidad y trazabilidad.

Decisión preliminar

La ruta recomendada es **baseline lineal híbrido → Transformer contextual y multitarea → adaptación de dominio → ensamble y ranking top–3**. La evaluación debe comparar una partición estratificada para preguntas conocidas con otra agrupada por `QuestionId` para transferencia; ambas deben reportar MAP@3, macro F1, desempeño por clase/pregunta y calibración.

Alcance y trazabilidad

Elemento	Tratamiento en este informe
Revisión bibliográfica	Artículos de revistas arbitradas e indexadas como corpus principal; trabajos fundacionales de conferencia o preprint se identifican como fuentes complementarias.
Norma de citación	Citas autor–fecha en el cuerpo y referencias finales en estilo APA, séptima edición.
Selección preliminar	Algoritmos, arquitectura, variables de entrada, validación, métricas, riesgos y criterios de descarte.
Datos del proyecto	Resultados ya obtenidos en el análisis exploratorio; el notebook no fue reejecutado para preparar este documento.
Límite	No se reportan resultados de entrenamiento. Las puntuaciones de la matriz de decisión son juicios de diseño, no métricas experimentales.

Índice

Resumen i

Alcance y trazabilidad ii

1 Planteamiento del problema 1

1.1 Contexto educativo y computacional . . . 1

1.2 Problema científico . . . 1

1.3 Objetivos . . . 2

1.3.1 Objetivo general . . . 2

1.3.2 Objetivos específicos . . . 2

2 Metodología de revisión bibliográfica 3

2.1 Alcance de la búsqueda . . . 3

2.2 Criterios de inclusión y exclusión . . . 3

2.3 Procedimiento de síntesis . . . 4

3 El caso MAP y sus requisitos de modelado 5

3.1 Unidad de análisis y variables . . . 5

3.2 Hallazgos del análisis exploratorio local . . . 5

3.3 Requisitos derivados . . . 6

4 Revisión de algoritmos y arquitecturas 8

4.1 De reglas y similitud a aprendizaje supervisado . . . 8

4.2 TF–IDF, regresión logística y SVM . . . 8

4.3 Ingeniería de características y ensambles . . . 9

4.4 Modelos recurrentes y orden de palabras . . . 9

4.5 La pregunta y el estudiante como contexto . . . 9

4.6 BERT y Transformers ajustados . . . 10

4.7 Adaptación de dominio para matemáticas . . . 10

4.8 Transferencia y aumento de datos . . . 10

4.9 Generalización a preguntas no vistas . . . 11

4.10 LLM generativos y evaluación con intervención humana 11
4.11 Confiabilidad, ataques y supervisión 11

5 Síntesis comparativa de la evidencia 12
5.1 Patrones convergentes 13
5.2 Vacíos identificados 14

6 Selección preliminar de algoritmos 15
6.1 Criterios de decisión 15
6.2 Nivel 1: baseline lineal híbrido 15
6.3 Nivel 2: Transformer contextual y multitarea 16
6.4 Nivel 3: adaptación al lenguaje matemático 16
6.5 Nivel 4: ensamble calibrado y ranking 17
6.6 Modelo no seleccionado como solución principal 17

7 Plan experimental propuesto 18
7.1 Particiones y control de fuga 18
7.2 Métricas 18
7.3 Secuencia de experimentos 19
7.4 Hiperparámetros iniciales 19
7.5 Análisis de errores y explicabilidad 20

8 Riesgos, ética y reproducibilidad 21
8.1 Sesgos y cobertura 21
8.2 Incertidumbre y supervisión 21
8.3 Privacidad y seguridad 21
8.4 Reproducibilidad 21

9 Conclusiones 22

Referencias 23

Apéndice A. Correspondencia entre evidencia y decisión 25

Apéndice B. Lista de verificación antes de entrenar 26

Índice de cuadros

2.1 Criterios aplicados en la revisión 3

3.1 Traducción de las variables de MAP a decisiones de modelado 5

5.1 Estudios de revista y aporte transferible al caso MAP 12

6.1 Matriz cualitativa de decisión (1 = desfavorable; 5 = muy favorable; Ctx. = contexto; Int. = interpretabilidad; Evid. = evidencia) 15

7.1 Hoja de ruta experimental 19

7.2 Espacio inicial de búsqueda, sujeto al presupuesto computacional 19

Índice de figuras

3.1 Distribución de etiquetas de error conceptual en el conjunto analizado. La cola larga exige métricas y estrategias sensibles a clases minoritarias. 6

3.2 Cruces por pregunta obtenidos en el análisis exploratorio. El patrón varía entre contextos y justifica comparar validación estratificada y agrupada. 6

1

Planteamiento del problema

1.1 Contexto educativo y computacional

Los errores matemáticos no son únicamente respuestas incorrectas. Con frecuencia constituyen evidencias de una regla aplicada fuera de contexto, una confusión de signos, una generalización excesiva o una representación incompleta del problema. La explicación escrita permite diferenciar un descuido de cálculo de una idea equivocada persistente. Esta distinción es pedagógicamente útil porque una retroalimentación adecuada depende de la causa del error y no solo del resultado. El análisis de errores puede convertir una respuesta fallida en evidencia del razonamiento del estudiante y en una oportunidad de aprendizaje más profundo (Rushton, 2018).

El reto MAP plantea automatizar parte de ese diagnóstico (Kaggle, 2025). A partir de una pregunta de opción múltiple, la opción elegida y una explicación breve, un sistema debe predecir la categoría de la respuesta y, cuando corresponde, el error conceptual asociado. El resultado esperado no es texto libre, sino una lista ordenada de hasta tres pares `Category:Misconception`. Por tanto, el problema combina clasificación multiclase, predicción jerárquica, ranking y procesamiento del lenguaje matemático.

Situación problemática

Revisar manualmente miles de explicaciones breves exige tiempo especializado y produce variabilidad entre evaluadores. Un clasificador confiable puede priorizar casos, sugerir etiquetas y acelerar la retroalimentación; no debe sustituir de forma ciega el juicio docente, especialmente en clases raras o explicaciones ambiguas.

1.2 Problema científico

Pregunta de investigación. ¿Qué combinación de representaciones léxicas, modelos contextuales y estrategias de adaptación al dominio permite ordenar con mayor precisión las categorías y los errores conceptuales matemáticos presentes en explicaciones estudiantiles cortas, manteniendo generalización a preguntas no vistas, reproducibilidad y trazabilidad?

La pregunta contiene cinco exigencias. Primero, comprender lenguaje informal y notación matemática. Segundo, condicionar la explicación a la pregunta y a la opción seleccionada. Tercero, aprender clases desbalanceadas. Cuarto, producir un ranking top–3 y no una sola etiqueta. Quinto, demostrar que el modelo reconoce patrones conceptuales y no memoriza identificadores o frases de una pregunta.

1.3 Objetivos

1.3.1 Objetivo general

Revisar críticamente algoritmos de aprendizaje automático aplicados a calificación automática, clasificación de respuestas cortas y detección de errores conceptuales, para seleccionar una arquitectura preliminar adecuada al reto MAP.

1.3.2 Objetivos específicos

1. Identificar familias de modelos, representaciones y esquemas de evaluación utilizados en literatura académica comparable.
2. Contrastar sus ventajas y limitaciones frente al tamaño, estructura, desbalance y dependencia contextual del corpus MAP.
3. Seleccionar líneas base, un modelo principal, alternativas de adaptación de dominio y un método de ensamble/ranking.
4. Diseñar un plan experimental que evite fuga entre preguntas y mida desempeño global, por clase y por pregunta.
5. Establecer controles de confiabilidad, explicabilidad y supervisión humana.

2

Metodología de revisión bibliográfica

2.1 Alcance de la búsqueda

La revisión es narrativa y orientada al diseño. Se priorizaron publicaciones entre 2015 y agosto de 2026 en revistas arbitradas e indexadas relacionadas con inteligencia artificial en educación, tecnologías de aprendizaje, aprendizaje interactivo, aplicaciones de IA y educación científica. Se consultaron las páginas oficiales de editoriales y los registros DOI para verificar título, año, volumen y paginación o número de artículo.

Las cadenas conceptuales de búsqueda combinaron términos como *automatic short-answer grading*, *student response classification*, *math misconception detection*, *BERT*, *Transformer*, *domain-specific pretraining*, *question context*, *augmentation*, *robustness* y *human-in-the-loop*. Se incluyeron trabajos que aportaran al menos uno de estos elementos: comparación de algoritmos, representación textual, uso de contexto, adaptación de dominio, transferencia, evaluación de generalización o análisis de confiabilidad.

2.2 Criterios de inclusión y exclusión

Cuadro 2.1: Criterios aplicados en la revisión

Dimensión	**Inclusión**	**Exclusión o uso secundario**
Tipo de fuente	Artículo completo en revista arbitrada; metadatos verificables y DOI cuando existe.	Blogs, resúmenes comerciales y repositorios sin revisión como evidencia principal.
Problema	Respuestas cortas, clasificación de razonamiento, retroalimentación o errores conceptuales.	Calificación de ensayos largos sin conexión metodológica con respuestas breves.
Método	Modelos clásicos, redes neuronales, Transformers, LLM, ensambles, adaptación y robustez.	Sistemas sin descripción suficiente del método o la evaluación.
Transferibilidad	Resultados que permitan derivar una decisión para MAP.	Cifras aisladas cuya tarea o métrica no es comparable.
Fuentes fundacionales	Conferencias arbitradas y preprints se usan para documentar BERT, DeBERTa, MathBERT y el origen del benchmark.	No se confunden con el núcleo de artículos de revista solicitado.

2.3 Procedimiento de síntesis

Para cada trabajo se registraron: tarea, datos, familia algorítmica, incorporación de contexto, métricas, aporte y limitación transferible. Después se agruparon los estudios por generación metodológica y se contrastaron con las restricciones del corpus local. Las cifras publicadas se conservan como evidencia de cada escenario, pero no se comparan directamente entre artículos porque cambian corpus, idiomas, escalas de nota y particiones.

Interpretación responsable

Una mejora de exactitud en otro conjunto no garantiza la misma mejora en MAP. La revisión sirve para formular hipótesis y reducir el espacio de búsqueda; solamente la evaluación local, con particiones sin fuga, puede confirmar la selección.

3

El caso MAP y sus requisitos de modelado

3.1 Unidad de análisis y variables

Cada observación representa una explicación estudiantil vinculada con una pregunta y una opción. La señal útil está distribuida entre variables: el texto describe el razonamiento, la opción acota el resultado elegido y la pregunta determina el significado matemático de las palabras y símbolos. Esto sugiere una entrada compuesta y no un clasificador que lea solo la explicación.

Cuadro 3.1: Traducción de las variables de MAP a decisiones de modelado

Señal	**Función**	**Tratamiento propuesto**
`QuestionId`/pregunta	Define el contexto conceptual y el vocabulario relevante.	Incorporar texto o identificador controlado; agrupar por pregunta en validación.
`AnswerText` u opción	Expresa el resultado que el estudiante defendió.	Concatenar con la explicación mediante separadores.
`StudentExplanation`	Contiene las pistas lingüísticas, operaciones y negaciones.	Conservar números, signos, fracciones y negaciones; producir representación léxica y contextual.
`Category`	Describe la clase general de corrección/atribución.	Primera cabeza de clasificación o primer nivel jerárquico.
`Misconception`	Etiqueta conceptual específica, válida solo en ciertos casos.	Segunda cabeza condicional; máscara de pérdida cuando no aplica.
Pareja de salida	Unidad evaluada y ordenada.	Probabilidad conjunta y ranking de tres candidatos.

3.2 Hallazgos del análisis exploratorio local

El análisis previo identificó 36,696 observaciones, 15 preguntas, 49 opciones distintas, 35 concepciones erróneas y 65 etiquetas compuestas. La categoría `True_Correct` representa 40.34%. La explicación típica es breve: la mediana es de 13 palabras y la media de 15.36. Además, 26,836 filas (73.1%) no contienen una etiqueta en `Misconception`; esta ausencia es principalmente estructural, porque una etiqueta específica no corresponde a todas las categorías, y no debe imputarse como si fuera un valor perdido ordinario.

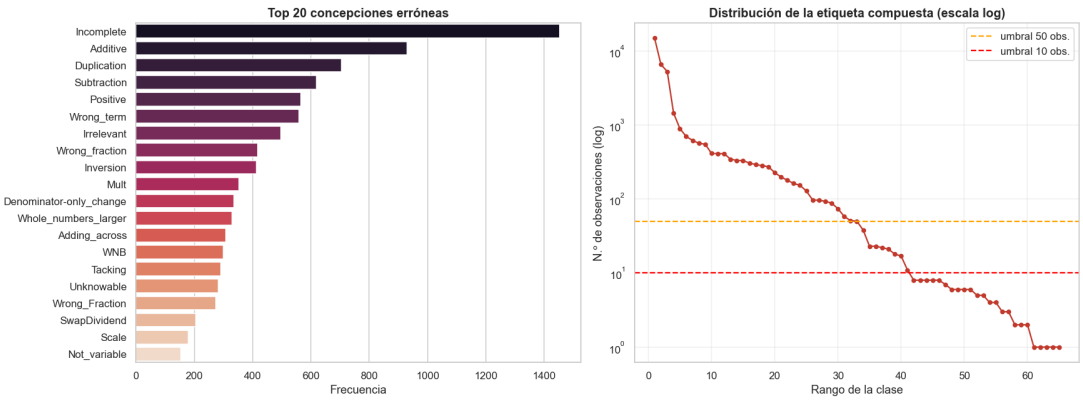


Figura 3.1: Distribución de etiquetas de error conceptual en el conjunto analizado. La cola larga exige métricas y estrategias sensibles a clases minoritarias.

La Figura 3.1 muestra que unas pocas etiquetas concentran muchas observaciones y varias poseen soporte reducido. En estas condiciones, la exactitud puede ocultar el fracaso en conceptos raros. Se requieren macro F1, recall por clase y análisis de errores, además de MAP@3.

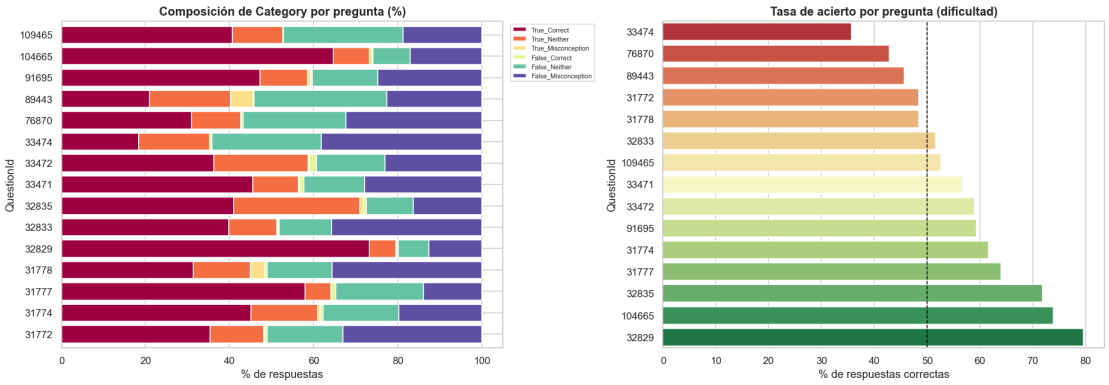


Figura 3.2: Cruces por pregunta obtenidos en el análisis exploratorio. El patrón varía entre contextos y justifica comparar validación estratificada y agrupada.

La heterogeneidad entre preguntas observada en la Figura 3.2 implica riesgo de fuga: una partición aleatoria por filas puede colocar frases muy similares de una misma pregunta en entrenamiento y validación. Un resultado alto en esa partición mediría, en parte, memorización del contexto. Por ello se propone reportar dos escenarios: estratificado por filas para preguntas conocidas y agrupado por `QuestionId` como prueba de transferencia. Debido a que 32 de las 35 concepciones son exclusivas de una pregunta, ninguno debe interpretarse de forma aislada.

3.3 Requisitos derivados

1. **Contextualidad:** interpretar explicación, pregunta y opción en conjunto.
2. **Sensibilidad matemática:** conservar símbolos, cantidades, operadores, signos y negaciones.
3. **Jerarquía:** modelar primero la categoría y después el concepto erróneo cuando corresponda.
4. **Cola larga:** ponderar clases, usar muestreo controlado y evitar que las clases frecuentes dominen la pérdida.

5. **Ranking:** calibrar probabilidades y optimizar una lista top–3.
6. **Generalización:** probar preguntas no vistas y variaciones lingüísticas.
7. **Trazabilidad:** disponer de una línea base interpretable y análisis humano de falsos positivos/negativos.

4

Revisión de algoritmos y arquitecturas

4.1 De reglas y similitud a aprendizaje supervisado

La revisión histórica de Burrows et al. (2015), que organiza más de ochenta trabajos de calificación automática de respuestas cortas, distingue una evolución desde reglas y coincidencia con respuestas modelo hacia métodos estadísticos y de aprendizaje automático. Los primeros sistemas eran transparentes, pero dependían de plantillas y vocabularios elaborados por expertos. Funcionaban mejor cuando la respuesta esperada estaba estrechamente delimitada y peor ante paráfrasis, ortografía no estándar o razonamientos novedosos.

Los métodos de similitud comparan la respuesta estudiantil con una referencia por superposición de palabras, distancia de edición, similitud coseno o recursos semánticos. Son útiles como características y como control de calidad, pero no constituyen por sí solos una solución suficiente para MAP: dos estudiantes pueden usar vocabulario parecido y defender conclusiones conceptualmente opuestas, o usar palabras distintas para expresar el mismo error.

4.2 TF–IDF, regresión logística y SVM

La representación TF–IDF asigna mayor peso a términos informativos y reduce la influencia de palabras frecuentes. Con $tf(t, d)$ como frecuencia del término t en el documento d, y N documentos, una forma común es

$$\text{tfidf}(t, d) = tf(t, d) \log\left(\frac{N + 1}{df(t) + 1}\right).$$

Sobre esta matriz dispersa, la regresión logística estima probabilidades de clase y la SVM lineal maximiza márgenes de separación. Los n-gramas de palabras capturan frases como “se cambia el signo”, mientras los n-gramas de caracteres toleran errores ortográficos y conservan fragmentos de notación. La revisión de GradeAid señala que SVM, bolsa de palabras y *word embeddings* han sido recursos muy frecuentes en ASAG; su propuesta híbrida combina TF–IDF y señales de BERT con regresores y logra errores competitivos en varios conjuntos públicos (del Gobbo et al., 2023).

Para MAP estos métodos ofrecen tres ventajas: entrenamiento rápido, coeficientes inspeccionables y un piso reproducible. Su limitación es la semántica: una bolsa de palabras no representa bien el orden, la referencia contextual o el efecto de una negación distante. Por ello deben considerarse baseline obligatorio y componente de ensamble, no única solución final.

4.3 Ingeniería de características y ensambles

Sahu y Bhowmick (2020) combinaron características léxicas, de alineamiento y semánticas mediante un esquema de regresión apilada. El ensamble mejoró la calificación automática frente a modelos individuales, lo que sugiere que ninguna representación captura por sí sola toda la evidencia de una respuesta breve. La lección transferible es conservar señales complementarias: n-gramas, longitud, coincidencias numéricas, operadores, negaciones, opción elegida y representación contextual.

En MAP un ensamble no necesita ser excesivamente complejo. Puede combinar la probabilidad calibrada del modelo lineal y la del Transformer. Si $p_L(y \mid x)$ es la distribución lineal y $p_T(y \mid x)$ la contextual, una primera formulación es

$$p_E(y \mid x) = \alpha p_T(y \mid x) + (1 - \alpha) p_L(y \mid x), \quad 0 \leq \alpha \leq 1,$$

donde α se elige exclusivamente con validación. También puede aprenderse un meta-modelo sobre predicciones *out-of-fold*; entrenarlo sobre predicciones del mismo conjunto produciría fuga.

4.4 Modelos recurrentes y orden de palabras

Las redes LSTM modelan secuencias y mitigan parte del desvanecimiento del gradiente de RNN simples. Zhang et al. (2022) propusieron un modelo para preguntas semiabiertas que integra información general y específica del dominio con LSTM. Su evaluación, basada en más de 16,000 respuestas de siete preguntas, respalda la utilidad de conservar orden y contexto. Sin embargo, las LSTM procesan tokens secuencialmente y suelen depender más de la cantidad de datos etiquetados que un Transformer preentrenado.

Se mantendría una BiLSTM como ablación si el costo lo permite, pero no es la primera candidata: el corpus MAP posee textos cortos y suficientes señales para comparar un baseline lineal fuerte con un Transformer. Esa comparación responde mejor a la pregunta práctica de cuánto valor aporta la contextualización moderna.

4.5 La pregunta y el estudiante como contexto

Zhang et al. (2020) demostraron que combinar modelos de la pregunta y del estudiante puede mejorar métodos basados únicamente en la respuesta. Aunque su arquitectura utiliza una red de creencia profunda, el aporte más relevante para MAP es conceptual: la misma frase cambia de interpretación según el enunciado y el historial o contexto disponible.

MAP no proporciona necesariamente una secuencia longitudinal completa por estudiante, pero sí ofrece `QuestionId` y opción. En consecuencia, se puede preservar la idea mediante una entrada estructurada:

```
[PREGUNTA] texto o identificador [SEP] [OPCIÓN] respuesta elegida [SEP]
                [EXPLICACIÓN] razonamiento estudiantil
```

El identificador no debe convertirse en un atajo. Cuando el texto completo de la pregunta esté disponible, es preferible porque ofrece significado transferible. Si solo existe el ID, debe comprobarse el desempeño en preguntas no vistas y considerarse una codificación “desconocida”.

4.6 BERT y Transformers ajustados

BERT aprende representaciones bidireccionales mediante preentrenamiento con texto no etiquetado y después se ajusta a una tarea supervisada (Devlin et al., 2019). Zhu et al. (2022) combinaron BERT, BiLSTM, redes cápsula y una función de pérdida específica, superando métodos previos en conjuntos de referencia de ASAG. El resultado apoya la capacidad de los Transformers para reconocer equivalencia semántica con pocos ejemplos en comparación con redes entrenadas desde cero.

La revisión de Morley et al. (2026) sobre los años fundacionales de Transformers en calificación automática de respuestas científicas encontró que BERT y sus variantes son la familia predominante y que el contexto de pregunta, rúbrica o material de apoyo puede mejorar el sistema. Al mismo tiempo, la revisión señala problemas pendientes de confiabilidad, explicación y sesgo. Por ello no basta con reportar una métrica agregada.

DeBERTa modifica la atención y la codificación posicional mediante atención desentrelazada y un decodificador mejorado (He et al., 2021). Se propone como candidato principal por su fortaleza general en clasificación, pero debe compararse con BERT/RoBERTa bajo el mismo presupuesto. La elección definitiva no se realizará por popularidad, sino por MAP@3, macro F1, estabilidad entre semillas y costo.

4.7 Adaptación de dominio para matemáticas

El lenguaje matemático escolar contiene expresiones y símbolos cuya distribución difiere del texto general. MathBERT fue preentrenado sobre material de educación matemática y mostró la viabilidad de especializar un Transformer para tareas del dominio (Shen et al., 2021). Como se trata de un preprint, se utiliza como fuente arquitectónica complementaria y no como evidencia principal de revista.

La evidencia indexada de Bonthu et al. (2024) es más generalizable: su marco PyDSBERT construye un corpus no etiquetado del dominio, continúa el preentrenamiento y ajusta el modelo a calificación. En su escenario reportó 88.77% de exactitud y 91.59% de F1, con mejoras de varios puntos sobre referencias. Estas cifras no se trasladan directamente a MAP, pero justifican probar *domain-adaptive pretraining* cuando exista texto matemático adicional y el presupuesto lo permita.

Wang et al. (2025) extendieron BERT con una perspectiva ontológica para clasificar niveles de experiencia científica. Su combinación de conocimiento de dominio, balanceo y evaluación mediante F1, exactitud y kappa ponderado confirma que la estructura conceptual puede complementar la representación contextual. Para MAP, la taxonomía de errores puede actuar como conocimiento: descripciones de las etiquetas, relaciones entre conceptos y restricciones de compatibilidad con la pregunta pueden alimentar un clasificador o un re-ranker.

4.8 Transferencia y aumento de datos

Bonthu et al. (2023) ajustaron modelos de oraciones y aplicaron reemplazo de sinónimos e intercambio aleatorio; reportaron aumentos de 4.91% en exactitud y 3.36% en F1 en su tarea. La transferencia es atractiva para clases raras, pero el aumento debe respetar la semántica matemática. Cambiar un número, signo, operador o negación puede alterar la etiqueta correcta. En lugar de aumentos ciegos se recomiendan transformaciones conservadoras: correcciones ortográficas ver-

ificadas, variantes de puntuación, espacios alrededor de operadores y paráfrasis revisadas por una persona con conocimiento matemático.

4.9 Generalización a preguntas no vistas

Padó et al. (2024) observaron que los Transformers eran robustos cuando las respuestas se parecían al dominio visto, pero no superaron necesariamente modelos lingüísticos diseñados a mano en tareas con preguntas no vistas. Este hallazgo es central para MAP: un modelo puede parecer preciso en una división aleatoria y fallar cuando cambia el concepto o el enunciado.

La consecuencia metodológica es directa. La evaluación debe comparar una división estratificada con *GroupKFold* o una variante de dejar preguntas fuera. Deben separarse dos objetivos: desempeño operativo sobre preguntas conocidas y capacidad de transferencia. El segundo escenario contiene numerosas etiquetas no vistas por construcción; por ello es una prueba de extrapolación y no reemplaza la evaluación operativa.

4.10 LLM generativos y evaluación con intervención humana

Los LLM pueden clasificar mediante instrucciones y ejemplos sin entrenamiento convencional. Grévisse (2024) evaluó respuestas médicas breves en 12 cursos y tres idiomas; GPT–4 y Gemini alcanzaron acuerdos moderados, pero la supervisión humana siguió siendo necesaria. El benchmark específico de errores matemáticos de Otero et al. (2025), formado por 55 conceptos erróneos y 220 ejemplos diagnósticos, encontró que restringir el tema y añadir revisión de educadores puede elevar el desempeño de modelos grandes hasta 83.9% en su configuración. La lección no es que el LLM deba reemplazar al clasificador, sino que la información temática y el juicio experto reducen ambigüedad.

Para el proyecto, un LLM alojado externamente introduce variabilidad de versión, costo, latencia, privacidad y dificultad para repetir exactamente el experimento. Puede usarse como comparación *zero-shot/few-shot*, generador de hipótesis o asistente para revisar errores, siempre sin enviar datos sensibles y registrando modelo, fecha, parámetros y plantilla de prompt.

4.11 Confiabilidad, ataques y supervisión

Schneider et al. (2023) estudiaron calificación multilingüe y multiformato a gran escala. Su trabajo muestra que combinar Transformers con intervención humana puede alcanzar niveles comparables a asistentes de docencia y, sobre todo, permite controlar tipos de error. Esto respalda un diseño de apoyo a decisiones: aceptar automáticamente solo predicciones bien calibradas y enviar casos inciertos a revisión.

Filighera et al. (2024) mostraron que insertar adjetivos y adverbios en respuestas incorrectas puede reducir entre 10 y 22 puntos la exactitud de sistemas BERT/T5 en escenarios adversariales. Un sistema puede aprender pistas superficiales que no representan comprensión. En MAP se deben construir pruebas de contraste: añadir palabras irrelevantes, corregir ortografía, invertir una negación y cambiar un número. El modelo debería ser estable ante cambios inocuos y sensible ante cambios matemáticamente decisivos.

5

Síntesis comparativa de la evidencia

Cuadro 5.1: Estudios de revista y aporte transferible al caso MAP

Estudio	Problema/ datos	Método	Hallazgo relevante	Implicación para MAP
Burrows et al. (2015)	Revisión de más de 80 trabajos de respuestas cortas.	Reglas, similitud, ML y evaluación.	Documenta la evolución del campo y la escasez histórica de benchmarks públicos.	Definir baseline y evaluación reproducible antes de aumentar complejidad.
Sahu y Bhowmick (2020)	Calificación automática en conjuntos de referencia.	Características léxicas, alineamiento, semántica y *stacking*.	Las señales complementarias mejoran a modelos aislados.	Ensamblar evidencia lineal y contextual usando predicciones fuera de muestra.
Zhang et al. (2020)	Respuestas estudiantiles condicionadas por pregunta y estudiante.	Red de creencia profunda con modelos de contexto.	Pregunta y estudiante agregan información frente a respuesta sola.	Concatenar pregunta, opción y explicación; evaluar el aporte de cada bloque.
Zhang et al. (2022)	Más de 16,000 respuestas semiabiertas, siete preguntas.	LSTM con información general y específica del dominio.	El orden y el dominio mejoran la representación.	Ablación secuencial opcional; preservar orden y notación.
Zhu et al. (2022)	SemEval 2013 y conjunto Mohler.	BERT, BiLSTM, cápsulas y pérdida especializada.	El preentrenamiento contextual supera referencias en sus conjuntos.	Ajustar un Transformer y compararlo bajo la misma partición.
del Gobbo et al. (2023)	Múltiples conjuntos públicos de ASAG.	TF–IDF, BERT y regresores.	La combinación léxica-semántica es robusta entre dominios.	Conservar TF–IDF como baseline y componente de ensamble.
Bonthu et al. (2023)	ASAG con datos etiquetados limitados.	Transferencia con Transformers de oraciones y aumento.	Reporta +4.91% en exactitud y +3.36% en F1 en su escenario.	Probar aumento conservador, nunca alterar significado matemático.
Padó et al. (2024)	ASAG en alemán, preguntas vistas y no vistas.	Transformers y modelos lingüísticos.	El Transformer no domina necesariamente en preguntas no vistas.	La prueba agrupada por pregunta es indispensable.

Continuación de la Tabla 5.1

Estudio	Problema/ datos	Método	Hallazgo relevante	Implicación para MAP
Bonthu et al. (2024)	Adaptación de dominio para respuestas cortas.	Preentrenamiento específico y ajuste supervisado.	PyDSBERT reporta 88.77% de exactitud y 91.59% F1 en SPRAG.	Probar preentrenamiento continuado con corpus matemático.
Schneider et al. (2023)	Cerca de 10 millones de pares, múltiples idiomas y tipos.	Transformer con flujo humano.	La intervención humana controla fallos y eleva confiabilidad.	Abstención por incertidumbre y revisión de casos críticos.
Filighera et al. (2024)	Ataques de caja negra a ASAG.	Inserción adversarial de adjetivos/adverbios contra BERT/T5.	Descensos de 10–22 puntos evidencian atajos léxicos.	Incluir pruebas de contraste y auditoría de tokens influyentes.
Grévisse (2024)	2,288 respuestas, 82 preguntas, 12 cursos y tres idiomas.	GPT–4 y Gemini con prompting.	Acuerdo moderado y necesidad de supervisión.	LLM solo como comparador/auditor; registrar versión y prompts.
Wang et al. (2025)	Clasificación de experiencia científica en respuestas escritas.	BERT, ontología y balanceo.	El conocimiento estructurado complementa la representación textual.	Usar descripciones y compatibilidades de la taxonomía de errores.
Otero et al. (2025)	55 errores matemáticos y 220 ejemplos diagnósticos.	LLM con restricción temática y revisión experta.	Hasta 83.9% en la configuración reportada.	Limitar candidatos por tema/pregunta y mantener revisión docente.
Morley et al. (2026)	Revisión de 21 artículos sobre respuestas científicas.	BERT a GPT–4.	Predominan BERT/variantes; contexto ayuda; persisten riesgos.	Transformer contextual con métricas de confiabilidad y explicación.

5.1 Patrones convergentes

1. **El contexto importa.** Pregunta, dominio y rúbrica contienen señal que la respuesta aislada no puede reconstruir (Zhang et al., 2020; Morley et al., 2026).

2. **Lo híbrido es competitivo.** TF–IDF y BERT capturan fenómenos distintos; combinarlos mejora robustez y conserva interpretabilidad parcial (del Gobbo et al., 2023; Sahu & Bhowmick, 2020).

3. **El dominio merece adaptación.** Preentrenar o incorporar conocimiento específico ayuda cuando el vocabulario y las relaciones difieren del texto general (Bonthu et al., 2024; Wang et al., 2025).

4. **La validación define la conclusión.** Una partición con preguntas vistas responde a una pregunta distinta de otra con preguntas no vistas (Padó et al., 2024).

5. **Precisión no equivale a confiabilidad.** Los modelos pueden explotar atajos y fallar ante perturbaciones; la calibración, el análisis de error y la intervención humana son componentes del sistema (Filighera et al., 2024; Schneider et al., 2023).

5.2 Vacíos identificados

La literatura de ASAG suele predecir una nota ordinal o binaria; MAP requiere clasificar la naturaleza del razonamiento y ordenar pares jerárquicos. Muchos estudios usan pocas preguntas, lo que dificulta estudiar transferencia. Además, las comparaciones entre modelos rara vez controlan simultáneamente clases de cola larga, notación matemática, calibración y robustez adversarial. Finalmente, los LLM recientes añaden capacidad semántica, pero también dependencia de servicios, versiones y políticas difíciles de congelar.

Estos vacíos hacen que la contribución del proyecto no sea simplemente ajustar un modelo. El valor reside en evaluar un pipeline contextual bajo dos escenarios complementarios —preguntas conocidas y transferencia a preguntas no vistas—, explicar la ganancia sobre una línea base transparente y documentar en qué preguntas y conceptos falla.

6

Selección preliminar de algoritmos

6.1 Criterios de decisión

Se consideran siete criterios: adecuación a texto corto, uso del contexto, desempeño esperado en cola larga, interpretabilidad, costo, facilidad de reproducir y evidencia académica. La Tabla 6.1 resume un juicio preliminar en escala 1–5. No son resultados del conjunto MAP; orientan qué experimentos merecen realizarse.

Cuadro 6.1: Matriz cualitativa de decisión (1 = desfavorable; 5 = muy favorable; Ctx. = contexto; Int. = interpretabilidad; Evid. = evidencia)

Familia	**Texto corto**	**Ctx.**	**Cola larga**	**Int.**	**Costo**	**Evid.**
Reglas/similitud	3	2	1	5	5	3
TF–IDF + logística	4	3	3	5	5	5
TF–IDF + SVM lineal	5	3	3	4	5	5
BiLSTM	3	4	3	2	3	4
BERT/DeBERTa	5	5	4	2	3	5
Modelo adaptado a matemáticas	5	5	4	2	2	4
LLM por API	4	5	3	2	1	3
Ensamble lineal + Transformer	5	5	4	3	3	5

6.2 Nivel 1: baseline lineal híbrido

Modelos seleccionados: regresión logística multinomial y SVM lineal One-vs-Rest sobre la unión de TF–IDF de palabras (1–2 gramas) y caracteres (3–5 gramas).

Razones para considerarlos.

- Son referencias sólidas en ASAG y permiten saber si un modelo complejo aprende más que vocabulario y frases frecuentes.
- Los caracteres toleran errores ortográficos y conservan formas parciales de números, fracciones y operadores.
- La regresión logística produce probabilidades; la SVM suele ser fuerte en espacios dispersos y puede calibrarse posteriormente.
- Los pesos de términos permiten inspeccionar atajos, palabras asociadas con cada concepto y posibles fugas por pregunta.

- Su costo bajo facilita validación cruzada, búsqueda de hiperparámetros y análisis por semillas.

El baseline debe comparar tres entradas: explicación sola; explicación + opción; y pregunta + opción + explicación. Así se cuantifica cuánto aporta el contexto sin atribuir automáticamente toda mejora al Transformer.

6.3 Nivel 2: Transformer contextual y multitarea

Modelo principal: DeBERTa-v3-base o, si el presupuesto computacional lo exige, BERT/RoBERTa base. La entrada concatena pregunta, opción y explicación. La salida emplea dos cabezas: categoría general y error conceptual condicional.

Sea h_{CLS} la representación contextual conjunta. Las dos distribuciones se obtienen mediante

$$p(c \mid x) = \text{softmax}(W_c h_{\text{CLS}} + b_c), \qquad p(m \mid x) = \text{softmax}(W_m h_{\text{CLS}} + b_m).$$

La pérdida multitarea puede escribirse como

$$\mathcal{L} = \mathcal{L}_{cat} + \lambda\, I(m \text{ aplica}) \mathcal{L}_{misc},$$

donde la máscara $I(\cdot)$ evita convertir la ausencia estructural de `Misconception` en una clase artificial. Se evaluarán pérdida ponderada, *focal loss* o muestreo balanceado únicamente con validación, pues una corrección agresiva puede descalibrar el ranking.

Razones para considerarlo.

- La literatura reciente muestra ventajas de representaciones bidireccionales preentrenadas en respuestas cortas (Zhu et al., 2022; Morley et al., 2026).
- La atención contextual puede distinguir negaciones y el papel de una frase dentro de la pregunta.
- La arquitectura multitarea refleja que categoría y error conceptual están relacionados, pero no son idénticos.
- DeBERTa es suficientemente establecido para clasificación y viable en una GPU académica con secuencias cortas.

6.4 Nivel 3: adaptación al lenguaje matemático

Alternativas:

(a) inicializar desde MathBERT; o (b) continuar el preentrenamiento de BERT/DeBERTa mediante *masked language modeling* sobre explicaciones y material matemático no etiquetado, y luego ajustar la tarea.

Esta fase se ejecutará después del Transformer base. Solo se justifica si aporta una mejora estable en preguntas no vistas o clases raras. El corpus de adaptación debe excluir cualquier texto de

validación que contenga señales de etiqueta. Las explicaciones sin etiqueta pueden participar en preentrenamiento auto-supervisado si se respetan las particiones.

Razones para considerarlo. La adaptación de dominio ha mejorado ASAG en literatura reciente (Bonthu et al., 2024), y el vocabulario matemático contiene usos especializados. No se selecciona directamente como única solución porque añade costo y existe riesgo de sobreajuste a las 15 preguntas disponibles.

6.5 Nivel 4: ensamble calibrado y ranking

La salida final exige parejas. Una aproximación coherente calcula

$$p(c, m \mid x) = p(c \mid x)\, p(m \mid c, x),$$

aplica una máscara de compatibilidad y ordena los tres pares con mayor probabilidad. Para categorías sin concepto erróneo se utiliza el valor permitido por el formato de la competencia. La mezcla de baseline y Transformer se ajusta con predicciones fuera de muestra. Temperatura, Platt o regresión isotónica se compararán para calibrar, sin usar el conjunto de prueba.

Razones para considerarlo. MAP@3 recompensa el orden y otorga crédito cuando la etiqueta correcta aparece entre las primeras posiciones. Un ensamble puede rescatar clases en las que el modelo lineal reconoce una expresión precisa y otras en las que el Transformer entiende una paráfrasis. La calibración es clave porque la combinación de probabilidades sin escala comparable es arbitraria.

6.6 Modelo no seleccionado como solución principal

Los LLM generativos por API se incluyen solo como referencia. Pueden formular una explicación legible y usar descripciones de etiquetas, pero su salida puede variar entre versiones y ejecuciones. También elevan costo y riesgo de privacidad y son susceptibles a instrucciones contenidas en el texto estudiantil. Si se prueban, se congelará un conjunto pequeño, se validará formato, se registrará el prompt y se impedirá que texto del estudiante modifique instrucciones del sistema.

Selección final de la revisión

Baseline obligatorio: TF–IDF de palabras + caracteres con logística y SVM. **Modelo principal:** DeBERTa/BERT contextual multitarea. **Experimento avanzado:** adaptación de dominio con MathBERT o preentrenamiento continuado. **Salida operativa:** ensamble calibrado, restricciones jerárquicas y ranking top–3. **LLM:** comparación diagnóstica, no producción.

7

Plan experimental propuesto

7.1 Particiones y control de fuga

Se recomienda conservar un conjunto de prueba final sin contacto durante la selección. Dentro del desarrollo se reportarán dos esquemas complementarios. La validación cruzada estratificada por etiqueta compuesta medirá el desempeño sobre preguntas conocidas; la validación agrupada por `QuestionId` estimará la transferencia a preguntas no vistas. Como solo existen quince preguntas, se usarán tres o cinco folds en el esquema agrupado y se documentará qué preguntas quedan fuera en cada iteración. La selección operativa dará prioridad al primer escenario, mientras que el segundo funcionará como prueba explícita de extrapolación.

Los transformadores de texto, vocabularios, ponderaciones de clase, calibradores y meta-modelos deben ajustarse solo con el fold de entrenamiento. Las predicciones para el ensamble deben ser *out-of-fold*. El texto duplicado o casi duplicado debe permanecer en el mismo grupo para impedir contaminación.

7.2 Métricas

Si r_i es la posición de la primera etiqueta correcta para el ejemplo i, la precisión promedio hasta tres candidatos se expresa como

$$\text{MAP@3} = \frac{1}{N} \sum_{i=1}^{N} \begin{cases} 1/r_i, & r_i \leq 3, \\ 0, & r_i > 3 \text{ o no aparece.} \end{cases}$$

MAP@3 será la métrica de selección por alinearse con el reto. Se acompañará de:

- macro F1 y recall macro para visibilizar clases raras;
- F1 ponderado y exactitud como contexto, nunca de forma aislada;
- desempeño por `QuestionId`, categoría y concepto erróneo;
- recall@3 y rango recíproco medio;
- pérdida logarítmica y error de calibración esperado;
- media y desviación entre semillas y folds.

7.3 Secuencia de experimentos

Cuadro 7.1: Hoja de ruta experimental

Fase	Experimento	Pregunta que responde	Criterio de avance
0	Dummy por frecuencia y por pregunta	¿Qué desempeño se obtiene sin leer el texto?	Todo modelo real debe superarlo en MAP@3 y macro F1.
1	TF–IDF palabra/carácter + logística/SVM	¿Cuánta señal existe en expresiones superficiales?	Baseline estable y errores interpretables.
2	Ablación de entradas	¿Qué aportan opción y pregunta?	Mejoras consistentes en folds agrupados.
3	BERT/DeBERTa contextual	¿La semántica contextual supera al baseline?	Mejora con costo y varianza aceptables.
4	Pérdida multitarea y balanceo	¿La jerarquía ayuda a conceptos raros?	Mayor macro F1 sin degradar MAP@3/calibración.
5	Adaptación matemática	¿El dominio aporta transferencia?	Ganancia en preguntas no vistas y clases raras.
6	Ensamble y calibración	¿Las señales son complementarias?	Mejora fuera de muestra y probabilidades más confiables.
7	Robustez y revisión humana	¿El modelo usa contenido o atajos?	Estabilidad ante perturbaciones inocuas y ruta de abstención.

7.4 Hiperparámetros iniciales

Cuadro 7.2: Espacio inicial de búsqueda, sujeto al presupuesto computacional

Componente	Valores iniciales	Observación
TF–IDF palabra	n-gramas (1,1), (1,2); min df 2–5; sublinear TF	No eliminar negaciones; revisar *stopwords*.
TF–IDF carácter	n-gramas (3,5), (3,6); límites de palabra y texto	Captura ortografía y notación parcial.
Logística/SVM	$C \in \{0.1, 0.5, 1, 2, 5\}$; peso balanceado sí/no	Calibrar SVM en fold separado.
Transformer	tasa 1–5 $\times 10^{-5}$; 3–8 épocas; longitud 128–256	*Early stopping* por MAP@3 agrupado.
Balanceo	ponderación inversa suavizada, focal $\gamma \in \{1, 2\}$	Comparar calibración y clases frecuentes.
Multitarea	$\lambda \in \{0.25, 0.5, 1, 2\}$	Máscara para etiqueta no aplicable.
Ensamble	$\alpha \in \{0, 0.1, \ldots, 1\}$	Ajustar solo con out-of-fold.
Semillas	mínimo 3	Reportar promedio y dispersión.

7.5 Análisis de errores y explicabilidad

Se construirá una matriz de confusión para etiquetas con soporte suficiente y una tabla de los pares confundidos. Para el modelo lineal se inspeccionarán n-gramas de mayor peso. Para el Transformer se usarán técnicas de atribución como gradientes integrados o eliminación de tokens, evitando interpretar pesos de atención como explicación causal.

Cada muestra auditada incluirá pregunta, opción, explicación, etiqueta real, top–3, probabilidades y observación del revisor. Se priorizarán: clases minoritarias, predicciones confiadas e incorrectas, desacuerdos entre baseline y Transformer, casos que cambian al modificar una negación y ejemplos sintéticos.

8

Riesgos, ética y reproducibilidad

8.1 Sesgos y cobertura

El conjunto MAP no representa automáticamente a todos los estudiantes, niveles, idiomas o currículos. El desempeño puede variar con ortografía, dialecto, competencia lingüística o formas distintas de explicar el mismo concepto. Una etiqueta de "concepto erróneo" describe una respuesta, no una identidad estable del estudiante. El sistema no debe usarse para decisiones disciplinarias ni para inferir capacidad general.

8.2 Incertidumbre y supervisión

Se recomienda una política de abstención. Si la probabilidad está mal calibrada, el margen entre los dos primeros candidatos es pequeño o la entrada queda fuera de distribución, el sistema debe mostrar tres sugerencias y solicitar revisión. La literatura de sistemas confiables favorece combinar automatización con control humano, en lugar de presentar la predicción como verdad definitiva (Schneider et al., 2023; Grévisse, 2024).

8.3 Privacidad y seguridad

Las explicaciones pueden contener datos personales introducidos accidentalmente. Antes de usar servicios externos debe existir anonimización y autorización. Los prompts no deben permitir que el contenido de la respuesta sustituya las instrucciones de clasificación. Además, las pruebas adversariales propuestas por Filighera et al. (2024) deben formar parte de la evaluación, no considerarse una tarea posterior opcional.

8.4 Reproducibilidad

Todo experimento debe registrar versión del conjunto, hash de particiones, semillas, librerías, hiperparámetros, hardware y tiempo. Se conservarán matrices de resultados por fold y no solo el mejor número. El repositorio debe separar datos, notebooks, código fuente, modelos y reportes; los archivos grandes o con licencia restrictiva no deben subirse sin verificación.

9

Conclusiones

La revisión bibliográfica permite responder las dos actividades solicitadas. En problemas similares se han empleado reglas y similitud, TF–IDF con regresión o SVM, ensambles de características, LSTM, Transformers ajustados, adaptación de dominio y LLM mediante prompting. No existe un ganador universal: el resultado depende de si las preguntas son vistas, del tamaño del corpus, del dominio, de la distribución de clases y del nivel de supervisión humana.

Para MAP, la evidencia favorece un enfoque contextual e híbrido. El baseline TF–IDF proporciona rapidez, transparencia y control. El Transformer incorpora pregunta, opción y explicación para capturar semántica. La formulación multitarea respeta la estructura entre categoría y error conceptual. La adaptación de dominio es un experimento avanzado justificado por el lenguaje matemático, y el ensamble calibrado transforma las probabilidades en el ranking top–3 exigido.

La contribución más importante del diseño será una evaluación honesta. Comparar particiones estratificada y agrupada, reportar macro F1 y MAP@3, analizar clases raras, probar perturbaciones y documentar incertidumbre evitará que una puntuación elevada por memorización se confunda con comprensión. Bajo estas condiciones, el sistema puede apoyar al docente a localizar patrones de razonamiento y priorizar retroalimentación, sin reemplazar su juicio.

Recomendación de implementación

Iniciar con el baseline y las ablaciones de contexto; ajustar después un DeBERTa/BERT multitarea; probar adaptación matemática solo si mejora de forma consistente ambos escenarios de validación; y cerrar con calibración, ensamble y auditoría humana. Esta secuencia maximiza el aprendizaje experimental por unidad de costo y mantiene una referencia interpretable en cada etapa.

Referencias

Bonthu, S., Sree, S. R., & Krishna Prasad, M. H. M. (2023). Improving the performance of automatic short answer grading using transfer learning and augmentation. *Engineering Applications of Artificial Intelligence, 123*, 106292. https://doi.org/10.1016/j.engappai.2023.106292

Bonthu, S., Sree, S. R., & Krishna Prasad, M. H. M. (2024). Framework for automation of short answer grading based on domain-specific pre-training. *Engineering Applications of Artificial Intelligence, 137*, 109163. https://doi.org/10.1016/j.engappai.2024.109163

Burrows, S., Gurevych, I., & Stein, B. (2015). The eras and trends of automatic short answer grading. *International Journal of Artificial Intelligence in Education, 25*(1), 60–117. https://doi.org/10.1007/s40593-014-0026-8

del Gobbo, E., Guarino, A., Cafarelli, B., & Grilli, L. (2023). GradeAid: A framework for automatic short answers grading in educational contexts—Design, implementation and evaluation. *Knowledge and Information Systems, 65*, 4295–4334. https://doi.org/10.1007/s10115-023-01892-9

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (Vol. 1, pp. 4171–4186). Association for Computational Linguistics. https://doi.org/10.18653/v1/N19-1423

Filighera, A., Ochs, S., Steuer, T., & Tregel, T. (2024). Cheating automatic short answer grading with the adversarial usage of adjectives and adverbs. *International Journal of Artificial Intelligence in Education, 34*, 616–646. https://doi.org/10.1007/s40593-023-00361-2

Grévisse, C. (2024). LLM-based automatic short answer grading in undergraduate medical education. *BMC Medical Education, 24*, 1060. https://doi.org/10.1186/s12909-024-06026-5

He, P., Liu, X., Gao, J., & Chen, W. (2021). DeBERTa: Decoding-enhanced BERT with disentangled attention. In *International Conference on Learning Representations*. https://openreview.net/forum?id=XPZIaotutsD

Kaggle. (2025). *MAP—Charting student math misunderstandings* [Data science competition]. https://www.kaggle.com/competitions/map-charting-student-math-misunderstandings/overview

Morley, F., Walland, E., & Vidal Rodeiro, C. L. (2026). Auto-marking short answer questions in science: The foundational years of transformer-based models from BERT to GPT-4. *International Journal of Artificial Intelligence in Education, 36*(1–2), 100005. https://doi.org/10.1016/j.ijaied.2026.100005

Otero, N., Druga, S., & Lan, A. (2025). A benchmark for math misconceptions: Bridging gaps in middle school algebra with AI-supported instruction. *Discover Education, 4*, 277. https://doi.org/10.1007/s44217-025-00742-w

Padó, U., Eryilmaz, Y., & Kirschner, L. (2024). Short-answer grading for German: Addressing the challenges. *International Journal of Artificial Intelligence in Education, 34*(4), 1321–1352. https://doi.org/10.1007/s40593-023-00383-w

Rittle-Johnson, B., Adler, R., Durkin, K., Burleigh, L., King, J., & Crossley, S. (2025). Detecting math misconceptions: An AI benchmark dataset. In *Proceedings of the 1st Workshop on Advancing Artificial Intelligence through Theory of Mind* (pp. 20–24). Association for Computational Linguistics. https://aclanthology.org/2025.aimecon-wip.3/

Rushton, S. J. (2018). Teaching and learning mathematics through error analysis. *Fields Mathematics Education Journal, 3*, Article 4. https://doi.org/10.1186/s40928-018-0009-y

Sahu, A., & Bhowmick, P. K. (2020). Feature engineering and ensemble-based approach for improving automatic short-answer grading performance. *IEEE Transactions on Learning Technologies, 13*(1), 77–90. https://doi.org/10.1109/TLT.2019.2897997

Schneider, J., Richner, R., & Riser, M. (2023). Towards trustworthy AutoGrading of short, multi-lingual, multi-type answers. *International Journal of Artificial Intelligence in Education, 33*(1), 88–118. https://doi.org/10.1007/s40593-022-00289-z

Shen, J. T., Yamashita, M., Prihar, E., Heffernan, N. T., Wu, X., Lee, D., & Wang, D. (2021). MathBERT: A pre-trained language model for general NLP tasks in mathematics education. *arXiv*. https://doi.org/10.48550/arXiv.2106.07340

Wang, H., Haudek, K. C., Manzanares, A. D., Romulo, C. L., Royse, E. A., & Azzarello, C. B. (2025). Extending a pretrained language model (BERT) using an ontological perspective to classify students' scientific expertise level from written responses. *Disciplinary and Interdisciplinary Science Education Research, 7*, 26. https://doi.org/10.1186/s43031-025-00149-5

Zhang, L., Huang, Y., Yang, X., Yu, S., & Zhuang, F. (2022). An automatic short-answer grading model for semi-open-ended questions. *Interactive Learning Environments, 30*(1), 177–190. https://doi.org/10.1080/10494820.2019.1648300

Zhang, Y., Lin, C., & Chi, M. (2020). Going deeper: Automatic short-answer grading by combining student and question models. *User Modeling and User-Adapted Interaction, 30*(1), 51–80. https://doi.org/10.1007/s11257-019-09251-6

Zhu, X., Wu, H., & Zhang, L. (2022). Automatic short-answer grading via BERT-based deep neural networks. *IEEE Transactions on Learning Technologies, 15*(3), 364–375. https://doi.org/10.1109/TLT.2022.3175537

Apéndice A. Correspondencia entre evidencia y decisión

Decisión	Evidencia principal	Comprobación local
Baseline TF–IDF/SVM	Burrows et al. (2015); del Gobbo et al. (2023)	Validación doble, pesos de n-gramas y costo.
Entrada con pregunta y opción	Zhang et al. (2020); Morley et al. (2026)	Ablación de tres configuraciones de entrada.
Transformer contextual	Zhu et al. (2022); Morley et al. (2026)	MAP@3 y macro F1 contra baseline, mismas particiones.
Adaptación de dominio	Bonthu et al. (2024); Wang et al. (2025)	Ganancia en preguntas no vistas y clases raras.
Ensamble híbrido	Sahu y Bhowmick (2020); del Gobbo et al. (2023)	Mezcla con predicciones out-of-fold y calibración.
Validación por pregunta	Padó et al. (2024)	GroupKFold por `QuestionId`.
Pruebas adversariales	Filighera et al. (2024)	Perturbaciones inocuas y cambios semánticos mínimos.
Supervisión humana	Schneider et al. (2023); Grévisse (2024)	Umbral de abstención y auditoría de alta incertidumbre.

Apéndice B. Lista de verificación antes de entrenar

1. Congelar ambas particiones y verificar que ningún duplicado cruce entre entrenamiento y validación; en el esquema agrupado tampoco debe cruzar una pregunta.
2. Confirmar la semántica exacta de categorías, valores nulos estructurales y formato de pares permitido.
3. Construir dummy y baseline antes de ajustar Transformers.
4. Conservar números, signos, operadores y negaciones en preprocesamiento.
5. Ajustar vectorizador, ponderaciones y calibrador dentro de cada fold.
6. Reportar MAP@3, macro F1, resultados por pregunta/clase y variación entre semillas.
7. Auditar ejemplos confiados e incorrectos, clases raras y desacuerdos entre modelos.
8. Documentar licencias, versiones, semillas, hardware, tiempos y huella de datos.
9. Definir un umbral de abstención y la intervención humana esperada.
10. No interpretar las puntuaciones de la matriz cualitativa como resultados empíricos.